

Politechnika Warszawska

W Y D Z I A Ł E L E K T R Y C Z N Y



Instytut Sterowania i Elektroniki Przemysłowej

Praca dyplomowa magisterska

na kierunku Informatyka Stosowana
w specjalności Inżynieria Oprogramowania

Rekonstrukcja trójwymiarowej sceny na podstawie jednego lub kilku zdjęć

Kamil Snopkowski

numer albumu 340973

promotor

dr inż. Witold Czajewski

Warszawa 2026

Rekonstrukcja trójwymiarowej sceny na podstawie jednego lub kilku zdjęć

Streszczenie

Niniejsza praca magisterska dotyczy rekonstrukcji trójwymiarowych scen na podstawie jednego obrazu lub niewielkiej liczby obrazów z wykorzystaniem współczesnych modeli opartych na architekturze typu „Transformer”. Jej celem było porównanie metod VGGT, MAST3R i MapAnything pod względem jakości uzyskiwanych rekonstrukcji oraz kosztu obliczeniowego ich praktycznego zastosowania na konsumenckim sprzęcie. Przyjęto cztery scenariusze badawcze obejmujące jeden, dwa, cztery i osiem obrazów wejściowych. Badania przeprowadzono na zbiorach LLFF i ETH3D oraz autorskim zestawie danych, a analizowane sceny podzielono na kategorie wewnętrzne, zewnętrzne, obiektowe i naturalne. Jakość wyników oceniano na podstawie ustandaryzowanej analizy wizualnej obejmującej kompletność, spójność geometryczną, występowanie artefaktów oraz odwzorowanie szczegółów. Dodatkowo dla MapAnything przeprowadzono ograniczoną analizę dokładności metrycznej, która wykazała silną zależność uzyskiwanych błędów od analizowanej sceny. Zwiększanie liczby obrazów w części przypadków umożliwiało odtworzenie dodatkowych fragmentów geometrii, lecz jednocześnie mogło prowadzić do wzrostu liczby artefaktów i nie gwarantowało poprawy ogólnej jakości rekonstrukcji. MapAnything osiągał ogólnie najlepsze wyniki jakościowe, wyróżniając się przede wszystkim kompletnością. Analiza wydajności wykazała, że VGGT i MapAnything zapewniały krótki czas działania, natomiast MAST3R wymagał znacznie dłuższego przetwarzania. Wyniki potwierdzają możliwość uzyskania użytecznej reprezentacji 3D z bardzo ograniczonej liczby zdjęć, wskazując jednocześnie na trudności związane zwłaszcza z roślinnością, cienkimi elementami oraz powierzchniami jednolitymi i refleksyjnymi.

Słowa kluczowe: rekonstrukcja 3D, rekonstrukcja z pojedynczego obrazu, rekonstrukcja wielowidokowa, modele Transformer, autorski zbiór danych, analiza wydajności, analiza jakości

One-shot and few-shot 3D scene reconstruction

Abstract

This master's thesis concerns the reconstruction of three-dimensional scenes from a single image or a small number of images using contemporary models based on the Transformer architecture. Its aim was to compare the VGGT, MAST3R, and MapAnything methods in terms of the quality of the resulting reconstructions and the computational cost of their practical use on consumer-grade hardware. Four experimental scenarios were considered, involving one, two, four, and eight input images. The experiments were conducted on the LLFF and ETH3D datasets as well as on a custom dataset, with the analysed scenes divided into indoor, outdoor, object-centric, and natural categories. Reconstruction quality was assessed using a standardised visual analysis covering completeness, geometric consistency, the presence of artifacts, and the reproduction of scene details. In addition, a limited metric accuracy analysis was performed for MapAnything, revealing that the resulting errors were strongly dependent on the analysed scene. Increasing the number of images enabled additional parts of the scene geometry to be reconstructed in some cases, but could also lead to an increase in artifacts and did not guarantee an improvement in overall reconstruction quality. MapAnything achieved the best overall qualitative results, particularly in terms of completeness. The performance analysis showed that VGGT and MapAnything provided short processing times, whereas MAST3R required substantially longer computation. The results confirm that useful 3D representations can be obtained from a very limited number of images, while also highlighting challenges associated particularly with vegetation, thin structures, and uniform or reflective surfaces.

Keywords: 3D reconstruction, single-image reconstruction, multi-view reconstruction, Transformer-based models, custom dataset, performance analysis, quality analysis

Spis treści

1	Wstęp	1
2	Stan wiedzy	5
2.1	Metody rekonstrukcji 3D	7
2.1.1	Odzyskiwanie geometrii z pojedynczego obrazu	8
2.1.2	Wolumetryczne reprezentacje sceny	10
2.1.3	Rzadka rekonstrukcja sceny	11
2.1.4	Gęsta rekonstrukcja sceny	13
2.1.5	Neuronowe pola radiancji	14
2.1.6	Rozsmarowywanie Gaussów	15
2.1.7	Duże modele jednokierunkowe	16
3	Przegląd istniejących rozwiązań	19
3.1	Omówienie przetestowanych metod	20
3.2	Architektura i charakterystyka wybranych modeli	25
4	Zbiory danych	31
4.1	Przegląd zbiorów danych	31
4.2	Stworzenie własnego zbioru danych	37
5	Analiza i porównanie eksperymentów	43
5.1	Charakterystyka przeprowadzonej analizy	43
5.2	Analiza wydajnościowa	47
5.3	Analiza jakościowa	55
6	Podsumowanie	73
6.1	Dalsze prace	74
	Bibliografia	77
	Wykaz skrótów i symboli	81
	Spis rysunków	83

Spis tabel	87
Spis załączników	89

Rozdział 1

Wstęp

Zdolność postrzegania i interpretacji środowiska na podstawie bodźców wizualnych stanowi podstawową umiejętność człowieka. Dążenie do odwzorowania tej umiejętności w systemach cyfrowych sprawiło, że rekonstrukcja trójwymiarowej sceny na podstawie obrazu pozostaje wieloletnim wyzwaniem z dziedziny widzenia komputerowego (ang. *computer vision*). Prace nad tym zagadnieniem rozpoczęły się już we wczesnych latach 60. XX wieku, a następnie były kontynuowane przez kolejne dziesięciolecia aż do współczesności, co w ostatnich latach zaowocowało wzrostem zainteresowania oraz liczbą naukowych przełomów. Bez względu jednak na aktualny stan rozwoju technologicznego niezmienny pozostaje jeden podstawowy wymóg, niezbędny do wykonania komputerowej rekonstrukcji 3D. By komputer, a w dalszej mierze algorytm, był w stanie wykonać rekonstrukcję, konieczne jest uprzednie cyfrowe zapisanie obserwowanej sceny. Metody takiego zapisu są różnorakie, a jedną z najstarszych i najprostszych jest zdjęcie. Obrazy posiadają wiele zalet, takich jak łatwość pozyskania czy powszechność sprzętu umożliwiającego ich rejestrację. To między innymi te przewagi przyczyniały się do dalszego rozwoju tej dziedziny, doprowadzając do stanu, w którym nawet nowoczesne metody tworzenia scen trójwymiarowych mogą okazywać się mniej optymalne w porównaniu z zautomatyzowanymi procesami na podstawie obrazów. Taka automatyzacja może znacząco ograniczyć czas i nakład pracy przykładowo w porównaniu z ręcznym opracowywaniem geometrii w systemach CAD (ang. *computer-aided design*) lub narzędziach klasy DCC (ang. *digital content creation*), co nawet dla wykwalifikowanego specjalisty może oznaczać od kilku do kilkudziesięciu godzin. Choćby rezultaty obu procesów nie są bezpośrednio porównywalne, współczesne algorytmy pozwalają uzyskać przybliżoną geometrię sceny w znacznie krótszym czasie. Bazowanie na obrazie stawia jednak szereg problemów natury fizycznej, technicznej i algorytmicznej. Jednym z takich problemów jest silne powiązanie dokładności algorytmów z właściwościami fizycznymi obiektów, którymi są m.in. tekstura czy refleksyjność powierzchni. Niska jakość danych wejściowych może znacząco zdegradować końcowy wynik reprezentacji, a z praktycznej perspektywy kluczowym problemem jest optymalizacja algorytmów w taki sposób, aby rekonstrukcja była możliwa poza środowiskiem laboratoryjnym lub bez specjalistycznego, kosztownego sprzętu. Jednocześnie możliwość przetworzenia zdjęć elementów lub całych scen ze świata rzeczywistego na skomplikowane struktury trójwymiarowe znajduje szereg

zastosowań w wielu dynamicznie rozwijających się gałęziach gospodarki. W branży pojazdów autonomicznych nagrania z kamer zarejestrowane podczas jazdy mogą posłużyć do rekonstrukcji środowisk większej skali, takich jak całe dzielnice miast [31]. W kontekście wirtualnej oraz rozszerzonej rzeczywistości zdjęcia wykorzystuje się do precyzyjnego lokalizowania globalnej pozycji [1]. W robotyce, gdzie kluczową rolę odgrywa zrozumienie i wejście w interakcje z otoczeniem, nowoczesne algorytmy rekonstrukcji bezpośrednio przyczyniają się do zwiększania możliwości maszyn autonomicznych [42, 37].

Podczas gdy większość nowoczesnych metod rekonstrukcji 3D skupia się na fuzji kilkudziesięciu lub kilkuset widoków tej samej sceny, wykorzystując m.in. zasady fotogrametrii lub geometrii epipolarnej, rekonstrukcja z pojedynczego obrazu lub ograniczonej liczby obrazów musi stosować inne środki, by wiernie odtworzyć strukturę docelowego obiektu lub sceny. Jednym z nich jest wykorzystanie metod uczenia maszynowego, zwiększających możliwości modeli rekonstrukcyjnych dzięki wykorzystaniu wiedzy nabytej w trakcie treningu. To właśnie tej kategorii modele zostały wykorzystane w ramach niniejszej pracy.

Cel pracy

Celem badawczym niniejszej pracy była analiza i porównanie współczesnych metod rekonstrukcji 3D z wykorzystaniem bardzo małej liczby zdjęć. Do badań wybrano trzy modele: VGGT [35], MapAnything [13] oraz MAST3R [15]. Rozwiązania te pozwalają na wykorzystanie różnej liczby danych wejściowych oraz możliwe są do uruchomienia na konsumenckiej jednostce komputerowej. Część eksperymentalną zaplanowano w czterech scenariuszach różniących się liczbą obrazów wejściowych. Poszczególne modele testowano z wykorzystaniem kolejno jednego, dwóch, czterech i ośmiu zdjęć tej samej sceny, przy czym dla MAST3R pominięto scenariusz jednoobrazowy, ponieważ metoda ta opiera się na przetwarzaniu par obrazów i wymaga co najmniej dwóch widoków. Na potrzeby pracy wykorzystano dwa publicznie dostępne zbiory danych oraz opracowano dodatkowy autorski zbiór po to, by przetestować działanie badanych modeli w warunkach zbliżonych do praktycznych zastosowań. Sceny zawarte w takim zestawieniu zbiorów podzielono na cztery kategorie:

- **wewnętrzne** — pomieszczenia i ich wyposażenie,
- **zewewnętrzne** — zabudowę i otoczenie,
- **obiektywne** — obiekt wyraźnie dominujący w części sceny,
- **naturalne** — roślinność.

Kluczową część pracy stanowiła analiza wyników, podzielona na dwa główne obszary: jakość uzyskiwanych rekonstrukcji oraz wydajność obliczeniową. Analiza jakościowa opierała się na wizualnej ocenie wygenerowanych reprezentacji 3D, prowadzonej z uwzględnieniem ich kompletności, spójności geometrii, występowania artefaktów oraz jakości odwzorowania drobnych szczegółów. Nie obejmowała natomiast pełnej ilościowej oceny dokładności geometrycznej względem referencyjnego

modelu 3D z wykorzystaniem standardowych metryk. Jako uzupełnienie przeprowadzono jednak ograniczoną analizę dokładności metrycznej dla modelu MapAnything. Badanie polegało na porównaniu rzeczywistych długości wybranych elementów scen z odpowiadającymi im odległościami wyznaczonymi w rekonstrukcji. Ze względu na ograniczoną liczbę scen i pomiarów miało ono charakter pomocniczy i nie stanowiło pełnoprawnej oceny dokładności geometrycznej modelu. Analiza wydajności koncentrowała się na czasie działania badanych metod oraz ich zapotrzebowaniu na zasoby sprzętowe. Uwzględniono zarówno czas inferencji, jak i czas rekonstrukcji pojedynczego przypadku testowego. Dodatkowo analizowano szczytowe wykorzystanie pamięci operacyjnej RAM oraz pamięci karty graficznej VRAM.

Przeprowadzone badania miały przede wszystkim określić, w jaki sposób liczba obrazów wejściowych wpływa na kompletność i ogólną jakość rekonstrukcji, jakie rodzaje scen sprawiają analizowanym metodom największe trudności oraz czym różnią się VGGT, MAST3R i MapAnything zarówno pod względem sposobu działania, jak i wpływu tych różnic na charakter oraz jakość uzyskiwanych wyników. Równocześnie badano, jak wraz ze wzrostem liczby obrazów wejściowych zmienia się koszt obliczeniowy poszczególnych metod. W szerszym ujęciu praca zmierzała do odpowiedzi na pytanie, czy współczesne modele rekonstrukcji 3D są w stanie, przy bardzo ograniczonej liczbie obrazów wejściowych, uzyskać użyteczną reprezentację geometrii sceny przy jednocześnie akceptowalnym czasie działania i wymaganiach sprzętowych.

Struktura pracy

Praca została podzielona na sześć rozdziałów. **Rozdział 1** oraz **rozdział 6** stanowią kolejno wstęp do problematyki rekonstrukcji trójwymiarowej na podstawie obrazów oraz podsumowanie niniejszej pracy.

Rozdział 2 obejmuje podstawy teoretyczne tematu i przegląd najpopularniejszych spośród metod rekonstrukcji 3D.

Rozdział 3 w części zasadniczej przedstawia metody wybrane do analizy eksperymentalnej: VGGT, MAST3R oraz MapAnything. Dla każdej z nich omówiono podstawowe założenia, budowę modelu, sposób przetwarzania danych wejściowych oraz generowane rezultaty. Wymieniono również metody rekonstrukcyjne analizowane w ramach pracy, ale niezakwalifikowane do końcowego badania.

Rozdział 4 skupia się na omówieniu popularnych, publicznie dostępnych zbiorów danych, wybranych zbiorów wykorzystanych w niniejszej pracy oraz opracowanego zbioru autorskiego, wraz z opisem procesu jego tworzenia i charakterystyką zawartych w nim scen.

Rozdział 5 zawiera prezentację i analizę wyników eksperymentalnych. W pierwszej części zaprezentowano charakterystykę wykonanych badań. Następnie porównano wydajność obliczeniową modeli, uwzględniając najważniejsze parametry działania algorytmów rekonstrukcyjnych. Rozdział kończy ustandaryzowana analiza wizualna, koncentrująca się na zmianach zachodzących wraz ze zwiększaniem liczby widoków, charakterystycznych tendencjach poszczególnych modeli, różnicach

między kategoriami scen oraz istniejących ograniczeniach. Analizę tę uzupełnia ograniczona analiza dokładności metrycznej rekonstrukcji uzyskiwanych za pomocą modelu MapAnything.


Rozdział 2

Stan wiedzy

Badania metod odtworzenia trójwymiarowej struktury na podstawie obrazu nie są domeną wyłącznie współczesnej informatyki. Ich początki sięgają roku 1963, gdy ukazała się praca „Machine Perception of Three-Dimensional Solids” autorstwa Lawrence’a Robertsa [23]. Nazywany jednym z pionierów widzenia komputerowego, Roberts omawia w niej proces pozyskiwania informacji o trójwymiarowych obiektach z pojedynczych fotografii. Zaproponowany system przekształcał obraz wejściowy w reprezentację krawędziową, a następnie analizował powstały układ linii w celu dopasowania znanych modeli trójwymiarowych oraz wyznaczenia ich położenia i orientacji w przestrzeni. Metoda opierała się przy tym na silnych założeniach dotyczących analizowanych scen, w szczególności na wykorzystaniu obiektów złożonych z płaskich powierzchni, możliwych do opisanego za pomocą niewielkiego zestawu wcześniej zdefiniowanych brył. Uzyskana reprezentacja mogła następnie posłużyć do wygenerowania rzutu sceny z innego punktu widzenia.

W kolejnych dekadach rozwój widzenia komputerowego prowadził do formułowania bardziej ogólnych modeli opisujących sposób pozyskiwania informacji przestrzennej z obrazów. Jedną z najbardziej wpływowych koncepcji przedstawił David Marr [19], który zaproponował pojęcie „szkicu pierwotnego” (ang. *primal sketch*), stanowiącego symboliczną reprezentację podstawowych struktur wyodrębnionych z obrazu. Proces jego tworzenia rozpoczynał się od wykrywania lokalnych zmian intensywności obrazu w różnych skalach. Na ich podstawie tworzony był „surowy szkic pierwotny” (ang. *raw primal sketch*), którego elementami były między innymi krawędzie, linie, plamy oraz ich zakończenia i nieciągłości. Elementom tym przypisywano właściwości takie jak położenie, orientacja, kontrast, długość i szerokość. Następnie analizowano ich wzajemne relacje przestrzenne oraz grupowano je w większe struktury, tworząc „pełny szkic pierwotny” (ang. *full primal sketch*). Informacje zawarte w szkicu pierwotnym stanowiły podstawę dalszej analizy obrazu, prowadzącej do określenia dodatkowych właściwości powierzchni wykorzystywanych przy tworzeniu „szkicu 2,5D”, stanowiącego formę pośrednią pomiędzy dwuwymiarowym obrazem a trójwymiarowym modelem. Szkic ten ma na celu odwzorowanie orientacji i głębi widocznych powierzchni. Opiera się on na zestawieniu powierzchniowych prymitywów (ang. *surface primitives*) określających nachylenie, odległość od obserwatora oraz na wykrywaniu nieciągłości w głębi i strukturze. Szkic 2,5D stanowił

punkt wyjścia do utworzenia reprezentacji modelu 3D, której schemat organizacji przedstawiono na rys. 1. Lewa strona zawiera oś modelu, a prawa strona przedstawia rozkład osi składowych modelu, zaznaczonych poprzez sposób, w jaki prostokąty nachodzą na siebie. Rysunek służy jednak wyłącznie celom ilustracyjnym, ponieważ względne położenie i orientacja osi składowych modelu są przedstawione w niepoprawnym układzie, wyśrodkowanym względem kamery, a nie wyśrodkowanym względem obiektu.



Rysunek 1. Przykład hierarchicznej reprezentacji modelu człowieka z podziałem na kolejne części składowe: kończynę górną, przedramię oraz dłoń. Źródło: [10]

Te wczesne koncepcje, opierające się na ekstrakcji cech obrazu 2D i stopniowym przekształcaniu ich w wartości przestrzenne, położyły podwaliny pod cały późniejszy rozwój dziedziny widzenia komputerowego. Wykorzystując tę wiedzę, kolejne pokolenia badaczy były w stanie ustandaryzować i udoskonalić metody rekonstrukcji 3D. Zanim jednak zostaną one szczegółowo omówione w tej pracy, w pierwszej kolejności należy zdefiniować formy reprezentacji, w jakich systemy komputerowe zapisują i generują trójwymiarowy świat.

Formy reprezentacji

Rekonstrukcja 3D to złożone zagadnienie, które można realizować i kategoryzować na podstawie wielu różnych kryteriów. Jednym z podstawowych podziałów metod rekonstrukcji jest ten wynikający z rodzaju zastosowanej reprezentacji przestrzennej. W ramach takiego podziału rozróżniamy dwa główne podejścia: reprezentację jawną (ang. *explicit representation*) oraz niejawną (ang. *implicit representation*). Wybór konkretnej formy reprezentacji ma decydujący wpływ na architekturę końcowego algorytmu, przebieg samego procesu rekonstrukcji, a w konsekwencji także na dobór odpowiednich metod i metryk ewaluacji wyników.

1. **Reprezentacja jawna** — w widzeniu komputerowym termin ten oznacza reprezentację geometrii, w której kształt obiektu jest bezpośrednio i szczegółowo opisany poprzez zbiór jego elementów w trójwymiarowej przestrzeni. Najczęściej wykorzystywanymi przykładami reprezentacji tego typu są siatki wielokątów (ang. *meshes*), chmury punktów (ang. *point clouds*) oraz woksele (ang. *voxels*). Ich istotną zaletą jest dostęp do zapisanej w pamięci geometrii, łatwość modyfikacji oraz dobra kompatybilność z innymi narzędziami grafiki komputerowej, zwłaszcza w przypadku siatek i chmur punktów. Wadą tych metod bywa jednak wysoki koszt pamięci, szczególnie częsty dla gęstych siatek wokselowych.
2. **Reprezentacja niejawna** — tego typu reprezentacje opisują scenę nie poprzez bezpośrednie przechowywanie jej geometrii, lecz za pomocą ciągłej funkcji matematycznej. Dla podanych współrzędnych przestrzennych funkcja ta może zwracać różne parametry opisujące scenę, takie jak odległość od struktury, gęstość ośrodka czy kolor zależny od kierunku obserwacji. W praktyce funkcja ta jest często aproksymowana przez sieci neuronowe, zwłaszcza wielowarstwowe perceptrony (MLP). Do najważniejszych przykładów reprezentacji niejawnych należą Signed Distance Fields (SDF), Occupancy Networks oraz neuronowe pola radiancji (ang. *Neural Radiance Fields*, NeRF). Ciągły charakter reprezentacji oraz brak teoretycznego ograniczenia rozdzielczości stanowią główną zaletę takiego rozwiązania. Jednocześnie wadą tych metod jest wysoki koszt obliczeniowy, szczególnie w przypadku modeli takich jak NeRF, gdzie proces renderowania wymaga wielokrotnego odpytywania funkcji wzdłuż promieni przemierzających scenę (ang. *ray marching*).

2.1 Metody rekonstrukcji 3D

Rekonstrukcję trójwymiarową na podstawie obrazów można w uproszczeniu określić jako proces odzyskiwania informacji o geometrii obserwowanego obiektu lub sceny na podstawie zarejestrowanych danych, a następnie zapisania jej w wybranej formie reprezentacji jawnej lub niejawnej. Przed omówieniem poszczególnych metod rekonstrukcji należy jednak zwrócić uwagę na charakter wykorzystywanych danych wejściowych. W niniejszej pracy skupiono się na obrazach stanowiących dwuwymiarowe projekcje obserwowanej sceny; nie są one jednak jedynym źródłem informacji wykorzystywanym do odtwarzania geometrii trójwymiarowej. Ze względu na sposób pozyskiwania informacji przestrzennej metody rekonstrukcji 3D można podzielić na **aktywne** oraz **pasywne**.

Określenie **aktywne** wywodzi się ze sposobu, w jaki zdobywane są dane na temat obserwowanego obiektu. Specjalistyczne urządzenia potrafią emitować wiązki światła lub promieniowanie elektromagnetyczne, na podstawie których obliczana jest odległość do celu. Jest to więc sposób, w którym wchodzi się w fizyczną interakcję z badaną sceną. Do tej grupy zalicza się między innymi skanery laserowe (LiDAR), czujniki czasu przelotu (ang. *Time-of-Flight*) oraz systemy światła strukturalnego (ang. *structured light*). Mimo że rozwiązania aktywne charakteryzują się wysoką precyzją otrzymanych pomiarów, nie są pozbawione wad. Sprzęt zdolny do wykonania tego typu

pomiarów jest z reguły kosztowny oraz znacznych rozmiarów. Dodatkowo sposób ich funkcjonowania wykazuje podatność na niekontrolowane aspekty; przykładowo, niesprzyjające warunki atmosferyczne mogą ograniczyć zasięg skutecznego działania. Z kolei metody pasywne opierają się wyłącznie na rejestracji i analizie promieniowania naturalnie odbitego, wykorzystując do tego celu klasyczne matryce światłoczułe, takie jak w cyfrowych aparatach fotograficznych. Ze względu na szeroką dostępność urządzeń rejestrujących obraz oraz stale rosnącą moc obliczeniową komputerów to właśnie rozwiązania pasywne stały się dominującym kierunkiem rozwoju w rekonstrukcji 3D. Ponieważ niniejsza praca skupia się na analizie rekonstrukcji wykorzystującej obrazy uzyskane sprzętem klasy konsumenckiej, w dalszej części szczegółowo omówione zostaną wyłącznie metody pasywne.

Kluczową rolę w doborze metod rekonstrukcyjnych odgrywa również liczba dostępnych widoków. W tej pracy skupiono się na pojedynczym lub kilku obrazach, co niesie za sobą poważne konsekwencje w wyborze metody. Przypadek wariantu jednoobrazowego określa się mianem problemu „niejednoznacznego”. Termin ten wynika z faktu, iż podczas rejestracji obrazu część informacji przestrzennej zostaje utracona, przede wszystkim głębokość, bowiem ten sam obraz może odpowiadać wielu różnym konfiguracjom geometrycznym. Dlatego określenie struktury sceny wymaga wykorzystania dodatkowych założeń, zależności pomiędzy obrazami albo wiedzy pozyskanej wcześniej na podstawie danych treningowych. Dostęp do większej liczby obrazów umożliwia wykorzystanie zależności geometrycznych pomiędzy poszczególnymi widokami tej samej sceny. Obserwacja tych samych punktów z różnych położeń kamery pozwala między innymi na estymację parametrów kamer oraz określenie położenia punktów w przestrzeni. Dodatkowe widoki ograniczają zatem niejednoznaczność charakterystyczną dla rekonstrukcji jednoobrazowej.

Złożoność problemu rekonstrukcji 3D znajduje odzwierciedlenie w różnorodności opracowanych metod oraz paradygmatów postępowania. Rozdział ten uporządkowano według dominujących podejść, a jego treść koncentruje się na najważniejszych i najczęściej stosowanych grupach metod. Należy przy tym podkreślić, że zaproponowana klasyfikacja ma charakter porządkujący, a granice pomiędzy poszczególnymi podejściami nie zawsze są jednoznaczne. Metody optymalizacyjne takie jak neuronowe pola radiancji czy rozsmarowywanie gaussów do działania wykorzystują parametry kamer wyznaczone wcześniej za pomocą algorytmów Structure from Motion. Jednocześnie techniki głębokiego uczenia są na szeroką skalę stosowane do wspomagania poszczególnych etapów SfM lub MVS. W rezultacie wiele współczesnych systemów rekonstrukcji 3D przenika klasyczne standardy, łącząc zalety podejść geometrycznych i metod uczących się.

2.1.1 Odzyskiwanie geometrii z pojedynczego obrazu

Pomimo problemu niejednoznaczności pojedynczy obraz zawiera wiele pośrednich wskazówek, które pozwalają na oszacowanie kształtu struktury. Należą do nich perspektywa liniowa, wzajemne przesłanianie obiektów, ich względne rozmiary, położenie względem linii horyzontu, gradient tekstury, rozmycie oraz rozkład światła i cienia. Przykładowo zbieganie się równoległych linii może wskazywać kierunek głębokości, natomiast przesłonięcie jednego obiektu przez drugi pozwala

określić ich kolejność względem obserwatora. Zmniejszanie się rozmiarów powtarzalnych elementów oraz wzrost gęstości tekstury mogą z kolei świadczyć o zwiększającej się odległości powierzchni od kamery. Wskazówki te nie określają geometrii w sposób bezwzględny, lecz ograniczają zbiór możliwych interpretacji obrazu, co jest kluczowe w przypadku tego problemu. Jednym z klasycznych podejść wykorzystujących pojedynczą obserwację jest **shape-from-shading** (SFS), po raz pierwszy zaprezentowany przez Berthold K. P. Horna [12], którego celem jest odzyskanie kształtu powierzchni na podstawie zmian w mocy nasycenia światła. Metoda ta zakłada istnienie związku pomiędzy jasnością piksela, orientacją powierzchni, właściwościami materiału oraz kierunkiem padania światła. Przy założeniu znanego modelu odbicia i położenia źródła światła możliwe jest oszacowanie lokalnych normalnych powierzchni, a następnie odtworzenie jej przybliżonego kształtu. W praktyce rozwiązanie pozostaje jednak silnie zależne od spełnienia założeń dotyczących oświetlenia i materiału. Cienie, refleksy czy nieznane źródła światła mogą prowadzić do przypisania zmian wyglądu do nieistniejących zmian geometrii.

Rozwój uczenia maszynowego doprowadził do zmiany sposobu rozwiązywania problemu. Zamiast odtwarzać geometrię wyłącznie na podstawie jawnie zdefiniowanych zależności fizycznych, modele uczone na dużych zbiorach danych mogą pozyskiwać statystyczną wiedzę o typowym wyglądzie scen i obiektów. Pozwala im to przewidywać najbardziej prawdopodobną strukturę przestrzenną również wtedy, gdy dostępne wskazówki geometryczne nie wystarczają do wyznaczenia jednoznacznego rozwiązania. Model może przykładowo nauczyć się typowych relacji pomiędzy podłogą, ścianami i sufitem, przybliżonych proporcji przedmiotów lub charakterystycznych kształtów określonych kategorii obiektów. Podstawowym zadaniem w tej grupie jest jednoobrazowa estymacja głębi (ang. *monocular depth estimation*). Jej rezultatem jest mapa głębokości przypisująca każdemu pikselowi wartość określającą odległość odpowiadającego mu punktu sceny od kamery. W zależności od zastosowanej metody przewidywana może być głębokość względna albo metryczna. W pierwszym przypadku zachowana zostaje przede wszystkim kolejność przestrzenna i proporcja odległości, lecz wynik jest określony z dokładnością do nieznanego współczynnika skali i niekiedy przesunięcia. Estymacja metryczna dąży natomiast do podania odległości w jednostkach fizycznych, zwykle w metrach. Metoda ta nie jest pozbawiona klasycznych problemów rekonstrukcji z pojedynczego źródła obserwacji, związanych z miejscem położenia kamery czy przesłonięciami i z tego względu wynik oparty na mapie głębokości ma zwykle postać modelu typu 2,5D, ale może zostać przekształcony w chmurę punktów, częściowo przedstawiającą scenę.

Pomimo rozwoju metod umożliwiających odzyskanie geometrii z zaledwie jednego obrazu większość najpopularniejszych podejść do rekonstrukcji 3D wykorzystuje wiele obserwacji tej samej sceny. Ich zastosowanie umożliwia rozwiązanie części problemów przedstawionych w tej sekcji, dlatego dalsza część rozdziału poświęcona została metodom i reprezentacjom stosowanym w rekonstrukcji wielowidokowej.

2.1.2 Wolumetryczne reprezentacje sceny

Powszechnym podejściem do modelowania trójwymiarowego, wywodzącym się z reprezentacji 3D poprzez siatki wielokątów, jest metodologia, w której opisuje się jedynie powierzchnię obiektu (ang. *boundary representation*). W myśl tej koncepcji przechowuje się jedynie informacje opisujące kształt struktury, takie jak jego ściany zewnętrzne, krawędzie i wierzchołki. Pozwala to zmniejszyć zapotrzebowanie na konieczną pamięć. Reprezentacje objętościowe (wolumetryczne) stanowią odwrotność tego podejścia. Podstawowym założeniem tego typu reprezentacji jest cyfrowy zapis informacji nie tylko o zewnętrznym kształcie danej bryły, lecz także o jej **cechach wewnętrznych**. Taki wzorzec znajduje zastosowania w dziedzinach technologii, w których reprezentacje powierzchniowe okazują się niewystarczające.

Przykładowo w medycynie, dzięki swoim wyjątkowym właściwościom, algorytmy wykorzystujące siatki wokseli (ang. *volumetric pixels*) służą do precyzyjnego odwzorowywania tkanek i wewnętrznej budowy narządów [28]. Woksele, jako jedna z fundamentalnych form rekonstrukcji 3D, należą do grupy jawnych reprezentacji, w której objętość dzielona jest na regularną siatkę sześciennych jednostek. Każda komórka takiej siatki, będąca trójwymiarowym odpowiednikiem piksela, przechowuje informacje o obecności materii w danym fragmencie przestrzeni, a opcjonalnie także o parametrach dodatkowych, takich jak kolor, gęstość czy przezroczystość. W praktyce klasyczne podejście wokselse opiera się na przypisaniu komórkom wartości binarnej (0 dla pustej przestrzeni, 1 dla zajętej). Proces ten, nazywany wokselizacją, może być wykonywany na podstawie różnego typu danych wejściowych. W przypadku zdjęć 2D algorytmy rzutują dane z obrazu w przestrzeń trójwymiarową, a następnie z wykorzystaniem różnorodnych technik, m.in. rzeźbienia w przestrzeni (ang. *space carving*) nadają odpowiedni kształt modelowi poprzez usuwanie niespójnych elementów. Główną wadą mechanizmu wokseli jest jednak jego niska skalowalność. Zużycie pamięci oraz złożoność obliczeniowa rosną w postępie sześciennym w stosunku do rozdzielczości siatki. Powoduje to, że reprezentowanie dużych lub szczegółowych scen szybko prowadzi do wyczerpania zasobów sprzętowych.

W celu zoptymalizowania zużycia pamięci i uniknięcia powszechnego problemu przypisywania zasobów na pustą przestrzeń (która nierzadko stanowi znaczną część analizowanej sceny), stosuje się hierarchiczne struktury danych, takie jak drzewa ósemkowe (ang. *octrees*). W podejściu tym objętość bazowa, stanowiąca korzeń drzewa, jest rekurencyjnie dzielona na osiem mniejszych sześciątów, przy czym kolejne węzły drzewa (gałęzie) mogą być potencjalnie nieobecne, co pozwala na całkowite pominięcie ich w procesie alokacji i późniejszych obliczeniach. Chociaż drzewa ósemkowe drastycznie redukują zapotrzebowanie na pamięć, zwiększają złożoność kodu i mogą sprawiać problemy natury technicznej w porównaniu do klasycznych tablic wokseli.

Rozwinięciem reprezentacji objętościowej, ukierunkowanym na precyzję rekonstrukcji powierzchni, jest zastosowanie pól TSDF (ang. *Truncated Signed Distance Fields*) [2]. W modelu tym w komórkach siatki wokselsej nie zapisuje się binarnej wartości określającej, czy komórka jest zajęta, lecz odległość danego punktu przestrzeni od najbliższej powierzchni obiektu. Wartość dodatnia oznacza, że woksół

znajduje się w pustej przestrzeni, natomiast ujemna – że leży we wnętrzu bryły. Określenie *Truncated* w tym przypadku oznacza, że dla oszczędności obliczeniowej dystans jest wyliczany jedynie w wąskim zakresie dookoła samej powierzchni. Choć pola TSDF wywodzą się z systemów wykorzystujących czujniki głębi, nadal znajdują zastosowanie w pasywnych metodach rekonstrukcji. Między innymi w klasycznej fotogrametrii służą do fuzji i wygładzania zaszumionych map głębi estymowanych na podstawie zdjęć 2D.

2.1.3 Rzadka rekonstrukcja sceny

Structure from Motion przez lata umocniło się na pozycji jednego z najważniejszych podejść w zakresie pasywnej rekonstrukcji 3D. Jak nazwa sugeruje, metoda ta polega na rekonstrukcji struktury poprzez analizę pozornego ruchu, a dokładniej — na analizie zestawu dwuwymiarowych obrazów przedstawiających badaną strukturę z różnych perspektyw.

Podstawową cechą działania algorytmów z tej rodziny jest umiejętność estymacji parametrów wewnętrznych i zewnętrznych kamer dla zadanych zdjęć. Potrafią one precyzyjnie określić pozycję, rotację oraz właściwości optyczne urządzenia rejestrującego, które wykonało daną fotografię. Na podstawie tych danych algorytm generuje produkt końcowy, czyli rzadką chmurę punktów (ang. *sparse point cloud*) reprezentującą geometrię badanego obiektu. Zanim jednak algorytm przystąpi do tworzenia chmury punktów, musi określić, które fragmenty na różnych zdjęciach przedstawiają ten sam fizyczny punkt w rzeczywistości. Z tego powodu pierwszym krokiem SfM jest ekstrakcja i dopasowanie lokalnych cech obrazu. Przez lata do dyspozycji badaczy pojawiło się wiele technik wykrywania punktów charakterystycznych. Są to m.in. SURF (ang. *Speeded-Up Robust Features*) oraz ORB (ang. *Oriented FAST and rotated BRIEF*), jednak podstawą pozostaje algorytm SIFT (ang. *Scale-Invariant Feature Transform*) [17].

Publikacja Davida Lowe'a z roku 1999 przedstawia kilkietapowy algorytm pozwalający na wykrycie i opis lokalnych cech w zadanym obrazie. Pierwszym etapem działania algorytmu jest wyznaczenie potencjalnych punktów charakterystycznych. Do tego zadania wykorzystuje się filtrację kaskadową, czyli utworzenie piramidy obrazów, w której kolejne poziomy piramidy powstają poprzez odejmowanie od siebie sąsiadujących obrazów, poddanych uprzednio filtracji Gaussa o stopniowo zwiększanym stopniu rozmycia. Jako potencjalne punkty charakterystyczne uznaje się te piksele, które są największe lub najmniejsze w swoim otoczeniu, gdzie otoczeniem określa się osiem najbliższych sąsiadów tego samego obrazu oraz po dziewięć dodatkowych pikseli z wyższego oraz niższego poziomu piramidy. Następnie weryfikuje się stabilność punktów oraz dopasowanie ich pod kątem skali i położenia w celu przefiltrowania źle dobranych punktów. Kolejnym etapem działania SIFT jest określenie orientacji zdefiniowanych w poprzednich krokach punktów, tak by uniezależnić je od obrotu obrazu. Ostatecznie dla każdego punktu wyznaczany jest unikalny deskryptor na podstawie wartości i orientacji lokalnych gradientów w jego bezpośrednim otoczeniu.

Gdy SfM zidentyfikuje odpowiadające sobie punkty na co najmniej dwóch zdjęciach oraz zna relatywną pozycję kamer, przystępuje do wstępnej estymacji punktów w przestrzeni. Proces

ten określa się mianem triangulacji (ang. *triangulation*). Polega ona na rzutowaniu promieni z centrów optycznych kamer przez odpowiadające sobie piksele na zdjęciach. Punkt w trójwymiarowej przestrzeni, w którym te promienie przecinają się, staje się współrzędną punktu w chmurze. Ze względu na obecność szumu w praktyce rzadko udaje się wyznaczyć punkty z taką dokładnością, by promienie przecinały się idealnie; stosuje się więc aproksymację metodą najmniejszych kwadratów do wyznaczenia optymalnego punktu względem rzutowanych promieni. Ostatnim etapem jest minimalizacja błędów z wykorzystaniem optymalizacji nieliniowej, nazywanej wyrównaniem (ang. *Bundle Adjustment*). Produktem końcowym SfM jest rzadka chmura punktów. Zawiera ona tylko te punkty, które algorytmy takie jak SIFT uznały za na tyle unikalne, by mogły je jednoznacznie dopasować. Choć chmura ta pozwala rozpoznać kształt obiektu, nie jest jeszcze pełną rekonstrukcją.

Współcześnie SfM to zasadniczo cała rodzina algorytmów, różniących się pod kątem architektury w celu osiągnięcia lepszych efektów. Twórcy stosują różne strategie budowy końcowego modelu, by odpowiedzieć na problemy wynikające ze zróżnicowanych parametrów odtwarzanej sceny. Wyróżnia się cztery główne grupy:

1. **Przyrostowe** (ang. *Incremental SfM*): podejście uważane za najdokładniejsze, w którym zdjęcia są dodawane sekwencyjnie. Ze względu na wysoką złożoność obliczeniową oraz kumulację błędów nie sprawdza się dobrze w przypadku większych zbiorów danych.
2. **Globalne** (ang. *Global SfM*): w tym rozwiązaniu pozycje kamer estymuje się na podstawie utworzonego uprzednio grafu, co pozwala na uniknięcie błędów typowych dla metod sekwencyjnych.
3. **Hierarchiczne** (ang. *Hierarchical SfM*): założeniem jest podział zbioru obrazów na mniejsze klastry, by zrekonstruować je osobno, a następnie połączyć w jedną całość. Celem tego podejścia jest rozwiązanie problemu skalowania.
4. **Hybrydowe** (ang. *Hybrid SfM*): łączy precyzję metod sekwencyjnych ze spójnością metod globalnych. Stanowi nowoczesny kompromis między wydajnością a stabilnością.

Przykładem praktycznego zastosowania podejścia przyrostowego jest publikacja „Photo Tourism: Exploring Photo Collections in 3D” z 2006 roku [29]. Autorzy przedstawili system umożliwiającą rekonstrukcję struktury trójwymiarowej na podstawie dużych, nieuporządkowanych kolekcji nieskalibrowanych fotografii. Proces rozpoczynał się od wykrywania i dopasowywania cech pomiędzy fotografiami, na podstawie których określano wzajemne zależności geometryczne obrazów. Właściwa rekonstrukcja była następnie budowana przyrostowo: po wybraniu początkowej pary zdjęć do modelu sukcesywnie dodawano kolejne kamery, triangulowano nowe punkty sceny oraz okresowo przeprowadzano optymalizację nieliniową, wspólnie korygującą parametry kamer i położenie punktów trójwymiarowych. W rezultacie uzyskiwano rzadką rekonstrukcję geometrii oraz położenia kamer, które umożliwiały przestrzenną organizację całej kolekcji fotografii. Szczególne znaczenie pracy wynikało z charakteru wykorzystanych danych wejściowych. Zamiast kontrolowanych sekwencji zdjęć stosowano fotografie wykonywane niezależnie przez różnych użytkowników, przy użyciu różnych aparatów, ustawień oraz z odmiennych punktów widzenia. W eksperymentach wykorzystano między

innymi internetowe kolekcje przedstawiające popularne obiekty turystyczne, takie jak katedra Notre Dame czy Fontanna di Trevi. Przykład ukazano na rys. 2. Praca pokazała tym samym praktyczną możliwość zastosowania SfM do niekontrolowanych zbiorów zdjęć pochodzących z internetu, jednocześnie uwidaczniając problemy ze skalowalnością przyrostowego procesu rekonstrukcji.



Rysunek 2. Trójwymiarowa rekonstrukcja w formie rzadkiej chmury punktów. Źródło: [29]

2.1.4 Gęsta rekonstrukcja sceny

Podczas gdy SfM dostarcza jedynie rzadką reprezentację sceny, głównym celem algorytmów Multi-View Stereo (MVS) jest wygenerowanie gęstej rekonstrukcji. Wykorzystując dane uzyskane w ramach działania SfM, przede wszystkim precyzyjnie wyznaczone parametry kamer oraz ewentualnie rzadką chmurę, algorytmy MVS stosują różnorodne podejścia w celu wykonania wysokiej jakości rekonstrukcji. Zależnie od przyjętej architektury metody MVS dzieli się na oparte na chmurze punktów, mapie głębi oraz strukturach wolumetrycznych. Podejścia korzystające z chmury punktów operują bezpośrednio na chmurze wytworzonej przez SfM, w procesie optymalizacyjnym stopniowo zagęszczając reprezentacje. Ponieważ algorytm w takim schemacie działania funkcjonuje sekwencyjnie, metody te charakteryzują się długim czasem działania. Rozwiązania wolumetryczne dyskretyzują przestrzeń trójwymiarową na siatkę wokseli, przypisując każdemu unikalny indeks, a następnie oceniając, czy znajduje się we wnętrzu docelowej struktury. Główną wadą tych metod jest wysokie zużycie pamięci. Warianty MVS wykorzystujące mapę głębi stanowią obecnie najpopularniejszą grupę ze względu na swoją elastyczność i skalowalność. Estymują one wartość głębi niezależnie dla każdego zdjęcia referencyjnego, a następnie dokonują fuzji tych map w jedną globalnie spójną chmurę punktów lub, w ramach przetwarzania końcowego, w siatkę trójkątów.

Rozwój klasycznych algorytmów MVS doprowadził do powstania wielu skutecznych narzędzi osiągających imponujące rezultaty w dziedzinie gęstej rekonstrukcji 3D. Pomimo tych sukcesów standardowe podejścia analityczne miały znaczące ograniczenia. Trudności w rekonstrukcji

powierzchni o jednolitej teksturze oraz elementów o wysokiej refleksyjności (takich jak woda, metal czy lustro) stanowiły jeden z głównych problemów. Próbą odpowiedzi na te wyzwania stało się wprowadzenie metod opartych na uczeniu maszynowym. Architektury takie jak MVSNet [38], odchodząc od klasycznego dopasowywania pojedynczych pikseli, wykorzystują dwuwymiarowe konwolucyjne sieci neuronowe (2D CNN) do ekstrakcji gęstych map cech obrazu z danej sceny. Dzięki analizie szerszego kontekstu i wykorzystaniu wyuczonych wzorców (ang. *learned priors*) sieci te potrafią estymować geometrię w scenach zawierających obszary o jednolitej teksturze lub zwierciadlane powierzchnie. Następnie na podstawie wyuczonych cech obrazu poprzez różniczkowalne przekształcenie homograficzne (ang. *differentiable homography*) tworzą trójwymiarową przestrzeń kosztów (ang. *cost volume*). Przestrzenią kosztów w tym przypadku nazywa się wielowymiarową macierz opisującą dopasowanie wyekstrahowanych cech wizualnych na dyskretnych płaszczyznach głębi. Po utworzeniu przestrzeni ta poddawana jest regularyzacji za pomocą sieci 3D CNN, co pozwala estymować dokładne mapy głębi i skuteczniej przetwarzać obszary o jednolitej teksturze niż w przypadku metod klasycznych.


Należy jednak zaznaczyć, że metody MVS nadal fundamentalnie opierają się na założeniu spójności fotometrycznej między różnymi ujęciami. Wdrożenie głębokiego uczenia poprawiło efektywność rekonstrukcji niektórych scen, ale służy ono jako krok wspomagający w całym procesie.

2.1.5 Neuronowe pola radiancji

Przełomowym rozwiązaniem w dziedzinie rekonstrukcji scen trójwymiarowych na podstawie dwuwymiarowych obrazów stało się wprowadzenie technologii neuronowych pól radiancji (ang. *Neural Radiance Fields*, NeRF) [20]. Metoda ta wykorzystuje głęboką sieć neuronową w architekturze wielowarstwowego perceptronu (ang. *Multilayer Perceptron*, MLP) do syntezy nowych widoków (ang. *novel view synthesis*), czyli generowania ujęć, których nie było w materiale źródłowym, na podstawie zbioru obrazów ze znanymi pozycjami kamer. NeRF jest w stanie osiągać bliższe fotorealizmi efekty w porównaniu do klasycznych metod rekonstrukcji, wykorzystując różniczkowalną funkcję ciągłą do reprezentacji sceny, klasyfikując się jako niejawna forma reprezentacji. Wynikiem działania modeli NeRF nie jest geometria 3D w postaci siatek trójkątów lub chmury punktów; zamiast tego model zwraca wartość koloru i gęstości dla dowolnego punktu w przestrzeni, które skumulowane tworzą dwuwymiarowy render sceny.

Algorytmy typu NeRF do działania wymagają znanych pozycji i orientacji kamer dla zadanych zdjęć wejściowych; autorzy oryginalnej pracy wykorzystują w tym celu oprogramowanie COLMAP [25]. W każdej iteracji procesu treningowego losowo generowana i wystrzeliana jest partia promieni ze zbioru wszystkich pikseli w zbiorze danych. Wzdłuż każdego z tych promieni następuje proces próbkowania punktów (ang. *ray marching*). Współrzędne tych punktów oraz kierunek promienia stanowią dane wejściowe dla sieci MLP, która zwraca estymowaną gęstość objętościową oraz kolor danej próbki. Kolejnym krokiem jest, przy pomocy klasycznych metod renderowania wolumetrycznego, skumulowanie parametrów wszystkich punktów w jednolity obraz 2D. Ostatecznie

sieć dokonuje optymalizacji wag poprzez porównanie zdjęcia źródłowego (ang. *ground-truth*) z obrazem wynikowym. Wizualizacje tego procesu można zobaczyć na rys. 3.



Rysunek 3. Procedura rekonstrukcji 3D w wykonaniu NeRF. Źródło: [20]

Jedną z głównych przewag modeli typu NeRF jest zdolność do rekonstrukcji powierzchni o wysokim stopniu refleksyjności. Tradycyjne metody takie jak SfM i MVS zakładają, że rekonstruowane powierzchnie charakteryzują się „odbiciem lambertowskim”, czyli cechą powierzchni, w której światło jest odbijane w jednaki sposób niezależnie od kąta patrzenia. Ponieważ w rzeczywistych scenach światło niejednokrotnie naruszane jest przez odbłaski, połysk czy przezroczystości, taka sytuacja nie zachodzi często. NeRF, dzięki wykorzystaniu kierunku promienia jako parametru wejściowego sieci, jest w stanie modelować efekty zależne od punktu widzenia, prowadząc do wiernego odtworzenia złożonych zjawisk optycznych.

Najczęściej wymienianą wadą neuronowych pól radiacji jest ich złożoność obliczeniowa, która swoje największe mankamenty objawia w kontekście renderowania w czasie rzeczywistym. Problem ten wynika bezpośrednio z natury algorytmu ray marching. Aby wyznaczyć kolor pojedynczego piksela, algorytm musi pobrać od kilkudziesięciu do kilkuset próbek wzdłuż promienia, a następnie każdą z nich przetworzyć za pomocą sieci MLP. W przypadku renderowania obrazu w wysokiej rozdzielczości oznacza to wykonywanie setek milionów zapytań. W efekcie na standardowym sprzęcie konsumenckim czas generowania pojedynczego widoku liczony jest w sekundach. Warto jednak zaznaczyć, że badacze już pracują nad rozwiązaniem tego problemu [36, 24].

2.1.6 Rozsmarowywanie Gaussów

Bezpośrednią odpowiedzią na podstawowe ograniczenia modeli NeRF, w szczególności wysokie koszty obliczeniowe i wynikającą z nich niesatysfakcjonującą wydajność renderowania w czasie rzeczywistym, stała się technika 3D Gaussian Splatting (3DGS) [14]. Metoda ta wraca do paradygmatu jawnej reprezentacji geometrii, w której scena jest przedstawiana poprzez zbiór prymitywów w postaci trójwymiarowych funkcji Gaussa. Każdy prymityw w tej metodzie jest zdefiniowany przez zestaw parametrów podlegających optymalizacji: pozycję (średnią), macierz

kowariancji określającą kształt i orientację elipsoidy, stopień przezroczystości oraz współczynniki harmonik sferycznych odpowiedzialnych za modelowanie wyglądu zależnego od punktu widzenia.

Proces rekonstrukcji standardowo rozpoczyna się od rzadkiej chmury punktów uzyskanej metodą SfM, na podstawie której inicjuje się zestaw Gaussów. Tak wytworzony zbiór prymitywów następnie poddaje się iteracyjnej optymalizacji wobec dostępnych widoków referencyjnych. Kluczowym czynnikiem, dzięki któremu 3DGS osiąga bezprecedensowe wyniki w kwestii wydajności, jest zastosowanie dedykowanych metod optymalizacyjnych. Pierwszą z nich jest kafelkowa rasteryzacja (ang. *tile-based rasterization*), czyli autorski algorytm, w którym docelowy obraz dzielony jest na mniejsze bloki (kafelki), do których przypisywane są rzutowane z przestrzeni gaussy. Drugie rozwiązanie stanowi akceleracja GPU, gdzie sortowanie gaussów względem głębokości w obrębie poszczególnych kafelków odbywa się poprzez algorytm Radix Sort, będący jednym z najszybszych dostępnych rozwiązań. Ostatnim krokiem jest proces mieszania pasma alfa (ang. *alpha-blending*) w celu dopasowania przezroczystości gaussów. Połączenie powyżej wymienionych metod w jedną architekturę umożliwia nie tylko wydajne renderowanie wygenerowanej sceny w czasie rzeczywistym, ale również wysoce efektywną propagację wsteczną w fazie treningu. Unikatowym dla rozsmarowywania gaussów aspektem procesu rekonstrukcyjnego jest krok adaptacyjnej kontroli gęstości (ang. *adaptive density control*). Ponieważ początkowy układ prymitywów generowany jest na podstawie chmury punktów uzyskanej w ramach SfM, nie oddaje on całokształtu sceny. Niezbędnym zatem okazało się iteracyjne modyfikowanie zbioru gaussów. Modyfikacja topologii realizowana jest poprzez trzy główne operacje:


1. **Klonowanie** — stosowane w obszarach, gdzie obecne gaussy są niewystarczających rozmiarów. Algorytm duplikuje taki prymityw i nieznacznie przesuw go w kierunku wskazywanym przez gradient.
2. **Podział** — aktywowany w sytuacjach, gdy prymityw ma zbyt duże rozmiary. Wówczas jest usuwany i zastępowany dwoma nowymi o proporcjonalnie zmniejszonej skali.
3. **Usunięcie** — algorytm regularnie usuwa prymitywy, których współczynnik przezroczystości spadnie poniżej ustalonego progu.

2.1.7 Duże modele jednokierunkowe

Omawiane do tej pory metodologie optymalizujące opierały się na założeniu odtworzenia pojedynczej sceny. Zasadniczy proces polegał w nich na wytrenowaniu małej sieci neuronowej (np. MLP), tak by wyspecjalizowała się w odtworzeniu wyłącznie tej konkretnej przestrzeni, przedstawionej w źródłowym zbiorze danych. W przypadku chęci zrekonstruowania nowej sceny oznacza to wymóg ponownego wytrenowania sieci od zera na nowym zbiorze danych, co jest procesem wysoce czasochłonnym i kosztownym obliczeniowo. Rozwiązaniem tego problemu stało się uprzednie wytrenowanie modeli na dużych, zróżnicowanych zbiorach danych. W ten sposób model nabywa zdolność generalizacji – potrafi zrekonstruować 3D z zupełnie nowych scen, których nie było w oryginalnym zbiorze treningowym (ang. *zero-shot inference*). Takie rozwiązania posiadają różne warianty wdrożenia.

Popularną architekturą do tego typu zadań stały się konwolucyjne (splotowe) sieci neuronowe (CNN) [8]. CNN to architektura wyspecjalizowana w przetwarzaniu danych o topologii siatki, takich jak zdjęcia 2D, w celu rozpoznawania wzorców ukrytych w danym obrazie. Działanie podstawowej warstwy tej sieci opiera się na operacji matematycznej funkcji splotu, która wykorzystuje dwa główne elementy: dwuwymiarową macierz zawierającą wartości pikseli obrazu oraz filtr, nazywany jądrem splotu (ang. *kernel*). Wynikiem przejścia filtru przez obraz docelowy jest tzw. mapa cech (ang. *feature map*). Ponieważ pojedynczy neuron w warstwie splotowej reaguje jedynie na specyficzny wycinek obrazu, czyli tzw. lokalne pole widzenia (ang. *receptive field*), pozwala to na wydajne wykrywanie podstawowych struktur, takich jak krawędzie czy narożniki. Mimo że architektura splotowa nadal znajduje zastosowanie w różnych modelach stawiających sobie za wyzwanie rekonstrukcję z jednego lub kilku zdjęć [41], zazwyczaj napotyka trudności w tych scenariuszach. Lokalne filtry CNN wykazują istotne ograniczenia w estymacji głębi w przypadku jednolitych powierzchni oraz ze znajdowaniem relacji między odległymi od siebie pikselami.

Przełomowa dla rozwiązania tego problemu okazała się architektura transformera, początkowo opracowana dla modeli językowych [34], a następnie zaadaptowana jako transformer wizyjny (ang. *vision transformer*, ViT) [7] na potrzeby wizji komputerowej. Przegląd modelu przedstawiono na rysunku 4.



Rysunek 4. Architektura modelu ViT. Źródło: [7]

Główną zaletą ViT jest wykorzystanie charakterystycznego dla tej architektury mechanizmu „samouwagi” (ang. *self-attention*). Jest to umiejętność modelu do oceny, które fragmenty danych wejściowych, po ich podzieleniu na mniejsze elementy nazywane tokenami, mają większe znaczenie w szerszym kontekście. W przypadku ViT tokenami są małe, kwadratowe wycinki obrazu wejściowego (ang. *patches*). Każdy z nich zostaje poddany operacji spłaszczania (ang. *flattening*), tj. przekształcenia dwuwymiarowego fragmentu w jednowymiarowy wektor, a następnie projekcji liniowej, czyli mapowaniu do wektora o ustalonym wymiarze D . Analogiczna operacja zachodzi wobec tokenów w modelach językowych. Kolejnym krokiem jest kodowanie pozycyjne (ang. *positional encoding*),

które polega na dodaniu do każdego fragmentu dodatkowego wektora przechowującego informacje o jego położeniu, dzięki czemu transformer wie, gdzie konkretny wycinek znajduje się w całej siatce. Na tym etapie załączany jest token klasyfikacyjny (ang. *classification token* – CLS Token). Jego zadaniem jest agregacja globalnych informacji ze wszystkich fragmentów w trakcie przetwarzania przez kolejne warstwy modelu. W tym momencie rozpoczyna się kluczowy etap działania modelu. Dane przekazywane są do enkodera, który stanowi właściwy moment przetwarzania informacji wizualnych. Enkoder nie jest jedną warstwą, lecz sekwencją L identycznych bloków, przez które przepływają tokeny. Pojedyncza warstwa w ViT składa się z następujących komponentów:

1. **Normalizacja (LN)** — stosowana, aby ustabilizować dystrybucję danych i przyspieszyć proces uczenia.
2. **Samouwaga wieloczęłonowa (MSA)** — umożliwia każdemu fragmentowi odczyt i modyfikację wszystkich innych wycinków obrazu w celu modelowania globalnych zależności, charakteryzując relacje nawet pomiędzy odległymi obszarami obrazu.
3. **Wielowarstwowy perceptron (MLP)** — powszechnie jest to dwuwarstwowa sieć neuronowa z nieliniową funkcją aktywacji, przykładowo GELU [9].
4. **Połączenia resztkowe** — służą zapobiegnięciu problemowi znikającego gradientu, zapewniając, że gradient pozostanie wystarczająco duży, aby umożliwić efektywną naukę.

Warto zaznaczyć, że w architekturze ViT bloki enkodera są zorganizowane według wariantu Pre-norm. W układzie tym warstwa normalizacji poprzedza każdy z dwóch głównych etapów przetwarzania, samouagę oraz sieć MLP. Całość dopełniają połączenia resztkowe, które są stosowane po każdym z tych etapów.

W celu skutecznego funkcjonowania modele typu ViT wymagają znacznie więcej danych niż sieci CNN. Wynika to przede wszystkim z braku *inductive bias*, czyli wstępnych założeń, które są naturalnie obecne w konwolucyjnych sieciach ze względu na ich strukturę operującą na lokalnych fragmentach obrazu. W przeciwieństwie do CNN, których architektura zawiera wbudowane założenia dotyczące lokalnej struktury obrazu, ViT muszą nauczyć się relacji przestrzennych od podstaw. Z tego powodu, aby mogły osiągać konkurencyjne wyniki, muszą być uprzednio wytrenowane na dużych zbiorach danych, takich jak m.in. ImageNet [6] lub JFT-300M [30]. Pomimo wysokich wymagań dotyczących skali danych treningowych architektura ViT stanowi obecnie jedną z przodujących metod rozwiązywania problemów z dziedziny widzenia komputerowego. Między innymi estymacja głębi lub segmentacja obrazu należą do zagadnień intensywnie rozwijanych w ramach tej technologii. Rozwój ten doprowadził do powstania szeregu rozwiązań, które wykorzystują mechanizmy uwagi do modelowania nie tylko cech wizualnych obrazu, ale również relacji przestrzennych pomiędzy elementami sceny. W konsekwencji możliwe stało się zastosowanie ViT w zadaniach związanych z rekonstrukcją trójwymiarową. Przykładem takich podejść są modele takie jak MapAnything, VGGT oraz MAST3R, szczegółowo omówione w sekcji 3.2.

Rozdział 3

Przegląd istniejących rozwiązań

Literatura naukowa oferuje bardzo szeroki zbiór rozwiązań poświęconych problemowi rekonstrukcji trójwymiarowej [25, 26, 20, 2, 14]. W praktyce jednak zastosowanie wielu metod dostępnych publicznie okazuje się utrudnione w przypadku rekonstrukcji realizowanej na podstawie niewielkiej liczby zdjęć, a w odniesieniu do pojedynczego obrazu bywa często niemożliwe. Tego rodzaju założenia w istotny sposób zawężają zbiór metod, które mogą zostać wykorzystane do realizacji postawionego zadania. Nie stanowi to jednak jedynej trudności pojawiającej się podczas prób zastosowania nowoczesnych metod rekonstrukcji 3D. Powszechnie obserwowanym zjawiskiem jest bowiem wysoka skuteczność danego algorytmu dla konkretnego, dedykowanego zestawu danych wejściowych, przy jednoczesnym spadku jego użyteczności w bardziej zróżnicowanych lub mniej kontrolowanych scenariuszach. Twórcy niejednokrotnie raportują bardzo dobre wyniki swoich algorytmów, osiągnęte przez metody zoptymalizowane pod kątem określonego zbioru danych. Należy jednak zauważyć, że autorzy rzetelnie w swoich artykułach wymieniają to ograniczenie oraz wskazują je jako potencjalne pole przyszłych badań. Faktem jest, że ograniczenie to nie podważa sensowności powstania danej metody oraz badań z nią związanych, lecz z reguły jest mniej eksponowanym elementem niż główne tezy publikacji. Drugim, równie istotnym problemem są wymogi techniczne. Standardową praktyką podczas pracy badawczej w dziedzinie informatyki jest bazowanie na narzędziach opracowanych przez innych autorów. Pozwala to znacząco przyspieszyć cały proces. Jednocześnie w dobie niezwykle dynamicznego rozwoju narzędzi informatycznych te zależności mogą długofalowo stawać się długim technologicznym projektem. W praktyce oznacza to, że w wielu przypadkach dany algorytm jest w stanie skutecznie funkcjonować wyłącznie w wysoce specyficznym środowisku oprogramowania. Niniejszy rozdział opisuje proces selekcji oprogramowania badawczego, dzieląc go na analizę metod przetestowanych, jednak ostatecznie odrzuconych oraz szczegółową charakterystykę modeli wytypowanych do przeprowadzenia testów.

3.1 Omówienie przetestowanych metod

Dobór algorytmów poddanych ewaluacji w niniejszej pracy był podyktowany potrzebą sprostania rygorystycznym założeniom badawczym wymienionym w celach pracy. Kluczowym kryterium było uwzględnienie metod zdolnych do rekonstrukcji 3D na podstawie pojedynczego obrazu lub niewielkiej liczby zdjęć, przy jednoczesnym braku konieczności wykorzystywania specjalistycznych danych wejściowych, takich jak na przykład mapy głębi. Istotne znaczenie miała również możliwość zastosowania wybranych modeli w zróżnicowanych scenariuszach testowych – od pojedynczych ujęć po rzadkie zbiory zdjęć. Celem zestawienia była ponadto analiza rozwiązań, które wykazują zdolność pracy na danych określanych jako *in-the-wild*, czyli fotografiach pozbawionych precyzyjnych metadanych oraz na bazie własnych danych testowych. W związku z powyższym zestawienie obejmuje zarówno ugruntowane metody fotogrametryczne, służące jako punkt odniesienia, jak i najnowocześniejsze modele klasy *state-of-the-art* (SOTA), które ostatecznie nie zostały wzięte pod uwagę w czasie ewaluacji.

COLMAP

COLMAP [25, 26] to otwarte oprogramowanie ogólnego przeznaczenia, będące obecnie jednym z najczęściej wykorzystywanych narzędzi rekonstrukcji 3D. Został zaprezentowany w 2016 roku przez badaczy z Politechniki Federalnej w Zurychu i Uniwersytetu Północnej Karoliny jako środowisko do realizacji metod SfM oraz MVS w ramach jednego systemu. Powstanie COLMAP stanowiło odpowiedź na potrzebę stworzenia uniwersalnego, wysoce zoptymalizowanego narzędzia do rekonstrukcji scen na podstawie nieustrukturyzowanych zbiorów zdjęć, przykładowo pobranych z internetu.

Obecnie dzięki swojej wyjątkowej dokładności i solidności COLMAP często traktowany jest jako punkt odniesienia zarówno w zakresie estymacji pozycji kamer, jak i rekonstrukcji rzadkiej i gęstej. Od strony algorytmicznej COLMAP bazuje na zasadach geometrii wielowidokowej. Typowy przebieg rekonstrukcji rozpoczyna się od wykrycia lokalnych cech obrazów, a następnie dopasowania ich między parami zdjęć. Dopiero na tej podstawie system przechodzi do właściwej rekonstrukcji rzadkiej. SfM w COLMAP-ie zakłada zestaw nakładających się obrazów tego samego obiektu lub sceny, wykonanych z różnych punktów widzenia, a wynikiem tego etapu jest rzadka chmura punktów wraz z parametrami wewnętrznymi i zewnętrznymi kamer. Uzyskana reprezentacja stanowi następnie podstawę dla modułu MVS, który oblicza mapy głębi dla zarejestrowanych obrazów i scala je w gęstą chmurę punktów. W dalszym kroku może wytworzyć siatkę powierzchni. Istotną zaletą COLMAP-u jest szeroki zakres funkcjonalności. Oprogramowanie oferuje tryb pełnej automatycznej rekonstrukcji, ale pozwala też uruchamiać każdy etap niezależnie, co jest bardzo ważne w zastosowaniach badawczych. Użytkownik ma do dyspozycji szereg narzędzi, w tym moduły ekstrakcji cech, rozmaite tryby dopasowywania obrazów, moduły rekonstrukcji w różnych wariantach SfM (przyrostowym, hierarchicznym i globalnym), narzędzia korekcji zniekształceń obrazów, generowanie siatek metodą Poissona lub Delaunaya. Projekt cechuje wysoka elastyczność,

co czyni go wiarygodnym narzędziem zarówno dla badaczy realizujących eksperymenty interaktywne, jak i dla osób budujących zautomatyzowane ciągi przetwarzania danych. Aplikacja oferuje przyjazny użytkownikowi interfejs graficzny (GUI), pozwalając śledzić proces rekonstrukcji niemal w czasie rzeczywistym oraz udostępniając w swoich ramach większość funkcjonalności programu. Równolegle interfejs wiersza poleceń (CLI) dostarcza pełen zestaw komend potrzebnych do budowania powtarzalnych eksperymentów. Oprogramowanie dostępne jest na systemach operacyjnych Windows, Linux oraz macOS, zapewniając powszechną dostępność. COLMAP przechowuje dane pośrednie w pojedynczej, relacyjnej bazie SQLite, co ułatwia organizację eksperymentów i integrację z własnymi skryptami. Baza przechowuje między innymi informacje o kamerach, obrazach, punktach kluczowych, deskryptorach, dopasowaniach oraz geometriach dwuwidokowych. Co więcej, oprogramowanie jest aktywnie rozwijane w kierunku programistycznej integracji z Pythonem poprzez PyCOLMAP, który udostępnia większość możliwości systemu w formie API oraz jest publikowany jako gotowe pakiety instalowane przez `pip`. Możliwości programu COLMAP można zobaczyć na rys. 5, na którym ukazano trójwymiarowy model Wiecznego Miasta, odtworzony na podstawie ponad 21 tysięcy zdjęć.



Rysunek 5. Model centrum Rzymu w formie rzadkiej chmury punktów wykonany za pomocą COLMAP. Źródło: [25].

Jednocześnie należy wyraźnie podkreślić, że COLMAP nie jest narzędziem przeznaczonym do rekonstrukcji 3D z pojedynczego obrazu. Wynika to bezpośrednio z jego założeń metodologicznych. Oficjalna dokumentacja zaleca listę zasad, wywodzących się bezpośrednio z założeń metod SfM i MVS, którymi należy kierować się w procesie tworzenia zdjęć wejściowych:

- należy unikać zdjęć całkowicie pozbawionych tekstury (np. białej ściany lub pustego biurka),
- zdjęcia powinny cechować się w miarę możliwości stałymi warunkami oświetleniowymi, ponieważ odbicia światła od błyszczących powierzchni utrudniają proces,
- zbiór zdjęć powinien zawierać różne perspektywy tej samej sceny,
- obrazy powinny się w znacznym stopniu pokrywać, a obiekt powinien być widoczny na **co najmniej trzech zdjęciach**.

Dopiero spełnienie takich warunków pozwala na wiarygodne funkcjonowanie oprogramowania. Z tego względu narzędzie to sprawdza się dobrze w rekonstrukcji z wielu zdjęć, lecz zasadniczo

nie odpowiada problemom postawionym w tej pracy. Pełni jedynie rolę punktu odniesienia, reprezentującego dojrzałe, klasyczne i szeroko zweryfikowane podejście do rekonstrukcji 3D.

Nerfstudio

Nerfstudio [32] to rozbudowana platforma programistyczna o otwartym kodzie źródłowym, stworzona w 2022 roku przez badaczy z Berkeley AI Research (BAIR), przeznaczona do tworzenia, trenowania i testowania metod opartych na polach radiancji. Autorzy podkreślają, że Nerfstudio ma na celu unifikację i uproszczenie pracy z tą technologią poprzez wprowadzenie modułowej architektury, pozwalającej na swobodne łączenie ze sobą różnych komponentów. Geneza tego oprogramowania jest bezpośrednio związana z sukcesem oryginalnego NeRF-a, który stanowił przede wszystkim propozycję badawczą, a nie wygodne narzędzie do codziennej pracy eksperymentalnej. Rosnąca popularność pól radiancji zrodziła potrzebę standaryzacji, kładąc podstawy pod opracowanie Nerfstudio. Twórcy podkreślają, że przyświecającą im ideą jest umożliwienie badaczom implementowania własnych metod w postaci modeli w ramach wspólnego ekosystemu. Między innymi dlatego architektura została zaprojektowana warstwowo. Główną koncepcją jest tu ciąg złożony przede wszystkim z dwóch komponentów: DataManagera oraz Modelu. DataManager odpowiada za ładowanie danych oraz generowanie pakietów danych dotyczących promieni, wykorzystywanych w kolejnych krokach funkcjonowania algorytmu. Model z kolei realizuje właściwe obliczenia i stanowi część implementacyjną dla badaczy chętnych do integracji z Nerfstudio. W obecnym momencie dostępnych jest ponad 20 unikalnych metod, w tym przygotowany przez twórców „Nerfacto” czy wykorzystujący rozsmarowywanie Gaussów „Splatfacto”. Ważną funkcję pełnią także DataParsery, sprowadzające różnorodne zbiory danych do wspólnego formatu obejmującego między innymi listę obrazów, parametry kamer czy opcjonalne maski. Taka organizacja nie tylko porządkuje kod, ale też ułatwia porównywanie metod i wymienianie poszczególnych komponentów bez konieczności przebudowy całego systemu. Jedną z największych zalet Nerfstudio jest bogactwo funkcjonalności użytkowych. Platforma udostępnia komplet narzędzi CLI, wśród których szczególnie istotne są `ns-process-data`, `ns-train`, `ns-viewer`, `ns-render`, `ns-export` oraz `ns-eval`. Dzięki nim użytkownik może przygotować dane, uruchomić trening, uruchomić podgląd na żywo, wyrenderować wideo, wyeksportować dane do innych formatów oraz obliczyć metryki jakości. Ekosystem Nerfstudio pozwala na wykorzystanie własnych danych wejściowych w wielu różnych standardach, takich jak zbiory obrazów, wideo, Polycam, Record3D, Metashape, RealityCapture, ODM czy Aria. Przy przetwarzaniu danych wykorzystywane są zewnętrzne narzędzia, przede wszystkim COLMAP i FFmpeg. Na wyróżnienie zasługuje również element obserwacji procesu uczenia. Po rozpoczęciu treningu Nerfstudio równolegle uruchamia przeglądarkowy podgląd, dzięki czemu możliwe jest śledzenie postępu w czasie rzeczywistym. Podgląd nie wymaga dodatkowej instalacji po stronie użytkownika, działa w przeglądarce i został zbudowany z użyciem Viser, ThreeJS oraz Reacta, komunikując się z procesem treningowym dzięki połączeniu WebSocket. Uzupełnieniem procesu trenowania modeli w Nerfstudio jest narzędzie `ns-eval`, przeznaczone do oceny jakości wytrenowanej reprezentacji

sceny. Metoda ta wczytuje punkt kontrolny modelu wymieniony w pliku konfiguracyjnym, oblicza metryki jakości, a następnie zapisuje wyniki do pliku JSON. Rozwiązanie to ma istotne znaczenie z perspektywy eksperymentalnej, ponieważ pozwala na zachowanie powtarzalności procedury oceny i ułatwia bezpośrednie porównywanie różnych zaimplementowanych metod.

Pomimo licznych zalet z punktu widzenia niniejszej pracy kluczowe jest jednak to, że Nerfstudio nie nadaje się do wiernej rekonstrukcji sceny z pojedynczego zdjęcia. Wynika to nie z braków implementacyjnych, lecz z samej natury metod, na których bazuje. W przypadku własnych zbiorów obrazów lub nagrań narzędzie `ns-process-data` wykorzystuje między innymi wymieniony powyżej COLMAP, a więc pośrednio dziedziczy ograniczenia charakterystyczne dla podejścia Structure from Motion. Dodatkowo sama metodyka NeRF jest silnie związana z liczbą zdjęć w zbiorze wejściowym. W ramach niniejszej pracy w celu zbadania granic praktycznej użyteczności dostępnych rozwiązań wykonano dodatkowy, minimalny test w postaci próby uruchomienia procesu treningowego na silnie ograniczonych zbiorach danych. Nerfstudio pozwala na kontrolowanie liczby obrazów wykorzystanych podczas uczenia, dzięki czemu możliwe było przetestowanie modeli Nerfacto oraz Splatfacto przy zredukowanej liczbie wejściowych kadrów¹. Wyniki eksperymentów wykazały, że minimalna liczba obrazów wymaganych do prawidłowego zainicjowania i przeprowadzenia procesu wynosiła odpowiednio 3 i 8 kadrów.

pixelNeRF

PixelNeRF [41] należy do grupy metod, które próbowały przezwyciężyć jedno z najważniejszych ograniczeń klasycznego NeRF, czyli konieczność osobnej, czasochłonnej optymalizacji dla każdej nowej sceny. W rozwiązaniu przedstawionym przez badaczy z UC Berkeley paradygmat neuronowych pól radiancji został rozszerzony o wykorzystanie sieci konwolucyjnych do ekstrakcji lokalnych cech obrazu. Dzięki temu możliwe staje się przewidywanie reprezentacji NeRF na podstawie jednego lub kilku obrazów wejściowych, bez dodatkowej optymalizacji w czasie testowym. W sensie metodologicznym autorzy zachowują podstawowy mechanizm objętościowego renderowania znany z NeRF, wprowadzając jednak istotną modyfikację: zamiast reprezentować scenę wyłącznie poprzez parametry sieci optymalizowane dla pojedynczego przypadku, rozszerzają wejście modelu o lokalne cechy obrazu powiązane z konkretnymi pikselami. Dzięki temu sieć może wykorzystywać zarówno informacje widoczne bezpośrednio w obrazie, jak i uprzednio wyuczone zależności, umożliwiając modelowi generalizację.

Z perspektywy praktycznego zastosowania pixelNeRF ujawnia jednak również istotne ograniczenia. Pomimo dużego znaczenia badawczego metoda nie jest rozwiązaniem szczególnie przyjaznym wdrożeniowo. W trakcie własnych prób uruchomienia napotkano liczne trudności instalacyjne, związane z zależnościami środowiskowymi. Nawet po poprawnym skonfigurowaniu środowiska kolejną barierą okazał się sposób przygotowania danych wejściowych. Implementacja pixelNeRF wymaga

¹Wymogiem eksperymentu rekonstrukcji na tak rzadkich zbiorach własnych danych w Nerfstudio było wywołanie `ns-process-data` na pełnym zestawie danych, np. 18 zdjęć, zależnie od sceny. Dopiero na etapie treningu ograniczano próbkę poprzez parametr `--train-split-fraction`.

bowiem przeformatowania zbioru danych do ściśle określonej struktury, zgodnej z oczekiwaniami projektu. Oznacza to, że wykorzystanie własnych obrazów lub niestandardowych zbiorów wymaga dodatkowego etapu wstępnego przetworzenia danych, który może być czasochłonny i technicznie problematyczny.

MVSplat

Tytuł metody MVSplat [4] trafnie oddaje jej charakter metodologiczny, ponieważ jest to rozwiązanie sytuujące się na pograniczu klasycznego Multi-View Stereo oraz nowoczesnych metod jednokierunkowych, reprezentując scenę za pomocą trójwymiarowych funkcji Gaussa. Od strony architektury technologicznej MVSplat to kompleksowy system rekonstrukcji i syntezy widoków. Integruje on moduł ekstrakcji cech obrazowych (wykorzystujący sieci CNN i transformery), mechanizm budowania bryły kosztów oparty na metodzie plane sweeping, komponent estymacji geometrii sceny, a także końcową reprezentację przestrzenną w postaci 3D Gaussian Splatting. Z perspektywy niniejszej pracy MVSplat należy więc traktować jako rozwiązanie bardzo interesujące metodologicznie, ponieważ pokazuje, że połączenie klasycznej techniki MVS z reprezentacją poprzez funkcje Gaussa może skutkować dobrą geometrią, wysoką jakością renderowania oraz dużą szybkością. Jednocześnie jego ograniczenie jest wyraźne: metoda zakłada wejście w postaci kilku obrazów z estymowanymi lub znanymi parametrami kamer, a więc nie rozwiązuje problemu wiernej rekonstrukcji sceny z pojedynczego zdjęcia. Pomimo podjętych prób implementacyjnych nie udało się uruchomić metody MVSplat na dostępnej maszynie obliczeniowej, co wynikało z problemów związanych z konfiguracją środowiska oraz kompatybilnością wymaganych pakietów.

TripoSR

TripoSR [33] to nowoczesny model jednokierunkowy, opracowany we współpracy firm Stability AI oraz Tripo AI. Algorytm ten jest w stanie wygenerować trójwymiarową siatkę wielokątów, wykorzystując zaledwie jedno zdjęcie w bardzo krótkim czasie. Od strony architektury TripoSR bazuje na wcześniej opracowanym modelu *Large Reconstruction Model* (LRM) [11], który zaprojektowano ściśle do zadań rekonstrukcji z pojedynczego zdjęcia. Twórcy, opierając się na architekturze LRM, dodatkowo rozwinęli ją o szereg usprawnień obejmujących dane treningowe, konstrukcję modelu oraz sam proces uczenia.

Rdzeń rozwiązania tworzą trzy zasadnicze elementy: zainicjalizowany na podstawie DINOv1 [3] enkoder obrazu, dekodery przekształcający cechy do reprezentacji *triplane* oraz moduł NeRF operujący na tej reprezentacji. Istotną cechą TripoSR jest rezygnacja z warunkowania modelu znanymi parametrami kamery. Zamiast tego autorzy zdecydowali się dopuścić, aby model sam estymował parametry zewnętrzne i wewnętrzne kamery zarówno podczas treningu, jak i inferencji. Celem takiego zabiegu było zwiększenie odporności rozwiązania na obrazy pochodzące z rzeczywistych, mniej kontrolowanych warunków. Bazowanie na architekturze LRM pociąga za sobą szereg konsekwencji, również tych negatywnych. TripoSR dziedziczy w ten sposób znaczną część problemów znanych

ze swoich poprzedników. Po pierwsze, ponieważ model otrzymuje dane tylko z jednej perspektywy, informacje o tylnej, niewidocznej stronie obiektu muszą zostać przewidziane (wygenerowane) na podstawie wag wyuczonego modelu. Często prowadzi to do utraty szczegółów z tyłu bryły lub generowania gładkich, nienaturalnych powierzchni. Po drugie, LRM zakłada obiekty o charakterze lambertowskim i pomija modelowanie wyglądu zależnego od kierunku obserwacji, przez co nie jest w stanie wiernie odwzorować materiałów przezroczystych, silnie połyskujących lub refleksyjnych.

Ostatecznie jednak to ograniczenia metodologiczne są głównym czynnikiem dyskwalifikującym TripoSR pod kątem niniejszej pracy. Pierwszym z nich jest fakt, że model ten został zaprojektowany wyłącznie do rekonstrukcji z pojedynczego obrazu i nie przyjmuje większej liczby zdjęć, co uniemożliwia przeprowadzenie testów w pozostałych planowanych scenariuszach. Dodatkowo ze względu na ukierunkowanie modelu na indywidualne obiekty oraz związany z tym wymóg izolacji bryły od tła, TripoSR jest całkowicie pozbawiony zdolności interpretacji i rekonstrukcji szerokich scen przestrzennych (zarówno wewnątrz, jak i środowisk zewnętrznych), które stanowią kluczowy element autorskiego zbioru danych.

3.2 Architektura i charakterystyka wybranych modeli

Rozwój algorytmów rekonstrukcji 3D w ciągu ostatnich lat charakteryzuje się wyraźnym przejściem od metod opartych na klasycznej geometrii wielowidokowej i czasochłonnej optymalizacji, aż po nowoczesne, jednokierunkowe sieci głębokie. Zrozumienie tej ewolucji jest kluczowe dla uzasadnienia modeli wybranych w niniejszej pracy. Tradycyjne algorytmy rekonstrukcji, reprezentowane przez oprogramowanie takie jak COLMAP, oparte na metodach SfM oraz MVS, wymagają gęstego nakładania się kadrów, wyraźnych cech tekstur oraz skomplikowanego procesu triangulacji w celu poprawnego odtworzenia geometrii sceny. Z kolei techniki oparte na uczeniu maszynowym pierwszej fali, takie jak klasyczne neuronowe pola radiancji czy początkowe implementacje rozsmarowywania Gaussów 3D, znacząco poprawiły jakość fotorealistycznego renderingu, jednak odziedziczyły główną wadę klasycznych rozwiązań: konieczność osobnej optymalizacji dla każdej rekonstruowanej sceny. W praktyce proces ten jest wysoce zasobochłonny, a jego czas wykonania pozostaje istotnym ograniczeniem zastosowań eksperymentalnych i praktycznych. Dodatkowo obie grupy metod nie są projektowane z myślą o rekonstrukcji z pojedynczego obrazu lub bardzo małej liczby zdjęć. W takim scenariuszu ich skuteczność wyraźnie spada, ponieważ dostępne dane nie dostarczają wystarczającej ilości informacji geometrycznych i wizualnych do stabilnego odtworzenia pełnej struktury sceny trójwymiarowej. Modele jednokierunkowych (ang. *feed-forward*) sieci wykorzystujące architektury typu transformer zaopatrzone w mechanizmy uwagi potrafią skutecznie odpowiedzieć na te ograniczenia. W fazie treningu uczą się globalnych relacji pomiędzy widokami, a na etapie inferencji potrafią przewidywać geometrię sceny bez konieczności kosztownej iteracyjnej optymalizacji. W rezultacie okazują się szczególnie użyteczne w zadaniach takich jak estymacja pozycji kamer przy trudnych danych, rekonstrukcja z rzadkich widoków, gęste dopasowanie korespondencji przy dużych zmianach perspektywy czy integracja niejednorodnych danych wejściowych. Nie oznacza to

jednak, że klasyczne metody geometryczne całkowicie tracą na znaczeniu. Nadal stanowią one ważny punkt odniesienia, a niekiedy również służą jako etap doprecyzowania wyników. Niemniej jednak to właśnie jednoprzebiegowe modele oparte na transformerach stanowią obecnie awangardę w rozwoju technologii rekonstrukcji 3D.

MASt3R

Model **MASt3R** (ang. *Matching and Stereo 3D Reconstruction*) [15] to zaawansowana architektura głębokich jednokierunkowych sieci neuronowych, opracowana i rozwijana przez zespół badawczy NAVER LABS Europe. Została oficjalnie zaprezentowana podczas konferencji ECCV 2024 jako bezpośrednia ewolucja i znaczne ulepszenie modelu DUS3R. Autorzy wychodzą z założenia, że problem korespondencji obrazowych nie powinien być traktowany wyłącznie jako zadanie dwuwymiarowe, lecz jako zagadnienie ściśle związane z geometrią 3D sceny i relacją pomiędzy kamerami.

Od strony architektonicznej MASt3R jest bezpośrednim rozwinięciem DUS3R. Dla pary obrazów model wykorzystuje współdzielony enkoder typu ViT, a następnie dwa splecione dekodery z mechanizmem uwagi krzyżowej (ang. *cross-attention*), których zadaniem jest modelowanie relacji przestrzennej pomiędzy dwoma widokami. Część odziedziczona po DUS3R przewiduje na podstawie każdego piksela mapę punktów 3D oraz mapę pewności. MASt3R zachowuje główną ścieżkę rekonstrukcyjną, ale dodaje do niej drugi, wyspecjalizowany moduł opisujący lokalne cechy. Ten dodatkowy człon generuje gęste deskryptory lokalne dla obu obrazów, dzięki czemu model może wykonywać dopasowanie nie tylko na podstawie samych przewidywanych punktów 3D, lecz także w wyuczonej przestrzeni cech. Jest to kluczowa zmiana, ponieważ, jak zauważają twórcy, choć same mapy punktów cechują się dużą odpornością wobec zmian widoku, nie zapewniają jeszcze optymalnej dokładności. Jednym z najważniejszych praktycznych problemów tego typu modeli jest koszt obliczeniowy gęstego dopasowania. Naiwne wzajemne wyszukiwanie najbliższych sąsiadów dla wszystkich pikseli szybko staje się niepraktyczne dla obrazów o większych rozmiarach lub rozdzielczości. Autorzy MASt3R rozwiązują ten problem dwuetapowo. Po pierwsze, wprowadzają algorytm *fast reciprocal matching*, który iteracyjnie prowadzi zbiór punktów do stabilnych, wzajemnych dopasowań. Po drugie, stosują strategię *coarse-to-fine*, w której najpierw wykonywane jest dopasowanie na obrazach o obniżonej rozdzielczości, a następnie proces jest lokalnie dopracowywany na wycinkach obrazów w pełnej rozdzielczości. Takie podejście pozwala zachować wyższą dokładność przy znacznie lepszej wydajności. Zakres funkcjonalności MASt3R jest dość szeroki. Model potrafi wyprowadzać ogniskową, estymować położenie kamer, wykonywać relokalizację wizualną oraz rekonstruować geometrię sceny. Twórcy zwracają szczególną uwagę na wyniki algorytmu w przypadku „relokalizacji bez mapy”, oznaczającej zdolność modelu do oszacowania pozy kamery w sześciu stopniach swobody [18] (ang. *Six Degrees of Freedom*, 6-DoF), czyli translacji i rotacji w trzech wymiarach. Szczególnie istotny z perspektywy niniejszej pracy jest fakt, że model zachowuje użyteczność także w scenariuszach opartych na niewielkiej liczbie zdjęć. Ważnym aspektem jest także sposób treningu modelu. W tym

przypadku zastosowano mieszankę czternastu zbiorów danych obejmujących sceny wewnętrzne, zewnętrzne, syntetyczne, rzeczywiste i skupione na obiektach. MAST3R dziedziczy bazowe zdolności rekonstrukcyjne DUST3R dzięki zapożyczeniu wag na potrzeby własnej inicjalizacji. Model uczony jest na podstawie 650 tysięcy par równomiernie rozdzielonych między wszystkie zestawy danych. Następnie na parach są wykonywane dodatkowe operacje w celu zróżnicowania danych treningowych.

Ponieważ MAST3R jest metodą zasadniczo dwuobrazową, odpowiada częściowym założeniom niniejszej pracy. Algorytm ten stanowi dobry punkt odniesienia dla trzech scenariuszy badawczych, w których badana jest rekonstrukcja z rzadkich zbiorów danych. Dodatkowym atutem jest fakt, że twórcy udostępniają interaktywną aplikację internetową umożliwiającą wygodne testowanie modelu i kontrolę wybranych parametrów, co ułatwia prowadzenie eksperymentów.

VGGT

VGGT [35], czyli Visual Geometry Grounded Transformer, to nowoczesny model zaprojektowany w celu rekonstrukcji 3D z jednego, kilku, a nawet setek zdjęć. Głównym założeniem badawczym było udowodnienie, że zadania do tej pory rozwiązywane przez zestawy osobnych, wyspecjalizowanych algorytmów mogą, dzięki postępowi w mocy sieci neuronowych, być rozwiązane bezpośrednio przez sieć. W efekcie opracowano architekturę zdolną do symultanicznego wykonywania wielu zadań z dziedziny widzenia komputerowego w pojedynczym przebiegu sieci neuronowej. Kluczową zaletą VGGT jest jego wielozadaniowość: model estymuje parametry wewnętrzne i zewnętrzne kamer, wyznacza mapy głębi dla poszczególnych obrazów, generuje gęste mapy punktów 3D oraz tworzy reprezentacje umożliwiające śledzenie trajektorii punktów (ang. *point tracking*) między widokami. Ponadto otwarty charakter projektu i publicznie udostępnione repozytorium dostarczają kompletnych skryptów oraz przykładów demonstracyjnych, co znacząco ułatwia proces testowania i wizualizację działania modelu.

Architektura VGGT opiera się na dużym transformerze z niewielką liczbą założeń specyficznych dla geometrii 3D. W pierwszej fazie wejściowa kolekcja obrazów zostaje przeskalowana, podzielona na regularne obszary (ang. *patches*) i poddana procesowi tokenizacji. Charakterystycznym elementem modelu jest mechanizm *alternating-attention* polegający na naprzemiennym stosowaniu uwagi w obrębie pojedynczego obrazu oraz pomiędzy wszystkimi obrazami wejściowymi. Rozwiązanie to ma umożliwić jednoczesne spójne modelowanie każdego indywidualnego obrazu oraz utrzymanie globalnych zależności pomiędzy różnymi ujęciami tej samej sceny. W praktyce model wykorzystuje 24 bloki uwagi, a każdy z nich składa się z 2 warstw.

1. **Warstwa uwagi wewnątrzkatkowej** — (ang. *frame-wise self-attention*) podnosi spójność wewnątrz pojedynczego ujęcia.
2. **Warstwa uwagi globalnej** — (ang. *global self-attention*) agreguje informacje ze wszystkich dostarczonych zdjęć.

W ostatecznym kroku procesu przetwarzania zaktualizowane tokeny trafiają do dwóch specjalistycznych głowic. Głowica kamery (ang. *Camera Head*) wykonuje końcową predykcję parametrów pozycjonowania (zewnętrznych i wewnętrznych), natomiast głowica DPT (ang. *Dense Prediction Transformer*) przekształca tokeny obrazowe bezpośrednio do postaci gęstych map punktów 3D oraz map głębi. Proces treningowy modelu VGGT przeprowadzono na wielkoskalowym i silnie zróżnicowanym zbiorze danych. Autorzy wskazują, że do treningu wykorzystano mieszankę wielu zbiorów danych obejmujących rozmaite kategorie scen, a zastosowane dane pozyskano z wielu źródeł, w tym z pomiarów wykonywanych za pomocą sensorów (np. sprzętowe mapy głębi), środowisk wygenerowanych komputerowo oraz danych otrzymanych za pomocą klasycznych metod SfM. Tak zróżnicowany zestaw danych treningowych zapewnia solidną podstawę do maksymalizacji umiejętności generalizacji przez model. Pomimo licznych zalet model VGGT nie jest pozbawiony pewnych ograniczeń. Twórcy publikacji wskazują, że bieżąca architektura nie obsługuje obiektów typu „rybie oko” (ang. *fisheye*) ani ujęć panoramicznych, a jakość wyestymowanej geometrii zauważalnie spada w przypadku bardzo dużych rotacji pomiędzy obrazami wejściowymi. Ponadto model osiąga gorsze wyniki w scenach obciążonych rozmyciem ruchu, choć niewielkie ruchy mogą być jeszcze tolerowane. Niemniej VGGT bez wątpienia najlepiej wpisuje się w problem rekonstrukcji scen zasadniczo statycznych. Badacze podkreślają jednak, że ze względu na elastyczność zastosowanej architektury powyższe ograniczenia mogą zostać częściowo zniwelowane. Docelowe dostrojenie sieci (ang. *fine-tuning*) na wyspecjalizowanych zbiorach danych stanowi obiecujący kierunek badawczy, który powinien pozwolić na poprawę wyników w trudniejszych scenariuszach.

Całościowa charakterystyka modelu VGGT, obejmująca szeroki zakres funkcjonalności, zastosowanie nowoczesnych technologii oraz wysoką elastyczność w prowadzeniu eksperymentów, sprawia, że stanowi on wartościowy przypadek do wykorzystania w przeprowadzanych badaniach.

MapAnything

MapAnything [13] to jeden z najnowocześniejszych modeli rekonstrukcji 3D należących do rodziny modeli jednokierunkowych. Algorytm ten został zaprezentowany w drugiej połowie 2025 roku jako efekt współpracy badaczy z laboratoriów Meta Reality Labs oraz uniwersytetu Carnegie Mellon (CMU). W odróżnieniu od wielu wcześniejszych metod, które były projektowane z myślą o jednym ściśle określonym zadaniu, na przykład estymacji głębi, dopasowaniu dwóch widoków albo klasycznym SfM, MapAnything ma na celu rozwiązywanie różnorodnych problemów rekonstrukcyjnych w ramach jednej architektury. Twórcy podkreślają, że model potrafi obsłużyć ponad dwanaście zadań z zakresu rekonstrukcji 3D. Kluczową cechą algorytmu jest możliwość wykorzystania szerokiego zakresu danych wejściowych, nie jedynie samych obrazów. Model opcjonalnie potrafi przyjąć dodatkowe dane geometryczne.

Rdzeniem MapAnything jest zastosowanie sfaktoryzowanej reprezentacji geometrii wielowidokowej, według której zamiast odtwarzać scenę poprzez zestaw map punktów dla całego otoczenia, algorytm rozбивa problem na osobne komponenty. Komponenty te stanowią lokalne kierunki

promieni, głębokości wzdłuż promieni, pozy kamer oraz globalny współczynnik skali metrycznej, z których następnie składana jest spójna rekonstrukcja sceny w przestrzeni 3D. Istotną przewagą oprogramowania na tle innych modeli jest jego duża elastyczność względem wejściowych danych. MapAnything zaprojektowano tak, by obsługiwał pojedyncze zdjęcia, krótkie sekwencje zdjęciowe, ale także bogatsze zbiory danych. Choć model może działać na samych obrazach, możliwe jest uzupełnienie danych wejściowych o dodatkowe informacje geometryczne, takie jak pozycje kamer lub mapy głębi. Pod względem architektury MapAnything jest dużym modelem typu transformer przystosowanym do pracy na wielu widokach oraz wielu typach danych wejściowych, wymaga więc indywidualnej strategii dla obsługi i formatowania danych. Dla obrazów wykorzystywany jest enkoder DINOv2 [22], z którego pobierane są znormalizowane cechy. Dodatkowe dane geometryczne, takie jak kierunki promieni i znormalizowane głębokości, są kodowane przez płytkie sieci splotowe, natomiast parametry o charakterze globalnym, takie jak rotacje, kierunki translacji czy skale, są mapowane do przestrzeni cech przy użyciu sieci MLP. Po zakodowaniu i normalizacji wszystkich wejść ich reprezentacje są agregowane, a następnie przekształcane w tokeny i przekazywane do wielowidokowego transformera wykorzystującego mechanizm *alternating-attention*, zaczerpnięty z modelu VGGT. W celu stabilnego działania MapAnything wytrenowano z użyciem 13 zróżnicowanych zbiorów danych obejmujących sceny wewnętrzne, zewnętrzne oraz przypadki *in-the-wild*. Aby zapobiec zjawisku nadmiernego dopasowania i uodpornić architekturę na braki w danych (częsty przypadek dla zdjęć wykonywanych urządzeniami powszechnego użytku), badacze podczas treningu losowo dołączali dodatkowe informacje geometryczne. W ten sposób sieć uczy się funkcjonować w wielu konfiguracjach, zamiast specjalizować się wyłącznie w jednej. Do ograniczeń algorytmu należą przede wszystkim brak jawnego uwzględniania szumu i niepewności w wejściach geometrycznych oraz ograniczona skalowalność w przypadku większych scen.

Na podstawie powyższych rozważań stwierdzono, że MapAnything dobrze wpisuje się w założenia niniejszej pracy, ponieważ został zaprojektowany z myślą o zróżnicowanych, nie zawsze idealnie kompletnych danych wejściowych, dzięki czemu stanowi interesujący obiekt badań w kontekście rekonstrukcji wykonywanej na podstawie ograniczonej liczby zdjęć. Jednocześnie model ten należy do grupy najnowszych rozwiązań jednokierunkowych, a więc dobrze obrazuje aktualny kierunek rozwoju metod rekonstrukcji 3D. Z tych względów jego uwzględnienie w pracy jest zasadne zarówno z perspektywy badawczej, jak i porównawczej.

Zestawienie

Omówione modele reprezentują zbliżony kierunek rozwoju współczesnej rekonstrukcji trójwymiarowej, oparty na jednokierunkowej inferencji wykonywanej przez duże modele transformerów. Pomimo tej wspólnej podstawy różnią się one szeregiem cech, w tym zakresem działania, typem przyjmowanych danych, charakterem generowanych wyników oraz stopniem dopasowania do scenariuszy testowych zakładanych w niniejszej pracy. Z tego względu konieczna jest ich weryfikacja nie tylko pod kątem

założeń teoretycznych, ale przede wszystkim praktycznej użyteczności. Poniższa tabela 1 porządkuje najważniejsze cechy przedstawionych modeli.

Tabela 1. Tabela porównawcza testowanych modeli rekonstrukcyjnych. Źródło: opracowanie własne na podstawie [13, 35, 15].

Kryterium	MapAnything	VGGT	MASt3R
Architektura	Feed-Forward Transformer	Feed-Forward Transformer	Feed-Forward Transformer
Cel	Uniwersalna metryczna rekonstrukcja 3D dla wielu zadań	Bezpośrednia rekonstrukcja geometrii sceny i kamer z jednego lub wielu obrazów.	Gęste dopasowanie par obrazów oraz lokalna rekonstrukcja 3D.
Dane wejściowe	Jeden lub wiele obrazów, opcjonalne dane pomocnicze	Od 1 do kilkuset obrazów z danej sceny, bez konieczności podawania znanych parametrów kamer.	Para obrazów bez wymaganej kalibracji wejściowej.
Dane wyjściowe	Metryczna rekonstrukcja 3D wraz z informacją o kamerach.	Parametry kamer, mapy głębi, mapy punktów oraz cechy/ścieżki do śledzenia punktów	Współrzędne 3D dla każdego piksela
Udział w scenariuszach testowych	1, 2, 3, 4	1, 2, 3, 4	2, 3, 4
Mocne strony	Największa elastyczność spośród porównywanych metod, zachowuje metryczną skalę absolutną, szeroki zakres zastosowań.	Mocne dopasowanie do tematu pracy.	Wyjątkowa skuteczność w dopasowywaniu cech przy drastycznych zmianach perspektywy, brak wymogu kalibracji kamer
Ograniczenia	W trybie samych obrazów nie wykorzystuje pełnego potencjału dodatkowych danych geometrycznych.	Potencjalnie wrażliwy na małe pokrycie między obrazami, nietypową optykę lub bardzo duże zmiany widoku.	Brak absolutnej skali metrycznej

Rozdział 4

Zbiory danych

Zbiory danych (ang. *datasets*) w procesie rekonstrukcji 3D mogą pełnić jedną z dwóch ról: stanowią fundament procesu uczenia głębokich sieci neuronowych lub dostarczają obiektywnego punktu odniesienia (ang. *ground truth*) do weryfikacji precyzji algorytmów. W sekcji 4.1 scharakteryzowano wybrane wielkoskalowe zbiory danych [39, 16, 40] wykorzystane w procesie trenowania analizowanych modeli jednokierunkowych. Wykorzystanie tak obszernych zasobów pozwala na maksymalizację zdolności trenowanej sieci neuronowej do generalizacji oraz umożliwia modelom naukę różnorodnych ujęć i warunków oświetleniowych, z jakimi mogą się zetknąć w rzeczywistych scenariuszach. Dodatkowo przedstawiono również dwa zbiory regularnie wykorzystywane do ewaluacji algorytmów rekonstrukcyjnych, które w niniejszej pracy posłużyły jako baza do wykonywanych eksperymentów. Pierwszy z nich to ETH3D [27]. O jego wyborze zdecydowały przede wszystkim kompaktowy rozmiar, wysoka różnorodność scen oraz wysoka jakość zrealizowanych ujęć. Drugim zestawem jest LLFF [21], szczególnie popularny w badaniach nad metodami NeRF. Jest to zbiór kompleksowy, zawierający szereg skomplikowanych struktur, które stanowią istotne wyzwanie dla nawet najskuteczniejszych algorytmów. Dopełnieniem rozdziału o zestawach danych jest sekcja 4.2 przedstawiająca opis autorskiego zbioru, pozbawionego laboratoryjnej precyzji wykonania, co pozwala na rzetelną ocenę użyteczności badanych rozwiązań w codziennych zastosowaniach.

4.1 Przegląd zbiorów danych

Istotnym elementem rozwoju nowoczesnych metod rekonstrukcji trójwymiarowej są ogólnodostępne zbiory danych i testy porównawcze. W przypadku omawianych w niniejszej pracy modeli wizyjnych kluczowe znaczenie ma skala oraz różnorodność danych treningowych. Współczesne modele oparte na sieciach neuronowych budują zdolność do generalizacji dzięki treningowi na rozległych kolekcjach obrazów. W związku z tym podstawową decyzją, przed jaką stają twórcy modelu, mającą bezpośredni wpływ na końcową jakość działania algorytmu, jest dobór odpowiedniego zestawu treningowego. Poszczególne zbiory różnią się nie tylko skalą, ale także charakterem scen, dokładnością geometrii, sposobem pozyskania danych czy docelowym zastosowaniem. Z tego względu twórcy agregują wiele

osobnych zbiorów, zamiast ograniczać się do pojedynczego zestawu. Taki plan działania pozwala zawrzeć w końcowym zbiorze różne klasy problemów, jak sceny wewnętrzne, zewnętrzne, syntetyczne czy dane typu *in-the-wild*. Autorzy modelu MapAnything deklarują w swojej pracy 13 wykorzystanych zbiorów; w przypadku modelu MAST3R było to 14 baz; natomiast twórcy VGGT nie podają dokładnej liczby, jednak wskazują, że zakres i różnorodność wykorzystanych danych były porównywalne z danymi użytymi do treningu modelu MAST3R. Tak szeroko zakrojone, połączone zestawy skutkują utworzeniem potężnej bazy treningowej, której rozmiar fizyczny określa się w terabajtach, a liczba unikalnych obrazów jest liczona w milionach. Z tego względu do właściwej ewaluacji badanych modeli zasadne jest wykorzystanie bardziej wyspecjalizowanych zbiorów testowych, takich jak ETH3D oraz LLFF, które umożliwiają ocenę algorytmów w lepiej zdefiniowanych i porównywalnych warunkach. Warto jednak uzupełnić niniejszą pracę o omówienie wybranych zestawów danych wykorzystanych do treningu analizowanych algorytmów, zwłaszcza tych, które odpowiadają charakterowi scen planowanych do rekonstrukcji.

ScanNet

Wśród najważniejszych zbiorów danych wykorzystywanych w badaniach nad rekonstrukcją trójwymiarowych scen wewnętrznych szczególne miejsce zajmują **ScanNet** [5] oraz jego nowszy rozwinięty odpowiednik **ScanNet++** [40]. Oba zbiory koncentrują się na zamkniętych przestrzeniach, jednak reprezentują dwa różne etapy rozwoju: pierwszy odpowiadał na potrzebę większej skali, drugi zaś celuje w wysoką precyzję wykonanych skanów.

Opublikowany w 2017 roku zbiór ScanNet składa się z ponad 2,5 miliona widoków, zebranych w 1513 skanach i pochodzących z 707 unikalnych pomieszczeń, co czyni go jednym z pierwszych tak dużych i kompleksowo opracowanych zbiorów RGB-D dla scen wewnętrznych. Tego rodzaju materiał dobrze oddaje typowe trudności pojawiające się przy rekonstrukcji wnętrza. Są to przede wszystkim: obecność wielu obiektów, częściowe przesłonięcia, zróżnicowane materiały oraz niejednorodność układów pomieszczeń. Dodatkowym atutem ScanNet jest fakt, że nie jest zbiorem danych udostępniającym jedynie obrazy oraz mapy głębi. Zbiór zawiera również estymowane parametry kamer, rekonstrukcje powierzchni, teksturowane siatki, segmentacje semantyczne oraz dla części scen dopasowane modele CAD. Obrazy rejestrowano przy pomocy konsumenckiego sensora podłączonego do tabletu Apple iPad. Ze względu na ograniczenia takiego zestawu obrazy cechują się relatywnie niską rozdzielczością oraz zauważalnym rozmyciem ruchu wynikającym z ręcznego operowania urządzeniem.

Odpowiedzią na te mankamenty stał się ScanNet++. Opublikowany w 2023 roku jako następca klasycznego ScanNetu, obejmuje 460 scen wewnętrznych, 280 tysięcy zdjęć z aparatu DSLR oraz ponad 3,7 miliona klatek RGB-D z iPhone'a. Zasadniczym postępem względem poprzednika było radykalne zwiększenie jakości rejestrowanych danych. Twórcy wykorzystali wysokiej klasy skanery laserowe oraz lustrzanki cyfrowe, a także komercyjne smartfony do osiągnięcia niespotykanej wcześniej precyzji, co znacznie zwiększyło wartość zbioru w kontekście nowych nurtów badawczych. Przykładem

takiego nurtu jest synteza nowych widoków. Autorzy wprost zaprojektowali ten zbiór jako test między innymi dla tego właśnie zadania.


Obecność takich zbiorów danych jak ScanNet czy ScanNet++ w procesie treningu ma istotne znaczenie dla skuteczności modeli rekonstruujących sceny wewnętrzne. Poprzez analizę dziesiątek tysięcy par zdjęć i precyzyjnych skanów laserowych sieci neuronowe uczą się globalnego kontekstu przestrzennego, co w praktyce przekłada się na lepsze rozumienie geometrii danej sceny oraz elementów w niej zawartych. Tym samym wykorzystanie tego rodzaju zbiorów zwiększa zdolność modelu do poprawnej interpretacji i generalizacji nowych scen, nawet jeśli różnią się one od przykładów wykorzystanych podczas treningu.

MegaDepth

Rozwój algorytmów głębokiego uczenia maszynowego, zdolnych do estymacji trójwymiarowej geometrii z pojedynczego lub zaledwie kilku ujęć, napotykał przez długi czas na zasadniczy problem: brak odpowiednio dużych i zróżnicowanych zbiorów danych treningowych. Dostępne kolekcje danych nie oferowały wystarczająco rozbudowanych i różnorodnych zasobów, aby sprostać wymaganiom stawianym przez rozwijane technologie rekonstrukcji. Jednym z głównych wyzwań była rekonstrukcja scen na podstawie zdjęć pochodzących z niekontrolowanych źródeł internetowych. Zbiory pozbawione tego rodzaju danych nie dostarczały modelom odpowiednich informacji podczas treningu, przez co miały one ograniczoną zdolność do skutecznego odtwarzania geometrii sceny w takich warunkach. Właśnie ta luka stała się jedną z przesłanek opracowania zbioru **MegaDepth** [16].

W odróżnieniu od innych popularnych zbiorów MegaDepth nie powstał na podstawie pomiarów wykonanych specjalistycznym sprzętem bezpośrednio rejestrującym głębię. Zamiast tego wykorzystano fotografie wielu znanych lokalizacji i obiektów architektonicznych pozyskane z internetu, a następnie poddano je zautomatyzowanemu procesowi rekonstrukcji 3D za pomocą algorytmów SfM oraz MVS (w szczególności z użyciem oprogramowania COLMAP). Taka metodologia była kluczowa dla osiągnięcia skali zbioru, obejmującego łącznie 196 unikalnych lokalizacji. Oparcie zestawu na nieustrukturyzowanych, publicznie dostępnych danych niesie jednak ze sobą pewne poważne wady. Jak wspomniano w sekcjach 2.1.4 oraz COLMAP, metody SfM+MVS stawiają wobec obrazów źródłowych szereg wymagań, których spełnienie jest niezbędne do uzyskania wyników odpowiedniej jakości. Trudno oczekiwać spełnienia tych rygorów od fotografii wykonanych przez przypadkowych użytkowników. Z tego względu twórcy MegaDepth zaimplementowali system filtrowania oparty na segmentacji semantycznej. Autorzy podzielili piksele obrazu na regiony pierwszoplanowe, tło oraz niebo. Informacje te wykorzystano do identyfikowania i usuwania z map głębi pikseli reprezentujących obiekty pierwszoplanowe niebędące częścią statycznej sceny (np. przechodniów, pojazdy). Segmentację semantyczną połączono ponadto z informacjami geometrycznymi uzyskanymi w procesie rekonstrukcji w celu automatycznego wyznaczania relacji głębi porządkowej (ang. *ordinal depth*), określających, który z dwóch elementów sceny znajduje się bliżej obserwatora. Relację tę określano mianem „bliżej–dalej”. W wyniku rekonstrukcji uzyskano około 150 tys. obrazów z informacją

geometryczną, z których po przeprowadzeniu procedury oczyszczania pozostawiono około 130 tys. poprawnych przykładów. Na rysunku 6 zaprezentowano przykład działania tego procesu.



Rysunek 6. Przykład wykonanej przez twórców MegaDepth optymalizacji map głębi, porównanie zdjęcia źródłowego (a) z mapą głębi klasycznego MVS (b) oraz ostateczną, poprawioną mapą głębi (c). Źródło: [16]

Ponieważ dane referencyjne w MegaDepth powstają pośrednio przez SfM i MVS, nie są wolne od błędów typowych dla tych metod. Dodatkowo charakter zbioru, oparty głównie na popularnych lokalizacjach fotografowanych przez użytkowników internetu, sprawia, że dominują w nim sceny plenerowe i architektoniczne, zwłaszcza punkty orientacyjne. Oznacza to, że choć MegaDepth skutecznie wspiera uczenie modeli ogólnej geometrii scen z fotografii, nie jest zbiorem w pełni reprezentatywnym dla wszystkich możliwych środowisk, na przykład dla scen skupionych wokół pojedynczych obiektów.

BlendedMVS

W roku 2020 opracowany został BlendedMVS [39], czyli zbiór danych, którego podstawowym celem było rozwinięcie możliwości modeli z kategorii metod MVS opartych na uczeniu maszynowym, przy czym szczególny nacisk położono na poprawę zdolności generalizacji sieci neuronowych. Motywacją do powstania tego zestawu był problem widoczny w pierwszych generacjach metod: mimo bardzo dobrych wyników uzyskiwanych na zbiorach zawierających jednorodne sceny, modele często wykazywały mniejszą skuteczność w przypadku rekonstrukcji scen rzeczywistych, bardziej zróżnicowanych pod względem skali, trajektorii kamer, oświetlenia oraz typu obiektów.

Procedura tworzenia BlendedMVS opierała się na rekonstrukcji teksturowanych modeli 3D z istniejących obrazów, a następnie renderowaniu tych modeli z różnych punktów widzenia. Taki sposób działania pozwolił na stworzenie dużego zbioru danych treningowych bez konieczności kosztownego pozyskiwania geometrii referencyjnej za pomocą skanerów laserowych lub innych sensorów. W pierwszym etapie dla wybranych scen przeprowadzana jest rekonstrukcja, której wynikiem jest

teksturowany model 3D oraz pozycje kamer. Następnie model ten renderowany jest z perspektyw odpowiadających poszczególnym obrazom wejściowym, co pozwala wygenerować zarówno obrazy RGB, jak i odpowiadające im mapy głębi. Szczególnie charakterystycznym elementem BlendedMVS jest zastosowanie procesu mieszania obrazów, od którego pochodzi nazwa zbioru. Siatkowe modele 3D pozwalają na masową produkcję renderów wraz z mapami głębi, jednak takie obrazy nie oddają w pełni rzeczywistych efektów oświetleniowych, zmian ekspozycji, odbić czy lokalnych warunków rejestracji obecnych w prawdziwych fotografiach. Aby złagodzić tę wadę, twórcy zdecydowali się wykorzystać oryginalne zdjęcia, które naturalnie zawierały informację o oświetleniu. Dokonano połączenia obu źródeł: z obrazu renderowanego pobierane są głównie wysokoczęstotliwościowe szczegóły wizualne, istotne dla dopasowywania, natomiast z obrazu rzeczywistego wydobywana jest niskoczęstotliwościowa informacja o oświetleniu (ang. *ambient lighting*). W efekcie powstaje obraz „zmieszany”, który zachowuje zgodność z mapą głębi, a jednocześnie lepiej przypomina dane rejestrowane w naturalnych warunkach. Zbiór obejmuje łącznie 113 scen i 17 818 obrazów. Sceny obejmują między innymi architekturę, widoki uliczne, rzeźby oraz mniejsze obiekty, a pojedyncza scena może zawierać od 20 do 1000 obrazów. Zbiór ten przesuwą akcent w stronę masowego generowania danych uczących dla sieci neuronowych, nawet kosztem tego, że referencja geometryczna nie pochodzi z niezależnego, fizycznego pomiaru, lecz jest wynikiem wcześniejszego procesu rekonstrukcji. Jest to celowy kompromis ukierunkowany na poprawę generalizacji metod głębokiego uczenia: w tym kontekście większa skala oraz różnorodność danych treningowych były większym priorytetem niż maksymalna dokładność referencyjnej geometrii pojedynczych scen.

LLFF

Dotychczas wymienione w niniejszej pracy zestawy danych stawiały na poprawę swojej użyteczności poprzez powiększanie skali i różnorodności, zawierając w sobie setki tysięcy lub miliony fotografii. LLFF [21], czyli Local Light Field Fusion, charakteryzuje się jednak nieco innym podejściem. Zbiór ten wywodzi się z pracy poświęconej praktycznej syntezie nowych widoków, w której główny nacisk położono nie na jak największą skalę zestawu danych, lecz na efektywne wykorzystanie ograniczonej liczby obrazów wejściowych. Celem autorów było opracowanie metody umożliwiającej renderowanie fotorealistycznych widoków przy rzadkim próbkowaniu przestrzennym. W efekcie zaproponowano podejście przeznaczone do rejestrowania i renderowania złożonych scen rzeczywistych uchwyconych za pomocą kamery prowadzonej z ręki.

W często wykorzystywanej wersji testowej związanej z LLFF analizuje się osiem statycznych scen rzeczywistych, obejmujących zarówno wnętrza, jak i przestrzenie otwarte. Reprezentują one wiele zróżnicowanych środowisk, zarówno wnętrz budynków, jak i przestrzeni otwartych, jednocześnie charakteryzujących się skomplikowaną geometrią, obecnością drobnych szczegółów (np. liści, płatków kwiatów) czy refleksyjnych powierzchni. Dane te nie reprezentują pełnych rekonstrukcji 360°, lecz sceny uchwycone z ograniczonego zakresu pozycji kamery, głównie z jednej strony obserwowanego obszaru.

Istotnym elementem pracy LLFF było wyprowadzenie praktycznych wytycznych określających, jak gęsto należy wykonywać zdjęcia sceny, aby późniejsza synteza nowych widoków była stabilna i fotorealistyczna. Autorzy odwołali się do teorii próbkowania plenoptycznego i pokazali, że zastosowanie warstwowych reprezentacji sceny, określanych jako Multiplane Image (MPI), pozwala znacząco zmniejszyć wymaganą liczbę obrazów wejściowych. Dla smartfona o polu widzenia około 64° podano uproszczoną zależność:

$$\frac{W}{\sqrt{N}} \leq 80 \frac{z_{\min}}{S} \quad (1)$$

gdzie W oznacza szerokość obrazu w pikselach, N liczbę zdjęć, $z_{\min}$ głębokość najbliższego punktu sceny, natomiast S rozmiar obszaru, po którym porusza się kamera.

Z powyższej zależności wynika, że liczba wymaganych zdjęć rośnie wraz z rozmiarem obszaru ruchu kamery oraz maleje wraz ze wzrostem odległości do najbliższego obiektu. Innymi słowy, im bliżej kamery znajduje się istotna część sceny, tym gęściej należy wykonywać kolejne ujęcia, aby zachować wystarczające pokrycie i ograniczyć artefakty podczas syntezy nowych widoków.

ETH3D

ETH3D [27] to zawierający kilkadziesiąt zróżnicowanych scen zbiór danych regularnie wykorzystywany w badaniach nad rekonstrukcją trójwymiarową. Motywacją do jego utworzenia były ograniczenia wcześniejszych testów porównawczych, które często były zbyt jednorodne, by spełniać wymagania nowoczesnych standardów eksperymentalnych. Autorzy ETH3D postawili sobie za cel stworzenie testu bardziej zróżnicowanego, lepiej odzwierciedlającego rzeczywiste warunki. W efekcie powstał zbiór obejmujący sceny wewnętrzne i zewnętrzne, zarejestrowane przy użyciu precyzyjnego skanera laserowego, wysokiej rozdzielczości aparatu DSLR oraz zestawu kamer. Jednym ze szczególnych aspektów ETH3D jest uwzględnienie akwizycji z nieograniczonym ruchem kamery w sześciu stopniach swobody. Oznacza to możliwość zmiany jej położenia wzdłuż trzech osi przestrzennych oraz orientacji poprzez obrót wokół każdej z nich. W przeciwieństwie do wielu zbiorów danych, w których kamera porusza się po z góry ustalonej lub mocno ograniczonej trajektorii, w ETH3D ruch kamery jest bardziej swobodny. Oznacza to, że algorytmy rekonstrukcyjne muszą uwzględniać bardziej złożone zmiany perspektywy oraz potencjalnie trudniejszy dobór sąsiednich widoków. Ponieważ w praktycznych zastosowaniach zdjęcia rzadko wykonywane są w idealnie równych odstępach, z jednakowym kątem patrzenia i stałym poziomem oświetlenia, jest to istotna zaleta zbioru w kontekście założeń badawczych niniejszej pracy. Zbiór ETH3D jest powszechnie uznawany za wymagający zestaw testowy, dobrze sprawdzający zdolność modelu do generalizacji. Wynika to bezpośrednio z charakterystyki scen wchodzących w skład tego zbioru. Ujęcia zewnętrzne charakteryzują się znacznymi zmianami punktu widzenia, występowaniem skomplikowanych okluzji, naturalnymi cieniami oraz zmiennymi warunkami oświetleniowymi. Z kolei sceny wewnętrzne obfitują w powierzchnie refleksyjne oraz obszary o jednorodnej (gładkiej) teksturze.

W kontekście niniejszej pracy ETH3D można uznać za zbiór szczególnie przydatny z dwóch powodów. Po pierwsze, pozwala on ocenić skuteczność algorytmów z rzeczywistymi, niekontrolowanymi scenami. Po drugie, obecność trudnych w rekonstrukcji elementów sprawia, że wyniki uzyskane na ETH3D mogą ujawniać ograniczenia badanych rozwiązań, szczególnie w zakresie odporności na słabą teksturę, okluzje i duże zmiany punktu widzenia.

4.2 Stworzenie własnego zbioru danych

W badaniach nad rekonstrukcją trójwymiarową częstą praktyką jest wykorzystywanie gotowych, publicznie dostępnych zbiorów danych zarówno do trenowania, jak i ewaluacji modeli. Takie podejście ma wiele zalet, ponieważ umożliwia porównywanie wyników różnych metod w ustandaryzowanych warunkach. Jednocześnie może jednak prowadzić do sytuacji, w której modele są oceniane na danych silnie zbliżonych do tych, które występowały w procesie ich uczenia lub dostrajania. Nawet jeśli konkretny zbiór testowy nie był bezpośrednio wykorzystany podczas treningu, często należy on do tej samej kategorii danych. W rezultacie uzyskane wyniki mogą w większym stopniu odzwierciedlać dopasowanie modelu do znanego typu danych niż jego rzeczywistą zdolność do generalizacji w nowych warunkach.

Z tego powodu w pracy uwzględniono również autorski zbiór zdjęć, przygotowany niezależnie od publicznie dostępnych zbiorów omawianych w poprzednich częściach pracy. Pozwala on uzupełnić eksperymenty o obrazy wykonane samodzielnie, w warunkach bliższych praktycznemu wykorzystaniu modeli niż profesjonalnie opracowane zestawy testowe. Skonfrontowanie badanych architektur ze zbiorem danych, z którym nie miały wcześniej styczności, pełni funkcję realnego testu umiejętności generalizacji modelu, kluczowego aspektu w przypadku rekonstrukcji z niewielkiej próbki danych. W dalszej części rozdziału przedstawiono założenia przyjęte podczas tworzenia tego zbioru, sposób akwizycji obrazów oraz podstawową charakterystykę przygotowanych scen.

Założenia i cel utworzenia zbioru

Podstawowym celem utworzenia autorskiego zbioru danych była analiza możliwości wybranych modeli rekonstrukcji trójwymiarowej na obrazach pozyskanych w warunkach zbliżonych do typowego, amatorskiego użycia. Zbiór miał symulować sytuacje, w których wykorzystywany sprzęt nie należy do klasy profesjonalnej, lecz jest urządzeniem powszechnie dostępnym, na przykład aparatem w smartfonie. Widoki uzyskane w ramach takiego procesu pozwalają na ocenę skuteczności współczesnych modeli rekonstrukcyjnych na zdjęciach, które nie zawsze spełniają idealne warunki rejestracji: mogą mieć ograniczoną jakość, mniej korzystne kadrowanie, niejednorodne tło lub nie być przygotowane specjalnie z myślą o danym algorytmie. Istotnym założeniem było przygotowanie danych w taki sposób, aby umożliwiały testowanie modeli przy różnej liczbie obrazów wejściowych. Każda scena miała być reprezentowana przez serię zdjęć wykonanych z różnych punktów widzenia, na podstawie których następnie utworzono podzbiory odpowiadające określonym scenariuszom

eksperymentalnym. Opracowanie takich wariantów testowych służyło spełnieniu kolejnego celu, jakim było zbadanie, czy zwiększenie liczby zdjęć oraz dobór ujęć spełniających podstawowe wymagania rekonstrukcji wpływają na jakość uzyskiwanych wyników, a także jak silna jest ta zależność. Przyjęto również, że zbiór będzie obejmował wyłącznie sceny statyczne oraz pozbawione ludzi i zwierząt. Elementy tego typu uznano za znajdujące się poza zakresem pracy, ponieważ mogłyby wprowadzać dodatkowe trudności związane z ruchem, zmianą kształtu, prywatnością oraz interpretacją wyników rekonstrukcji. Z tego względu skupiono się na obiektach oraz fragmentach otoczenia. Dodatkowym założeniem było zachowanie podstawowej jakości obrazów wejściowych. Fotografowany obiekt lub fragment przestrzeni musiał być widoczny w kadrze i oświetlony w stopniu umożliwiającym jego rozpoznanie. Nie dążono jednak do stworzenia idealnych warunków, tak by zachować możliwie realistyczny charakter danych. Przyjęte założenia miały więc zapewnić kompromis pomiędzy jakością fotografii a praktyczną naturą przygotowanych zdjęć. Ostatnim istotnym założeniem był sposób wykonywania zdjęć w obrębie jednej sceny. Dla każdej sceny starano się pozyskać serię obrazów z różnych perspektyw. Jeżeli możliwe było obejście obiektu dookoła, wykonywano zdjęcia obejmujące pełny lub częściowy ruch wokół niego. W przypadkach, w których pełne obejście sceny nie było możliwe, stosowano ujęcia skierowane w jednym kierunku (ang. *forward-facing*), skupione na obserwacji obiektu lub fragmentu przestrzeni od frontu oraz z boków.

Procedura pozyskania danych

Wszystkie fotografie wykonywano smartfonem Apple iPhone 16 Pro w orientacji poziomej, z użyciem ustawień umożliwiających zapis obrazów w formacie Apple ProRAW oraz w rozdzielczości do 48 MP. Podczas akwizycji danych starano się zachować możliwie spójną procedurę rejestracji, przy jednoczesnym utrzymaniu amatorskiego i praktycznego charakteru zbioru. Dla każdego przypadku testowego wykonywano serię zdjęć przedstawiających ten sam obiekt lub fragment otoczenia z różnych punktów widzenia. Sposób przemieszczania aparatu dostosowywano do charakteru fotografowanej sceny. Jeżeli obiekt można było swobodnie obejść, zdjęcia wykonywano z kolejnych pozycji rozmieszczonych wokół niego, tak aby uchwycić go z różnych stron. W pozostałych przypadkach, na przykład podczas fotografowania fragmentów architektury, murali, ścian lub szerszych fragmentów przestrzeni, aparat przemieszczano po łuku, utrzymując go skierowanego w stronę jednego, stałego obszaru. W obu przypadkach celem było uzyskanie zestawu obrazów różniących się perspektywą, ale nadal przedstawiających wspólne elementy obserwowanej sceny. Podczas wykonywania kolejnych zdjęć starano się zachować częściowe pokrycie pomiędzy ujęciami. Oznacza to, że te same kluczowe elementy fotografowanego obszaru powinny być widoczne na kilku sąsiednich obrazach, a jednocześnie pozycja aparatu powinna zmieniać się na tyle, aby dostarczać modelowi zauważalnie odmienne perspektywy. W praktyce przesunięcie między kolejnymi ujęciami wynosiło zwykle około dwóch kroków, jednak wartość ta nie była mierzona w precyzyjny sposób i należy ją traktować orientacyjnie. Nie stosowano filtrów, dodatkowej obróbki graficznej ani ręcznej korekcji kolorów, ekspozycji lub ostrości. Jedynym warunkiem koniecznym było spełnienie podstawowych wymagań jakościowych:

główny obiekt lub istotny fragment sceny musiał być widoczny, rozpoznawalny i możliwy do wykorzystania jako dane wejściowe dla modeli rekonstrukcyjnych.

W trakcie prac nad zbiorem testowano również inne podejścia do pozyskiwania materiału źródłowego. Jednym z początkowo rozważanych wariantów było nagrywanie filmów wideo, a następnie ich podział na pojedyncze klatki. Podejście to zostało jednak odrzucone, ponieważ generowało dużą liczbę nadmiarowych, bardzo podobnych obrazów oraz utrudniało wybór ujęć zachowujących porównywalne odstępstwa między kolejnymi punktami widzenia.

Po zakończeniu rejestracji przeprowadzano selekcję zgromadzonego materiału zdjęciowego. Jeżeli dla danej sceny wykonano większą liczbę obrazów, wybierano spośród nich zestaw najlepiej reprezentujący zmianę punktu widzenia, przy jednoczesnym zachowaniu czytelności fotografowanego obiektu lub obszaru. Usuwano przede wszystkim zdjęcia wyraźnie rozmyte, silnie poruszone, przypadkowo zasłonięte oraz takie, w których główny obiekt albo istotny fragment sceny został niewłaściwie zawarty w kadrze. Odrzucano również obrazy, których jakość techniczna mogłaby uniemożliwić sensowne przeprowadzenie testu. W zbiorze pozostawiono ujęcia, które mogą zawierać drobne problemy typowe dla fotografii wykonywanej w warunkach amatorskich, takie jak nieidealna ekspozycja, mniej korzystny balans kolorów, niejednorodne tło lub niewielkie różnice w ostrości lub kadrowaniu. Przed włączeniem zgromadzonego materiału do ostatecznego zbioru testowego surowe pliki poddano wstępnemu przetwarzaniu. Po wykonaniu zdjęć materiał eksportowano z urządzenia do popularnego formatu JPG, bez danych lokalizacyjnych. Dzięki temu końcowy zbiór składał się z plików w powszechnie obsługiwanym formacie rastrowym. Jednocześnie ograniczono ilość nadmiarowych metadanych, co ułatwiało ich dalsze przetwarzanie oraz wykorzystanie podczas analizy modeli. Dla każdej sceny przygotowano ostateczny zestaw zapisany jako osobny katalog o nazwie nawiązującej do ogólnej zawartości danej sceny. Każdy taki zestaw zawierał dokładnie osiem zdjęć. Następnie w obrębie każdego katalogu tworzone podzbiory odpowiadające scenariuszom testowym opisanym w pracy, różniące się liczbą obrazów wejściowych.

Charakterystyka scen

Przygotowany zbiór danych obejmuje kilka kategorii scen dobranych tak, aby reprezentowały różne przypadki typowe dla praktycznej rekonstrukcji trójwymiarowej. W zbiorze uwzględniono sceny wewnętrzne, zewnętrzne, naturalne, a także obiektowe. Taki dobór danych miał na celu uwzględnienie szerokiego zakresu wyzwań charakterystycznych dla rekonstrukcji trójwymiarowej, omawianych szerzej w poprzednich rozdziałach. Wyzwania te krótko podsumowano w tabeli 2.

Tabela 2. Tabela potencjalnych problemów rekonstrukcyjnych występujących w danych kategoriach scen. Źródło: opracowanie własne.

Kategoria scen	Przykłady	Potencjalne trudności
Wewnętrzne	pomieszczenia, przestrzeń biurowa	tło, płaskie powierzchnie, powtarzalne elementy
Zewnętrzne	budynki, murale, fragmenty otoczenia	większa skala, zmienne oświetlenie, ograniczony dostęp
Naturalne	roślinność	cienkie struktury, nieregularna geometria, duża liczba detali
Obiektowe	przedmioty codziennego użytku, posągi	wpływ tła, odbicia, częściowo niewidoczne powierzchnie

W przypadku obiektów centralnych uwzględniono zarówno sytuacje, w których obiekt był względnie odizolowany od otoczenia, jak i takie, w których występowało wyraźne tło. Pozwalało to sprawdzić, czy obecność dodatkowego kontekstu w scenie utrudnia modelowi rekonstrukcję obiektu, czy przeciwnie, zwiększa jakość rekonstrukcji poprzez dostarczenie dodatkowych informacji przestrzennych. Sceny różniły się między sobą skalą, złożonością tła oraz charakterem fotografowanych elementów. Część z nich przedstawiała pojedynczy, dominujący obiekt, natomiast inne obejmowały szerszy fragment otoczenia. W zbiorze znalazły się zarówno przypadki względnie proste, w których główny obiekt był dobrze widoczny i wyraźnie oddzielony od tła, jak i sceny bardziej wymagające, zawierające większą liczbę detali, nieregularną geometrię, powtarzalne wzory lub elementy mogące utrudniać rekonstrukcję. Na rys. 7 przedstawiono jedną ze scen wewnętrznych zawartych w zbiorze, natomiast szczegółową prezentację zestawu danych umieszczono w załączniku 2.



Rysunek 7. Przykład sceny wewnętrznej ze zbioru danych: wnętrze kawiarni z licznymi drobnymi obiektami, powierzchniami refleksyjnymi, przeszkloną witryną oraz zróżnicowanym oświetleniem. Źródło: opracowanie własne.

Ograniczenia zbioru

Część wymienionych powyżej założeń projektowych, stanowiących świadomy wybór autora, mogłaby zostać uznana za ograniczenia w klasycznym teście porównawczym. Aspekty takie jak wykorzystanie urządzenia konsumenckiego, wykonywanie zdjęć powierzchni problematycznych z perspektywy modeli rekonstrukcyjnych czy brak precyzyjnego pomiaru pozycji i orientacji kamery podczas rejestracji nierzadko uchodzą za cechy niepożądane w przypadku tworzenia profesjonalnych zbiorów. Ze względu jednak na przyjęty charakter budowanego zestawu danych, którego jednym z głównych założeń było postawienie wyzwania testowanym algorytmom rekonstrukcyjnym, elementy te potraktowano jako zamierzone czynniki eksperymentalne. Niemniej w ostatecznej wersji zbioru należy wskazać co najmniej dwa istotne ograniczenia.

Pierwszym z nich jest skala zestawu. Zbiór obejmuje dwadzieścia scen, co pozwala na przeprowadzenie porównania w kilku typach warunków, ale nie daje podstaw do traktowania go jako

wyczerpującego testu reprezentującego pełną różnorodność problemów występujących podczas rekonstrukcji trójwymiarowej. Szczególnie istotnym pominiętym typem danych są sceny wielkoskalowe, takie jak rozległe przestrzenie miejskie czy krajobrazy. Drugim ograniczeniem jest dobór zdjęć do poszczególnych wariantów wejściowych. Choć starano się wybierać kadry reprezentujące istotną zmianę punktu widzenia, decyzja o wyborze konkretnych fotografii była podejmowana ręcznie, bez automatycznego kryterium oraz bez dokładnego pomiaru pozycji kamery. Może to wpływać na wyniki uzyskiwane w wariantach z mniejszą liczbą obrazów, a także ograniczać powtarzalność procedury.

Rozdział 5

Analiza i porównanie eksperymentów

Analiza eksperymentalna przeprowadzona na potrzeby niniejszej pracy dyplomowej obejmowała testy modeli VGGT, MAST3R oraz MapAnything na trzech zbiorach danych: LLFF, ETH3D oraz zbiorze autorskim. Celem badań było określenie, w jaki sposób współczesne metody rekonstrukcji 3D oparte na architekturach transformerowych zachowują się przy bardzo ograniczonej liczbie obrazów wejściowych oraz jakie koszty obliczeniowe wiążą się z ich praktycznym wykorzystaniem. Eksperymenty przeprowadzono w czterech scenariuszach obejmujących odpowiednio 1, 2, 4 oraz 8 obrazów wejściowych. Wyjątek stanowił model MAST3R, który ze względu na sposób działania testowano od dwóch obrazów wejściowych. Rozdział podzielono na trzy główne części. W pierwszej przedstawiono metodykę przeprowadzonych eksperymentów. Druga dotyczy wydajności obliczeniowej i obejmuje porównanie czasu wymaganego do wykonania rekonstrukcji oraz poziomu zużycia pamięci RAM i VRAM. Parametry te mają kluczowe znaczenie z perspektywy praktycznego zastosowania modeli, ponieważ mogą stanowić istotne ograniczenie ich działania, szczególnie w środowiskach dysponujących ograniczonymi zasobami. Trzecia część rozdziału obejmuje ustrukturyzowaną analizę jakościową uzyskanych rekonstrukcji, opartą na jednolitej skali punktowej. Każdy wynik oceniono pod względem czterech kryteriów: kompletności rekonstrukcji, spójności geometrycznej, obecności artefaktów i szumu oraz stopnia odwzorowania struktury i szczegółów sceny. Na podstawie uzyskanych ocen przeanalizowano wpływ liczby obrazów wejściowych na jakość rezultatów, porównano charakterystyczne zachowania poszczególnych metod, omówiono wpływ perspektywy oraz wskazano typy scen i elementów, które sprawiały największe trudności rekonstrukcyjne. Dodatkowo przeprowadzono ograniczoną analizę dokładności metrycznej modelu MapAnything, porównując wybrane odległości w rekonstrukcjach z rzeczywistymi wymiarami.

5.1 Charakterystyka przeprowadzonej analizy

Niejednokrotnie eksperymenty z zakresu głębokiego uczenia i rekonstrukcji 3D, ze względu na swoją charakterystykę, są prowadzone z wykorzystaniem wysokiej klasy układów takich jak NVIDIA A100, H100, H200 lub nowsze jednostki Blackwell. Są to rozwiązania projektowane z myślą

o wielogodzinnej pracy, wysokiej przepustowości pamięci oraz współdzieleniu zasobów przez wielu użytkowników. Wiąże się to jednak z ich bardzo wysoką ceną, ograniczoną dostępnością, większym zapotrzebowaniem na energię oraz koniecznością stosowania odpowiedniej infrastruktury zasilania i chłodzenia. Ponieważ takie jednostki są poza zasięgiem przeciętnego konsumenta, w tym autora niniejszej pracy, wykorzystano relatywnie wydajne, prywatne stanowisko komputerowe wyposażone w kartę graficzną NVIDIA serii 40xx z 12 GB pamięci VRAM. Szczegółowa specyfikacja sprzętowa stanowiska została przedstawiona w załączniku 1.

Systemem bazowym był Windows, natomiast właściwe środowisko testowe uruchamiano w Ubuntu działającym w ramach Windows Subsystem for Linux. Wybór takiej konfiguracji wynikał z faktu, iż większość repozytoriów implementujących współczesne metody rekonstrukcji 3D jest rozwijana z myślą o systemach linuksowych. Ponieważ wspomniane metody standardowo funkcjonują w bardzo konkretnych zestawach zależności, obejmujących określoną wersję języka Python oraz pakiety wskazane przez autorów, do zarządzania zależnościami zdecydowano się wykorzystać menedżer Conda. Menedżer ten pozwala na przygotowywanie oddzielnych środowisk, co umożliwia uniknięcie kłopotliwych konfliktów pomiędzy zależnościami różnych modeli. Aby zachować spójność warunków eksperymentalnych, wszystkie testy wykonywano na tej samej jednostce oraz przy użyciu tych samych danych wejściowych. W ramach takiego indywidualnego środowiska uruchamiano opracowane przy pomocy sztucznej inteligencji skrypty pomocnicze, których celem było usprawnienie i automatyzacja procesu pomiarowego. Do tego zadania wykorzystano model GPT-5.5. Wygenerowany kod został następnie zweryfikowany przez autora pracy, dostosowany do środowiska eksperymentalnego oraz sprawdzony na wybranych przypadkach testowych przed rozpoczęciem właściwych pomiarów. Uzyskane skrypty można podzielić na dwa typy: rekonstrukcyjne oraz podsumowujące.

Pomocnicze skrypty rekonstrukcyjne

Zadaniem tej grupy programów jest wygenerowanie rekonstrukcji 3D na podstawie zestawu zdjęć. Każdy z nich uruchamia konkretną metodę, zapisuje wynikowy model oraz informacje o przebiegu eksperymentu. Dodatkową grupą w ramach tego typu skryptów były ich odpowiedniki grupowe (ang. *batch*), które automatyzowały uruchamianie wielu rekonstrukcji dla kolejnych scen i scenariuszy. Zestawienie skryptów przedstawiono w tabeli 3.

Tabela 3. Zestawienie skryptów wykorzystanych do automatyzacji rekonstrukcji. Źródło: opracowanie własne.

Skrypty	Rola	Efekt
vrgt/reconstruct_cli.py mast3r/reconstruct_cli.py mapany/reconstruct_cli.py	Uruchamia pojedynczą rekonstrukcję dla wskazanego zestawu zdjęć.	Plik z rekonstrukcją 3D oraz plik z informacjami o przebiegu testu.
vrgt/reconstruct_cli_batch.py mast3r/reconstruct_cli_batch.py mapany/reconstruct_cli_batch.py	Zawiera listę testów i kolejno uruchamia odpowiedni skrypt pojedynczej rekonstrukcji dla każdej sceny. Kontroluje przebieg serii, obsługuje błędy i wprowadza przerwy między testami.	Zestaw katalogów wynikowych, osobny dla każdego testu, zawierający rekonstrukcję 3D i metryki.

Ponieważ badane modele różnią się udostępnianym API, szczegóły implementacyjne skryptów odpowiedzialnych za wykonanie pojedynczej rekonstrukcji nie są identyczne. Starano się jednak zachować wspólną strukturę przetwarzania, tak aby ograniczyć wpływ różnic na końcowe wyniki testów. Przykład tej struktury przedstawia algorytm 1 w formie pseudokodu, natomiast pełne wersje omawianych skryptów zamieszczono w repozytorium projektu, do którego link znajduje się w załączniku 3.

Algorithm 1 Ogólny przebieg pojedynczej rekonstrukcji

```
1: START
2: Wczytaj nazwa_testu
3: Wczytaj ścieżka_do_obrazów
4: if nazwa_testu jest niepoprawna then
5:   Zakończ program z błędem
6: end if
7: obrazy ← Znajdź_obrazy(ścieżka_do_obrazów)
8: if obrazy są puste then
9:   Zakończ program z błędem
10: end if
11: Utwórz katalog_wynikowy
12: if GPU jest niedostępne then
13:   Zakończ program z błędem
14: end if
15: model ← Załaduj_model_rekonstrukcji
16: Rozpocznij pomiar czasu
17: dane_wejściowe ← Przygotuj_obrazy(obrazy)
18: wynik_modelu ← Uruchom_model(model, dane_wejściowe)
19: rekonstrukcja_3D ← Przetwórz_wynik(wynik_modelu)
20: Zapisz(rekonstrukcja_3D, reconstruction.glb)
21: metryki ← Przygotuj_metryki(obrazy, czas działania, zużycie pamięci)
22: Zapisz(metryki, metrics.json)
23: KONIEC
```

Pomiar został podzielony na etapy, aby możliwe było oddzielenie kosztu inicjalizacji modelu od kosztu właściwego procesu rekonstrukcji. Osobno rejestrowano czas wczytywania obrazów, inferencji, przetwarzania wyniku oraz eksportu rekonstrukcji do pliku. Nie stosowano dodatkowego dopasowywania modeli pod kątem wydajnościowym, to znaczy przyjęto domyślne, proponowane przez twórców wartości parametrów rekonstrukcyjnych, zaczerpnięte z dostępnych interfejsów UI lub plików README, których szczegółowe przedstawienie znajduje się w załączniku 4.

Tak opracowane skrypty zostały następnie wykorzystane w ramach skryptów grupowych, które wprowadzały dodatkową warstwę organizacji procesu testowego. Ich zadaniem było automatyczne uruchamianie właściwych skryptów rekonstrukcyjnych dla kolejnych scen oraz scenariuszy eksperymentalnych. Dla każdego przypadku testowego, tj. jednego scenariusza dla jednej sceny, wykonywano trzy przebiegi testowe. Takie podejście miało na celu ograniczenie wpływu losowych wahań działania

systemu oraz potencjalnego efektu zimnego startu na końcowe wyniki pomiarów. Jako docelową wartość z testów przyjmowano medianę. Ostatnim wartym wspomnienia aspektem procesu było zastosowanie stałej 30-sekundowej przerwy między kolejnymi testami. Przerwa ta miała charakter praktyczny i miała sprzyjać zwolnieniu zasobów oraz częściowemu ustabilizowaniu pracy GPU.

Pomocnicze skrypty podsumowujące

Ich celem jest przekształcenie wielu pojedynczych wyników w uporządkowane tabele, które następnie wykorzystano do analizy. Zestawienie skryptów przedstawiono w tabeli 4.

Tabela 4. Zestawienie skryptów wykorzystanych do agregacji wyników eksperymentów. Źródło: opracowanie własne.

Skrypt	Rola	Efekt
export_results_xlsx.py	Zbiera wyniki zapisane dla jednej metody i tworzy uporządkowane zestawienie testów.	Plik Excel zawierający wyniki wielu testów jednej metody
merge_model_summaries_xlsx.py	Łączy arkusze wynikowe VGGT, MAST3R i MapAnything w jeden wspólny raport porównawczy	Zbiór plików umożliwiający porównanie metod między scenami, scenariuszami i zbiorami danych.

Opisane skrypty oraz sposób organizacji wyników stanowiły podstawę do przeprowadzenia właściwej analizy eksperymentów. Dzięki tak wykonanej automatyzacji procesu możliwe było porównanie badanych metod w spójnych warunkach oraz ograniczenie wpływu ręcznych operacji na wyniki testów. Na tej podstawie w kolejnym podrozdziale omówiono różnice pomiędzy badanymi modelami pod względem czasu rekonstrukcji oraz zapotrzebowania na zasoby sprzętowe.

Dobór obrazów do scenariuszy badawczych

Charakter oraz sposób pozyskania ujęć różniły się w zależności od wykorzystywanego zbioru danych. Poszczególne sceny cechowały się odmiennym rozmieszczeniem punktów obserwacji, stopniem nakładania się obrazów oraz liczbą dostępnych fotografii. Z tego względu przyjęto zestaw zasad, którymi kierowano się podczas doboru obrazów.

Każda ze zbadanych w ramach pracy scen składała się z co najmniej ośmiu fotografii. W przypadkach, w których dostępna była większa liczba ujęć, w pierwszej kolejności ręcznie wyznaczano bazowy zestaw ośmiu obrazów, stanowiący podstawę do utworzenia kolejnych scenariuszy badawczych. Podczas doboru dążono do zachowania kompromisu pomiędzy częściowym pokryciem obserwowanych fragmentów sceny a odpowiednim zróżnicowaniem perspektyw. Ujęcia wybierano w taki sposób, aby zachować przynajmniej częściowe wspólne pole widzenia pomiędzy fotografiami, a jednocześnie uniknąć obrazów przedstawiających scenę z niemal identycznej perspektywy. Przyjęta procedura miała zapewnić zarówno ciągłość informacji pomiędzy widokami, jak i odpowiednie zróżnicowanie geometryczne zestawu wejściowego. Na podstawie utworzonego zestawu bazowego dla każdej sceny przygotowano cztery warianty danych wejściowych, obejmujące odpowiednio jeden,

dwa, cztery oraz osiem obrazów. Zestawy te miały charakter zagnieżdżony, przy czym każdy wariant stanowił podzbiór wariantu bezpośrednio większego. Zależność tę można zapisać jako:

$$I_1 \subset I_2 \subset I_4 \subset I_8$$

gdzie I_n oznacza zbiór obrazów wykorzystanych w scenariuszu obejmującym n ujęć wejściowych. Oznacza to, że zwiększanie liczby obrazów odbywało się poprzez dodawanie kolejnych widoków przy zachowaniu wszystkich fotografii wykorzystanych w scenariuszu poprzednim. Takie podejście pozwalało analizować zmiany zachodzące wraz ze wzrostem liczby dostępnych obrazów bez jednoczesnej wymiany wcześniej wykorzystanych ujęć. W przypadku zbioru autorskiego oraz LLFF analizę przeprowadzono z wykorzystaniem pełnego dostępnego zestawu scen. Dla zbioru ETH3D wykorzystano natomiast wyłącznie podzbiór testowy (*test*)¹.

Należy jednak uwzględnić, że jakość uzyskiwanej rekonstrukcji może zależeć nie tylko od liczby obrazów wejściowych, lecz również od doboru konkretnych perspektyw. Zastosowanie pojedynczego zestawu dla każdego scenariusza nie pozwala zatem całkowicie rozdzielić wpływu obu tych czynników. Z tego względu w dalszej części pracy przeprowadzono dodatkowy eksperyment wykorzystujący alternatywne warianty zestawów dwu-i czteroobrazowych, którego wyniki omówiono w sekcji 5.3.

5.2 Analiza wydajnościowa

W niniejszej sekcji przedstawiono analizę oraz porównanie wyników testów przeprowadzonych z wykorzystaniem wybranych metod rekonstrukcji trójwymiarowej. Celem tej części pracy jest ocena praktycznego zachowania badanych modeli w identycznych warunkach testowych, ze szczególnym uwzględnieniem czasu działania oraz zapotrzebowania na zasoby sprzętowe. Analizie poddano wyniki uzyskane dla scenariuszy obejmujących różną liczbę obrazów wejściowych, co pozwala określić, jak zwiększenie liczby widoków wpływa na koszt obliczeniowy poszczególnych metod. Zestawienie wyników obejmuje łącznie 418 zagregowanych przypadków testowych, w tym po 152 dla metod MapAnything i VGGT oraz 114 dla metody MAST3R. Różnica ta wynika z pominięcia scenariusza jednoobrazowego dla MAST3R, którego mechanika działania opiera się na analizie relacji pomiędzy co najmniej dwoma widokami tej samej sceny. Porównanie obejmuje przede wszystkim metryki wydajnościowe. Podczas testów uwzględniono wiele parametrów pomiarowych, w tym czas rekonstrukcji, maksymalne wykorzystanie pamięci RAM oraz maksymalne wykorzystanie pamięci VRAM. Pozwalają one ocenić kluczowe aspekty funkcjonowania modeli, takie jak szybkość działania czy ich wymagania sprzętowe, ale także skalowalność w przypadku masowej rekonstrukcji na podstawie ograniczonej próbki danych.

¹Ze zbioru ETH3D pominięto scenę *door*, ponieważ obejmuje ona jedynie siedem fotografii, co uniemożliwiało zastosowanie przyjętego w pracy scenariusza ośmioobrazowego.

Czas rekonstrukcji


Czas rekonstrukcji stanowi podstawową metrykę opisującą praktyczną użyteczność analizowanych metod. Obejmuje on proces wykonania pojedynczego przypadku testowego, a więc wczytanie danych wejściowych, przygotowanie obrazów, uruchomienie właściwego modelu, przetwarzanie otrzymanego wyniku oraz zapis rekonstrukcji do pliku. Metryka ta opisuje praktyczny czas wykonania pojedynczej rekonstrukcji po wcześniejszym załadowaniu modelu do pamięci. Czas inicjalizacji i ładowania modelu traktowano jako jednorazowy koszt poprzedzający właściwy proces rekonstrukcji. W ramach testów mierzono również **czas inferencji**, który odnosi się do właściwego etapu działania modelu, czyli momentu, w którym przygotowane dane wejściowe są przetwarzane przez sieć neuronową. Wydzielenie tej wartości umożliwia dokładniejszą ocenę kosztu obliczeniowego modelu, niezależnie od dodatkowych operacji wykonywanych przez skrypt, takich jak konwersja formatów, eksport pliku czy przetwarzanie pomocniczych struktur danych. Należy jednak zaznaczyć, że w opracowanych skryptach pojęcie inferencji nie ma identycznego znaczenia dla wszystkich modeli. Na potrzeby niniejszej pracy jako inferencję przyjęto zasadniczy etap obliczeniowy rekonstrukcji dostępny w ramach API stworzonego przez twórców danego modelu. W przypadku VGGT i MapAnything oznacza on przede wszystkim główny etap predykcji modelu, w którym na podstawie przygotowanych obrazów generowane są informacje geometryczne niezbędne do dalszej rekonstrukcji sceny. Nie jest to jednak pełny proces rekonstrukcyjny, ponieważ po tym etapie wykonywane są jeszcze przetwarzanie końcowe oraz eksport wyniku, przy czym obie fazy mierzono osobno. W przypadku MAST3R etap nazwany inferencją ma szerszy zakres, ponieważ obejmuje nie tylko predykcję modelu, ale również istotne elementy procesu rekonstrukcyjnego. Zatem różnica w znaczeniu etapu „inferencja” jest konsekwencją struktur wdrożeniowych modeli i z tego powodu główną metryką porównawczą przyjętą w pracy jest czas rekonstrukcji. Wyniki przedstawiono w tabeli 5.

Tabela 5. Tabela przedstawiająca średni czas rekonstrukcji oraz średni czas inferencji przy zastosowaniu różnej liczby zdjęć źródłowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne.

a) Czas rekonstrukcji (s)			
Liczba zdjęć	VGGT	MapAnything	MASt3R
1	0,78	0,67	-
2	1,31	1,36	9,46
4	2,37	2,88	19,55
8	6,07	5,92	54,24
b) Czas inferencji (s)			
Liczba zdjęć	VGGT	MapAnything	MASt3R
1	0,28	0,27	-
2	0,38	0,50	8,02
4	0,60	1,01	16,83
8	2,65	1,99	49,02

Analiza wyników pozwala sformułować dwa podstawowe wnioski. Po pierwsze, zwiększenie liczby obrazów wejściowych prowadzi w przypadku każdego z analizowanych modeli do wydłużenia


czasu rekonstrukcji, choć skala tego wzrostu różni się pomiędzy metodami. Po drugie, MAST3R charakteryzuje się zdecydowanie dłuższym czasem działania niż VGGT i MapAnything. Wzrost czasu rekonstrukcji wraz z liczbą wykorzystanych obrazów jest zjawiskiem oczekiwanym, ponieważ większy zbiór wejściowy oznacza większą ilość danych wymagających przetworzenia oraz wzajemnego porównania. Otrzymane wyniki pokazują jednak, że na tempo tego wzrostu istotnie wpływa również architektura poszczególnych modeli. Jak opisano w rozdziale 3.2, MAST3R bazuje na architekturze wywodzącej się z modelu DUST3R, w której podstawową jednostkę przetwarzania stanowi para obrazów. Dla każdej pary wyznaczane są niezależne dopasowania oraz lokalne predykcje geometrii, które następnie muszą zostać połączone w spójną rekonstrukcję w procesie globalnego wyrównania (ang. *global alignment*). W konsekwencji koszt obliczeniowy MAST3R rośnie wraz z liczbą zdjęć znacznie szybciej niż w przypadku modeli VGGT i MapAnything. Metody te zaprojektowano do bezpośredniego przetwarzania wielu obrazów w pojedynczym przebiegu i w ramach przeprowadzonych badań osiągały zbliżone wyniki. Jednocześnie MAST3R, wykorzystujący odmienny sposób przetwarzania danych, był w porównywalnych scenariuszach około **siedmiu do dziewięciu razy wolniejszy**. Różnice te zobrazowano na rysunku 8.



Rysunek 8. Wykresy przedstawiające uśrednione czasy rekonstrukcji oraz czasy inferencji przy zastosowaniu różnej liczby zdjęć źródłowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.

Wyniki pokazują, że VGGT i MapAnything znacznie lepiej odpowiadają zastosowaniom wymagającym szybkiej rekonstrukcji. Różnice pomiędzy nimi są relatywnie niewielkie, podczas gdy MAST3R wyróżnia się zdecydowanie wyższym kosztem czasowym. Przy ośmiu obrazach rekonstrukcja trwa około 54 s, podczas gdy pozostałe metody kończą ją w około 6 s. Ponadto wzrost czasu pomiędzy wariantami obejmującymi cztery i osiem obrazów sugeruje, że zwiększanie liczby danych wejściowych nie prowadzi wyłącznie do liniowego wzrostu kosztu. Efekt ten jest szczególnie widoczny w przypadku MAST3R, lecz można go zaobserwować również dla VGGT i MapAnything, jednak ze względu na ograniczoną liczbę analizowanych wariantów wnioszek dotyczący dokładnego charakteru tego trendu należy traktować ostrożnie.

Dodatkowym wartym wymienienia aspektem testów jest udział inferencji w procesie rekonstrukcyjnym. W przypadku MapAnything inferencja stanowiła od około 33,6% do 40,3% całego procesu, natomiast dla VGGT jej udział mieścił się w zakresie od 25,3% do 43,7%. Oznacza to, że większa część czasu działania tych metod była związana z pozostałymi etapami procesu. Odminną charakterystykę zaobserwowano dla MAST3R. Inferencja odpowiadała za około 84,8% czasu rekonstrukcji dla dwóch obrazów, 86,1% dla czterech oraz 90,4% dla ośmiu obrazów. Jak zobrazowano na rys. 9, udział inferencji w czasie rekonstrukcji różnił się również w zależności od źródła danych.



Rysunek 9. Wpływ źródła danych na czas rekonstrukcji modelu MapAnything dla poszczególnych scenariuszy. Przeciętna rekonstrukcja sceny z autorskiego zestawu dla scenariusza z 8 obrazami zajmowała około dwukrotnie dłużej niż przeciętna scena ze zbioru LLFF przy takiej samej liczbie zdjęć. Źródło: opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.

Dla każdej z badanych metod najwyższy średni czas rekonstrukcji odnotowano dla zbioru autorskiego, natomiast najniższy zazwyczaj dla LLFF. Zależność ta była szczególnie wyraźna w przypadku MapAnything i VGGT, dla których inferencja stanowiła przeciętnie mniej niż połowę czasu przetwarzania. Sugeruje to, że obrazy ze zbioru autorskiego generowały większy narzut związany z dodatkowymi operacjami na danych. Jednym z czynników mogących wpływać na ten efekt był rozmiar plików wejściowych. Obrazy ze zbioru LLFF charakteryzowały się przeciętnie najmniejszą objętością i jednocześnie prowadziły do najkrótszych czasów działania we wszystkich trzech modelach. Zależność ta nie była jednak jednoznaczna, ponieważ różnice w czasie rekonstrukcji pomiędzy zbiorem ETH3D a zbiorem autorskim pozostawały widoczne mimo zbliżonych rozmiarów plików źródłowych.

Oznacza to, że w tym przypadku istotną rolę mogły odegrać inne właściwości obrazów, takie jak ich rozdzielczość, stopień kompresji, proporcje kadru lub koszt wykonywanych transformacji.


Zużycie pamięci VRAM

W przypadku współczesnych modeli rekonstrukcji 3D opartych na głębokim uczeniu maksymalne zużycie pamięci VRAM jest jedną z najważniejszych praktycznych metryk modelu. To właśnie ilość dostępnej pamięci karty graficznej często decyduje o tym, czy dany model można uruchomić dla określonej liczby zdjęć lub czy wysoka rozdzielczość zdjęć nie będzie wymagała przeskalowania ich w dół. Wyniki testów przedstawiono w tabeli 6 oraz na rysunku 10.

Tabela 6. Tabela przedstawiająca średnią wartość maksymalnej przypisanej pamięci VRAM w MiB przy zastosowaniu różnej liczby zdjęć źródłowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne.

Liczba zdjęć	VGGT	MapAnything	MASt3R
1	7170,665	7269,765	-
2	7464,749	7344,451	3134,445
4	8188,600	7493,821	3220,458
8	9824,801	7792,562	3221,563

Widoczne są trzy wyraźnie różne charakterystyki wykorzystania pamięci VRAM. Największe zapotrzebowanie wykazuje VGGT, którego szczytowa alokacja rośnie wraz z liczbą obrazów z około 7,0 GiB dla jednego obrazu do około 9,6 GiB dla ośmiu obrazów. Oznacza to wzrost o około 40%.



Rysunek 10. Wykres przedstawiający średnią maksymalną ilość przypisanej pamięci VRAM przy zastosowaniu różnej liczby zdjęć źródłowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.

Szczególnie wyraźne zwiększenie zużycia pamięci występuje między czterema a ośmioma obrazami, co może sugerować podobny wzrost przy wykorzystaniu większej liczby obrazów źródłowych. Jeżeli założyć utrzymanie tego tempa wzrostu, pamięć VRAM mogłaby się okazać wąskim gardłem przy użyciu konsumenckich jednostek GPU. MapAnything rozpoczyna od podobnego poziomu jak VGGT, jednak wraz ze zwiększaniem liczby obrazów jego zapotrzebowanie rośnie znacznie wolniej. Dla ośmiu obrazów osiąga około 7,6 GiB, a więc tylko o około 0,5 GiB więcej niż dla pojedynczego obrazu. Model ma zatem, podobnie do omawianego poprzednika, stosunkowo wysoki koszt bazowy, wynikający między innymi z rozmiaru samej sieci i jej komponentów, ale lepiej skaluje się pamięciowo przy dodawaniu kolejnych widoków. Przy ośmiu obrazach wykorzystuje około 2 GiB mniej pamięci niż VGGT. Najniższe zużycie VRAM wykazał MAST3R, nieco ponad 3,0 GiB we wszystkich badanych scenariuszach. W efekcie wspomnianej powyżej architektury pary obrazów są kolejno obsługiwane, co pozwala na niemal stałą wartość przypisaną pamięci. W przypadku pamięci VRAM wpływ zbioru danych był niewielki. Wykonane testy nie wykazały znacznych różnic w zapotrzebowaniu na pamięć karty graficznej.

Zużycie pamięci RAM

Ostatnim analizowanym aspektem wydajności jest wykorzystanie pamięci operacyjnej RAM. W przeciwieństwie do pamięci VRAM wykorzystywanej przede wszystkim do przechowywania danych i wykonywania operacji związanych z obliczeniami na GPU, pamięć RAM służy między innymi do przechowywania danych wejściowych, parametrów i danych pośrednich wykorzystywanych przez poszczególne etapy procesu. W analizie wykorzystania pamięci RAM zastosowano dwie uzupełniające się metryki:

1. **Całkowite maksymalne zużycie** — określa najwyższą zarejestrowaną wartość wykorzystania pamięci RAM w ramach całego procesu, z uwzględnieniem etapu inicjalizacji i ładowania modelu.
2. **Średnie maksymalne zużycie w czasie rekonstrukcji** — określa średnią wartość szczytowego wykorzystania pamięci RAM rejestrowanego podczas wykonywania poszczególnych rekonstrukcji, bez uwzględniania jednorazowego kosztu inicjalizacji modelu.

Zastosowanie dwóch metryk umożliwia rozdzielenie stałego kosztu pamięciowego związanego z inicjalizacją i utrzymaniem modelu od zapotrzebowania wynikającego z właściwego procesu rekonstrukcji. Pozwala to zarówno określić całkowite wymagania sprzętowe danej metody, jak i dokładniej ocenić wpływ liczby obrazów wejściowych na wykorzystanie pamięci RAM podczas przetwarzania.

Wyniki przeprowadzonych testów wskazują, że całkowite maksymalne zużycie pamięci RAM było w niewielkim stopniu zależne od liczby obrazów wejściowych. Największe zapotrzebowanie odnotowano dla modeli VGGT i MapAnything, dla których wartości pozostawały praktycznie stałe we wszystkich analizowanych scenariuszach i wynosiły około 10 GiB. Wyraźnie mniejsze zużycie

zaobserwowano w przypadku MAST3R, osiągającego niespełna 6 GiB, przy czym również dla tego modelu zwiększenie liczby obrazów z dwóch do ośmiu nie powodowało zauważalnego wzrostu wartości. Szczegółowe dane przedstawiono w tabeli 7.

Tabela 7. Średnie maksymalne wykorzystanie pamięci RAM w MiB w ramach całego procesu dla testowanych modeli i poszczególnych scenariuszy liczby obrazów wejściowych. Źródło: opracowanie własne.

Liczba zdjęć	VGGT	MapAnything	MASt3R
1	10327,659	10316,781	-
2	10327,740	10317,312	5976,504
4	10327,696	10317,083	5976,959
8	10324,988	10317,670	5976,009

Otrzymane wyniki sugerują zatem, że w przypadku niewielkiej liczby zdjęć wejściowych zasadniczą część zapotrzebowania na pamięć RAM stanowi koszt związany z inicjalizacją i utrzymaniem modelu, podczas gdy liczba przetwarzanych obrazów ma jedynie niewielki wpływ na maksymalne wykorzystanie pamięci. Zależność ta staje się jeszcze wyraźniejsza po zestawieniu tych wartości ze zużyciem pamięci rejestrowanym podczas właściwego procesu rekonstrukcji, przedstawionym w tabeli 8.


Tabela 8. Średnia wartość maksymalnej przypisanej pamięci RAM w MiB w trakcie wykonywania rekonstrukcji przy zastosowaniu różnej liczby zdjęć wejściowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne.

Liczba zdjęć	VGGT	MapAnything	MASt3R
1	1874,598	2354,843	-
2	1815,824	2436,093	1778,243
4	1834,175	2626,186	1808,332
8	1882,558	3079,631	1844,395

Najbardziej stabilnymi wymaganiami charakteryzowały się VGGT i MAST3R. Dla VGGT wartość pozostawała na poziomie około 1,8 GiB niezależnie od liczby obrazów wejściowych. Również w przypadku MAST3R zaobserwowano jedynie niewielki wzrost, z około 1,74 GiB dla dwóch obrazów do około 1,8 GiB dla ośmiu obrazów. Odminną charakterystykę wykazał MapAnything, dla którego szczytowe wykorzystanie RAM wzrosło z około 2,3 GiB do 3,0 GiB. Model ten wykorzystywał zatem najwięcej pamięci operacyjnej we wszystkich badanych scenariuszach, a różnica względem pozostałych metod zwiększała się wraz z liczbą obrazów.

Kolejnym analizowanym aspektem było wykorzystanie pamięci RAM podczas rekonstrukcji w zależności od liczby obrazów wejściowych oraz zastosowanego zbioru danych. Poszczególne modele wykazywały przy tym odmienne profile wykorzystania pamięci. Analogicznie do wyników dotyczących czasu rekonstrukcji najniższe wartości uzyskiwano zazwyczaj dla zbioru LLFF, średnie dla ETH3D, natomiast najwyższe dla zbioru autorskiego. Zależność ta była szczególnie wyraźna w przypadku MapAnything. Stabilny charakter wykorzystania pamięci RAM przez MAST3R utrzymał się również w trakcie porównania na podstawie źródła; model wykazywał jedynie niewielkie, regularne różnice w zależności od zbioru danych. W przypadku VGGT wartości nie zmieniały się monotonicznie,

początkowo następował ich spadek, a następnie niewielki wzrost dla czterech i ośmiu obrazów. Skala tych wahań pozostawała jednak stosunkowo mała, dlatego nie wskazuje ona na istotną niestabilność pamięciową modelu. Najsilniejszą zależność od liczby obrazów zaobserwowano dla MapAnything. Model ten już w scenariuszu z jednym obrazem wykazywał najwyższe zapotrzebowanie na pamięć RAM spośród metod obsługujących taki wariant, a wraz ze wzrostem liczby wejść jego wykorzystanie pamięci zwiększało się wyraźniej niż w przypadku konkurencyjnych modeli. Wyniki zobrazowano na rys. 11.



Rysunek 11. Każdy z modeli charakteryzował się innym profilem dystrybucji dostępnej pamięci RAM w zależności od źródła danych. Źródło: opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.

Reasumując, zapotrzebowanie na pamięć RAM podczas samej rekonstrukcji pozostaje niewielkie, jednak to podczas inicjalizacji modeli obserwowane są największe wartości, sięgające około 10 GiB. Mimo że nie stanowi to istotnego ograniczenia dla współczesnych komputerów klasy konsumenckiej, wynik ten należy uwzględnić przy wyborze metody przeznaczonej do testów w określonym środowisku sprzętowym.

Podsumowanie

Podsumowanie przeprowadzonej analizy wskazuje, że najlepsze wyniki pod względem czasu rekonstrukcji uzyskały modele VGGT oraz MapAnything. Po uwzględnieniu również zapotrzebowania na pamięć RAM i VRAM najbardziej zrównoważonym rozwiązaniem okazał się jednak MapAnything. Model ten łączy krótki czas rekonstrukcji z relatywnie niewielkim wzrostem zużycia pamięci VRAM oraz umiarkowanym zapotrzebowaniem na pamięć RAM, które pozostaje porównywalne z wartościami odnotowanymi dla pozostałych metod.

MASt3R charakteryzował się najniższym i najbardziej stabilnym wykorzystaniem pamięci VRAM, jednak przewaga ta była okupiona wielokrotnie dłuższym czasem działania. Z tego względu model może stanowić korzystne rozwiązanie w środowiskach o ograniczonych zasobach pamięci GPU, gdy krótki czas wykonywania rekonstrukcji nie jest wymagany.

Uzyskane wyniki wskazują zatem na wyraźny kompromis pomiędzy czasem przetwarzania a zapotrzebowaniem na zasoby pamięciowe. To właśnie charakter tego kompromisu może być uznany za jeden z kluczowych czynników przy wyborze modelu z perspektywy wydajnościowej. Należy jednak podkreślić, że przedstawione zależności odnoszą się wyłącznie do badanego zakresu liczby obrazów wejściowych oraz zastosowanego środowiska sprzętowego. W przypadku rekonstrukcji wykonywanej na podstawie większych zbiorów danych lub z wykorzystaniem wydajniejszych jednostek obliczeniowych relacje pomiędzy analizowanymi metodami mogą ulec zmianie.

5.3 Analiza jakościowa

Ocena jakości wygenerowanych rekonstrukcji 3D stanowi istotny element porównania metod stosowanych w tym obszarze. Jednym z podstawowych kierunków ich rozwoju jest zwiększanie dokładności, tak aby uzyskana rekonstrukcja możliwie wiernie i szczegółowo odwzorowywała rzeczywistą scenę. Przeprowadzenie rzetelnej analizy rezultatów nie zawsze jest jednak możliwe, ponieważ wymaga dostępu do obiektywnego punktu odniesienia, z którym można je porównać. Takie dane referencyjne, określane również angielskim terminem *ground truth* (GT), mogą przyjmować różne formy zależnie od charakteru analizowanego zadania. W przypadku metod omawianych w niniejszej pracy powinny one przede wszystkim opisywać rzeczywistą geometrię badanej sceny. Dane tego rodzaju pozyskuje się zazwyczaj za pomocą precyzyjnych urządzeń pomiarowych, takich jak skanery laserowe. Ze względu na przyjęte założenia pracy referencyjne dane geometryczne nie były dostępne ani dla autorskiego zbioru scen, ani dla zbioru LLFF². W ramach pracy podjęto również próbę utworzenia tak zwanego *pseudo-ground truth* (PGT), czyli przybliżonych danych referencyjnych wygenerowanych za pomocą powszechnie stosowanej metody rekonstrukcji. W tym celu wykorzystano program COLMAP, który miał posłużyć do utworzenia możliwie kompletnej geometrii scen na podstawie pełnych zestawów obrazów. Uzyskane rezultaty okazały się jednak zbyt niekompletne i niestabilne, aby mogły stanowić wiarygodny punkt odniesienia dla badanych metod. Z tego względu otrzymane PGT nie zostały wykorzystane w dalszej analizie.

Brak geometrycznych danych referencyjnych sprawił zatem, że niniejszą sekcję poświęcono opisowej analizie wizualnej zachowania badanych metod na wykorzystanym zbiorze scen, a nie pomiarowi ich dokładności geometrycznej. Aby ograniczyć arbitralność takiej oceny oraz zapewnić możliwie jednolite warunki porównania poszczególnych metod, zastosowano ustrukturyzowaną skalę punktową opartą na czterech zdefiniowanych kryteriach. Każdą rekonstrukcję oceniano niezależnie pod względem: kompletności, spójności geometrycznej, obecności artefaktów i szumu oraz stopnia odwzorowania struktury i szczegółów sceny. Szczegóły zastosowanej metodologii opisano w dalszej części pracy.

²Zbiór ETH3D udostępnia referencyjną geometrię pozyskaną za pomocą skanera laserowego. Zdecydowano się jednak nie wykorzystywać jej w głównej analizie, aby zachować spójność warunków eksperymentalnych dla wszystkich badanych zbiorów i scen.

Przybliżone dane referencyjne

Wielokrotnie przywoływany w niniejszej pracy COLMAP, ze względu na swoją ugruntowaną pozycję, wysoką dokładność i szerokie wykorzystanie w badaniach naukowych, może stanowić źródło przybliżonych danych referencyjnych. Wobec braku takich danych, między innymi dla autorskiego zbioru scen, zdecydowano się zbadać możliwość ich przybliżonego utworzenia za jego pomocą. Założono, że dla każdej sceny pełny dostępny zestaw obrazów zostanie wykorzystany do wygenerowania możliwie kompletnej rekonstrukcji. Otrzymany model miał następnie stanowić punkt odniesienia dla rezultatów VGGT, MAST3R i MapAnything uzyskanych na podstawie jednego, dwóch, czterech oraz ośmiu obrazów. Próby wykazały jednak, że wygenerowane rekonstrukcje nie osiągały jakości pozwalającej na traktowanie ich jako wiarygodnego PGT. W przypadku części scen nie wszystkie fotografie mogły zostać poprawnie zarejestrowane, natomiast uzyskiwane gęste chmury punktów pozostawały niekompletne i obejmowały jedynie wybrane fragmenty sceny. Jakość wyników była silnie zależna od charakterystyki konkretnej sceny, co uniemożliwiało zachowanie porównywalnych warunków oceny. Jedną z głównych przyczyn tych problemów była ograniczona liczba obrazów źródłowych. Większość scen z autorskiego zbioru obejmowała jedynie osiem fotografii, co zapewniało stosunkowo niewielką powtarzalność obserwacji w porównaniu ze zbiorami typowo wykorzystywanymi do klasycznej rekonstrukcji SfM i MVS. W połączeniu z trudnymi warunkami panującymi w niektórych scenach prowadziło to do niepełnych i niestabilnych rezultatów.

Dodatkową trudność stanowiło wyrównanie rekonstrukcji pochodzących z różnych metod. Wyniki testowanych modeli były generowane w odmiennych układach współrzędnych, skalach i orientacjach, dlatego ich bezpośrednie porównanie wymagało zastosowania odpowiedniej transformacji. W przypadku niekompletnych i zaszumionych rekonstrukcji pełniących funkcję PGT proces ten nie gwarantował uzyskania jednoznacznego dopasowania. W konsekwencji różnice wynikające z niedokładnego wyrównania mogłyby wpłynąć na wartości obliczanych metryk i zostać błędnie zinterpretowane jako niedokładność analizowanych metod. W następstwie powyższych problemów zrezygnowano z oceny jakości względem rekonstrukcji utworzonej przez COLMAP.

Metodologia oceny wizualnej

Ponieważ w ramach przeprowadzonych badań nie wykorzystano danych referencyjnych do ilościowego określenia dokładności geometrycznej, niniejszą analizę jakościową oparto na ustrukturyzowanej inspekcji wizualnej. Uwzględniono cztery aspekty rekonstrukcji: **kompletność**, określającą stopień odtworzenia istotnych elementów sceny widocznych na obrazach wejściowych; **spójność geometryczną**, odnoszącą się do poprawności wzajemnego położenia, proporcji i ciągłości odtworzonych struktur; **obecność artefaktów i szumu**, obejmującą między innymi punkty odstające, zdublowane elementy oraz lokalne rozwarstwienia; a także **odzworowanie struktury i szczegółów**, opisujące stopień zachowania zarówno głównych elementów sceny, jak i jej drobniejszych cech. Na potrzeby analizy opracowano jednolitą skalę punktową dla wszystkich wymienionych kryteriów, której zastosowanie miało na celu ograniczenie subiektywności oraz zapewnienie spójnych warunków porównania

analizowanych metod. Dla każdego kryterium przyznawano od 0 do 3 punktów, gdzie wartość 0 odpowiadała najniższemu poziomowi jakości w danym aspekcie, natomiast wartość 3 oznaczała jego bardzo dobre spełnienie. Łączny wynik rekonstrukcji mógł zatem wynosić od 0 do 12 punktów:

$$Q = C + G + A + D$$

gdzie Q oznacza łączny wynik rekonstrukcji, C — ocenę kompletności, G — spójność geometryczną, A — artefakty i szum, natomiast D — odwzorowanie struktury i szczegółów. Dokładną interpretację poszczególnych wartości przedstawiono w tabeli 9.

Tabela 9. Skala zastosowana do jakościowej oceny rekonstrukcji. Źródło: opracowanie własne.

Kryterium	0 pkt	1 pkt	2 pkt	3 pkt
Kompletność	Brak użytecznej rekonstrukcji lub jedynie pojedyncze fragmenty.	Zrekonstruowano niewielką część sceny; występują duże braki.	Większość istotnych elementów jest obecna, lecz widoczne są zauważalne braki.	Obecne są praktycznie wszystkie istotne elementy widoczne na obrazach wejściowych.
Spójność geometryczna	Brak możliwości rozpoznania spójnej struktury przestrzennej.	Liczne i poważne deformacje, przesunięcia lub rozwarstwienia.	Ogólna geometria jest poprawna, lecz występują lokalne deformacje lub nie-spójności.	Proporcje i wzajemne położenie elementów są wizualnie spójne.
Artefakty i szum	Artefakty dominują nad właściwą rekonstrukcją.	Występują liczne punkty odstające, zdublowane struktury lub inne poważne artefakty.	Artefakty są widoczne, lecz nie uniemożliwiają interpretacji rekonstrukcji.	Artefakty są nieliczne i mają marginalny wpływ na odbiór wyniku.
Struktura i szczegóły	Podstawowa struktura sceny jest nierozpoznawalna.	Rozpoznawalne są jedynie główne bryły lub najbardziej ogólny układ sceny.	Poprawnie odwzorowano główne elementy i część drobniejszych szczegółów.	Dobrze zachowano zarówno główne struktury, jak i drobniejsze elementy sceny.

Ocena kompletności C odnosiła się do zawartości widocznej na obrazach wejściowych, dlatego jej interpretacja zależała od liczby wykorzystanych widoków. Większa liczba fotografii mogła obejmować szerszy fragment sceny, a tym samym zwiększać zakres geometrii podlegającej ocenie. Z tego względu różnice wartości zagregowanego wyniku Q pomiędzy poszczególnymi scenariuszami testowymi nie stanowią bezwzględnej miary różnic w jakości rekonstrukcji.

Interaktywną inspekcję reprezentacji 3D przeprowadzono z możliwością swobodnej zmiany punktu obserwacji, obrotu oraz skali widoku. Wyniki porównywano z obrazami wejściowymi, bez wymuszania identycznej perspektywy ze względu na różnice w skali, orientacji i układach współrzędnych pomiędzy modelami. Globalnej translacji, rotacji i skali nie uwzględniano w ocenie; analizowano natomiast

wewnętrzne relacje geometryczne, takie jak wzajemne położenie, proporcje, ciągłość oraz lokalne deformacje i rozwarstwienia. Rekonstrukcje nie były poddawane dodatkowej obróbce. Wynik całkowity należy traktować wyłącznie jako pomocniczą ocenę jakości wizualnej, a nie miarę dokładności geometrycznej względem rzeczywistej sceny. Jak wspomniano w rozdziale 5.1, poszczególne modele uruchamiano z wykorzystaniem ich domyślnych konfiguracji, których szczegółowe zestawienie przedstawiono w załączniku 4. Dotyczyło to również sposobu filtrowania punktów na podstawie pewności predykcji (ang. *confidence*). W przypadku MapAnything filtrowanie to było domyślnie wyłączone, podczas gdy VGGT stosował globalny próg odpowiadający 50. percentylowi wartości pewności, a MAST3R próg równy 1,5. Podczas oceny wizualnej nie normalizowano tych różnic ani nie korygowano na ich podstawie przyznawanych ocen, ponieważ celem badania było porównanie rezultatów uzyskiwanych przez poszczególne metody w ich domyślnych konfiguracjach. Należy jednak uwzględnić, że odmienne mechanizmy filtrowania mogły wpływać na liczbę punktów zachowywanych w końcowej rekonstrukcji, a tym samym między innymi na ocenę jej kompletności oraz obecności artefaktów i szumu.

Pełne wyniki przeprowadzonej oceny, obejmujące wartości wszystkich kryteriów dla poszczególnych rekonstrukcji, udostępniono w repozytorium projektu, do którego odnośnik zamieszczono w załączniku 3. Natomiast tabela median oraz średnich dla każdego z kryteriów znajduje się w załączniku 6. W dalszej części analizy przedstawiono zagregowane zestawienia wyników w formie tabel oraz wybrane ilustracje prezentujące przypadki reprezentatywne dla obserwowanych zjawisk, natomiast szerszy zestaw przykładów rekonstrukcji zamieszczono w załączniku 7.

Rekonstrukcja na podstawie pojedynczego obrazu oraz wpływ liczby obrazów wejściowych

Wariant rekonstrukcji na podstawie pojedynczej fotografii naturalnie stanowił scenariusz najbardziej ograniczony pod względem ilości dostępnej informacji wejściowej, ponieważ geometria sceny musiała być wnioskowana bez możliwości wykorzystania zależności pomiędzy różnymi widokami. Nie przełożyło się to jednak na niższe wartości zagregowanego wyniku Q , jak przedstawiono w tabeli 10.

Tabela 10. Mediana i średnia zagregowanego wyniku jakościowego Q w zależności od liczby obrazów wejściowych. Źródło: opracowanie własne.

Model	Statystyka	1 obraz	2 obrazy	4 obrazy	8 obrazów
VGGT	Mediana Q	7,00	6,00	6,00	6,00
	Średnia Q	6,55	6,45	6,24	6,13
MASt3R	Mediana Q	-	6,00	6,00	6,00
	Średnia Q	-	6,11	6,08	6,00
MapAnything	Mediana Q	8,00	8,00	8,00	8,00
	Średnia Q	8,47	8,05	8,00	7,79

Pomimo ograniczonej ilości informacji wejściowej dla VGGT mediana wyniku Q wyniosła w tym wariancie 7 punktów, wobec 6 punktów dla wszystkich wariantów wieloobrazowych. Również średnia wartość Q , wynosząca 6,55, była najwyższa spośród analizowanych scenariuszy tego modelu. W przypadku MapAnything mediana utrzymywała się na poziomie 8 punktów niezależnie od liczby obrazów, natomiast najwyższą średnią, równą 8,47, uzyskano również dla pojedynczego obrazu.

Spośród dwóch modeli analizowanych w scenariuszu jednoobrazowym wyższe oceny uzyskiwał MapAnything. Jego rekonstrukcje zazwyczaj obejmowały większą część kadru i tworzyły zwartą chmurę punktów, umożliwiając rozpoznanie układu przestrzennego oraz podstawowego kształtu obiektów. Wyniki te nie zawsze były geometrycznie spójne, jednak ich kompletność i czytelność były na ogół zadowalające. VGGT również potrafił uzyskać rozpoznawalną strukturę przestrzenną, jednak jego wyniki znacznie częściej pozostawały niekompletne. Jedną z tendencji modelu, szerzej omówionych w kolejnych sekcjach, była skłonność do pomijania powierzchni trudnych do rekonstrukcji, co prowadziło do powstawania otworów w geometrii oraz zanikania całych fragmentów sceny. W skrajnych przypadkach rekonstrukcja była na tyle niepełna lub zdeformowana, że otrzymała najniższą ocenę w kryterium kompletności C . Nie oznaczało to jednak nieskuteczności modelu w scenariuszu jednoobrazowym. Jakość uzyskiwanych rezultatów była wyraźnie zależna od charakteru sceny, a w części przypadków zagregowany wynik jakościowy Q przekraczał 8 punktów, osiągając maksymalnie 10 punktów. Wybrane przykłady rekonstrukcji z pojedynczego obrazu zaprezentowano w załączniku 7.


Intuicyjnie można oczekiwać, że zwiększenie liczby obrazów wejściowych będzie sprzyjać poprawie rekonstrukcji, ponieważ kolejne ujęcia dostarczają dodatkowych informacji o geometrii i wyglądzie sceny. Wartości zagregowanego wyniku Q nie wykazały jednak takiej zależności, przy czym ich interpretacja wymaga uwzględnienia opisanego wcześniej sposobu oceny kompletności. Dla VGGT wartość Q zmniejszyła się z 6,55 punktu dla pojedynczego obrazu do 6,13 punktu dla ośmiu obrazów, natomiast dla MapAnything z 8,47 do 7,79 punktu. W przypadku MAST3R wartości pozostawały bardziej zbliżone, wyniosły bowiem 6,11 dla scenariusza dwuobrazowego oraz 6,00 dla ośmioobrazowego. Spadek ogólnego wyniku nie oznaczał jednak pogorszenia wszystkich aspektów rekonstrukcji. Jak przedstawiono w tabeli 11, wraz ze wzrostem liczby obrazów średnia ocena kompletności pozostawała na zbliżonym poziomie lub wzrastała, podczas gdy systematycznie malała ocena dotycząca artefaktów i szumu.

Tabela 11. Średnie oceny kompletności oraz artefaktów i szumu w zależności od liczby obrazów wejściowych. Źródło: opracowanie własne.

Model	Kryterium	1 obraz	2 obrazy	4 obrazy	8 obrazów
VGGT	Średnia C	1,11	1,24	1,24	1,24
	Średnia A	2,24	2,08	1,95	1,84
MASt3R	Średnia C	–	1,42	1,53	1,61
	Średnia A	–	1,76	1,53	1,37
MapAnything	Średnia C	2,34	2,42	2,47	2,47
	Średnia A	2,18	1,89	1,74	1,58

Wskazuje to, że wpływ zwiększania liczby obrazów wejściowych nie był jednakowy dla wszystkich ocenianych aspektów rekonstrukcji. Dodatkowe widoki mogły sprzyjać odtwarzaniu większego zakresu informacji dostępnej w obrazach wejściowych, lecz jednocześnie wiązały się ze wzrostem liczby niepożądanych elementów w uzyskiwanej geometrii. W rezultacie zwiększenie liczby obrazów nie prowadziło do jednoznacznego wzrostu zagregowanego wyniku Q.

W poszczególnych scenach efekt dodawania kolejnych widoków również był zróżnicowany. W części przypadków pozwalały one odtworzyć dodatkowe fragmenty geometrii, jednak nie zawsze poprawiały odwzorowanie elementów widocznych już wcześniej. Zwiększenie liczby obrazów wejściowych nie skutkowało więc poprawą wszystkich ocenianych aspektów rekonstrukcji. Przykład sceny, w której dodatkowe fotografie pozwoliły odtworzyć większy fragment geometrii, przedstawiono na rysunku 12, a kolejne przykłady zamieszczono w załączniku 7.



Rysunek 12. Przykład sceny obiektowej, dla której zaobserwowano wzrost oceny kompletności rekonstrukcji C wraz ze zwiększeniem liczby fotografii. W górnym rzędzie przedstawiono rekonstrukcje odpowiadające drugiemu scenariuszowi (dwa zdjęcia), natomiast w dolnym – trzeciemu scenariuszowi (cztery zdjęcia). W przypadku MAST3R wartość C wzrosła z 1 pkt do 2 pkt, natomiast dla MapAnything z 2 pkt do 3 pkt. Źródło: opracowanie własne.

W przypadku ograniczonej liczby dostępnych fotografii istotne znaczenie może mieć sposób ich akwizycji oraz dobór perspektyw. Charakter sceny oraz odpowiednie zaplanowanie procesu pozyskiwania obrazów mogą sprzyjać uzyskaniu kompletnej i spójnej rekonstrukcji.

Wpływ doboru perspektywy

W celu uzupełnienia analizy przeprowadzono dodatkowy eksperyment mający na celu ocenę wpływu doboru konkretnych perspektyw na jakość uzyskiwanych rekonstrukcji. Badanie wykonano na próbie dziewięciu scen, obejmującej po trzy sceny wybrane z każdego z badanych zbiorów. Dla każdej z nich przygotowano po dwa dodatkowe warianty zestawów dwu-i czteroobrazowych, zachowując przy tym tę samą ośmioobrazową pulę zdjęć wykorzystaną w eksperymencie głównym. Podstawowy zestaw obrazów wykorzystany w głównej części pracy oznaczono jako wariant A, natomiast dwa dodatkowo utworzone alternatywne zestawy jako warianty B i C. W obrębie każdego wariantu zachowano zasadę zagnieżdżenia, zgodnie z zależnością:

$$I_2^{(k)} \subset I_4^{(k)} \subset I_8, \quad k \in \{A, B, C\}$$

gdzie $I_2^{(k)}$ oraz $I_4^{(k)}$ oznaczają odpowiednio dwu-i czteroobrazowy zestaw wejściowy dla wariantu k , natomiast I_8 stanowi wspólny dla wszystkich wariantów zestaw ośmiu obrazów. Łącznie dla każdej analizowanej sceny porównano zatem trzy różne konfiguracje doboru ujęć dla scenariuszy dwu-i czteroobrazowych. Rekonstrukcje wykonane w ramach wariantów dodatkowych miały charakter wyłącznie uzupełniający i nie zostały uwzględnione w zagregowanych wynikach analizy wydajnościowej przedstawionych w poprzedniej części pracy.

Zestawienie średnich wartości oceny Q w tabeli 12 wskazuje, że wpływ zwiększenia liczby obrazów z dwóch do czterech nie był jednakowy dla wszystkich analizowanych metod, natomiast w przypadku części modeli pozostawał spójny niezależnie od zastosowanego wariantu doboru zdjęć. Dla VGGT we wszystkich trzech wariantach odnotowano wzrost średniej wartości Q , co sugeruje, że dodatkowe widoki przeważnie korzystnie wpływały na jakość rekonstrukcji tej metody. Odwrotną zależność zaobserwowano dla MapAnything, dla którego każdy z wariantów charakteryzował się niższą średnią oceną przy czterech obrazach. Najmniej jednoznaczne rezultaty uzyskano dla MAST3R. W wariantach A i B średnia wartość Q nieznacznie spadła, natomiast w wariacie C wzrosła. Oznacza to, że w przypadku tej metody wynik porównania dwóch i czterech obrazów był bardziej podatny na dobór konkretnych perspektyw.

Tabela 12. Średnie wartości sumarycznej oceny jakości Q dla rekonstrukcji wykorzystujących dwa i cztery obrazy wejściowe, z uwzględnieniem trzech wariantów doboru obrazów. Źródło: opracowanie własne.

Model	2 obrazy – A	4 obrazy – A	2 obrazy – B	4 obrazy – B	2 obrazy – C	4 obrazy – C
VGGT	5,89	6,56	6,00	6,44	6,00	6,78
MASt3R	6,22	6,00	6,11	5,78	6,00	6,44
MapAnything	8,67	8,33	8,44	8,22	8,67	8,00

Spośród 9 analizowanych scen w 6 zaobserwowano co najmniej jeden przypadek, w którym zastosowanie różnych wariantów doboru obrazów prowadziło do odmiennej wartości oceny Q. Pozostałe 3 sceny były natomiast całkowicie stabilne, tzn. dla każdego modelu i obu analizowanych liczebności wejścia warianty A, B i C uzyskiwały identyczne oceny. Na poziomie wszystkich 54 kombinacji scena-model-liczba obrazów identyczne wartości Q dla trzech wariantów wystąpiły w 37 przypadkach, czyli w 68,5% analizowanych zestawień. Jeszcze większą zgodność zaobserwowano przy analizie kierunku zmiany jakości po przejściu z dwóch do czterech obrazów. Spośród 27 kombinacji scena-model w 21 przypadkach, czyli 77,8%, wszystkie trzy warianty wskazywały ten sam kierunek zmiany: poprawę, pogorszenie albo brak. W kolejnych 5 przypadkach rozbieżność dotyczyła jedynie sytuacji, w której część wariantów wskazywała zmianę, a pozostałe brak zmiany. Faktyczne odwrócenie kierunku zależności, czyli jednoczesne wystąpienie poprawy dla jednego wariantu i pogorszenia dla innego, odnotowano tylko w 1 z 27 przypadków. Sugeruje to, że w ramach przeprowadzonych testów dodatkowych wariantów dobór konkretnych zdjęć jedynie sporadycznie prowadził do zmiany kierunku obserwowanej zależności pomiędzy scenariuszem dwu- i czteroobrazowym.


Wyniki potwierdzają zatem, że dobór konkretnych perspektyw może wpływać na ocenę rekonstrukcji i powinien być uwzględniany przy interpretacji wpływu liczby obrazów wejściowych. Dla VGGT we wszystkich analizowanych wariantach zwiększenie liczby obrazów wiązało się z poprawą ocen, natomiast dla MapAnything obserwowano ich pogorszenie. Najbardziej niejednoznaczne rezultaty uzyskano dla MAST3R, dla którego kierunek zmian zależał od wariantu doboru obrazów. Ze względu na ograniczoną liczbę wariantów oraz ich częściowo losowy sposób wyboru obserwacji tych nie należy jednak traktować jako ogólnych właściwości analizowanych metod, lecz jako dodatkową weryfikację stabilności wniosków sformułowanych w ramach przeprowadzonego eksperymentu.

Porównanie charakterystycznych zachowań modeli

Analiza uzyskanych rezultatów pozwoliła zidentyfikować kilka charakterystycznych tendencji w działaniu badanych modeli, dotyczących przede wszystkim kompromisu między kompletnością rekonstrukcji, spójnością geometrii oraz liczbą generowanych artefaktów.

VGGT najczęściej generował relatywnie zwarte i czytelne rekonstrukcje, zawierające mniej artefaktów i punktów odstających niż rezultaty pozostałych analizowanych metod. Jednocześnie jakość poszczególnych rezultatów była wyraźnie zróżnicowana — zagręgowana ocena Q mieściła się w zakresie od 3 do 10 punktów. W wielu przypadkach obserwowano pomijanie fragmentów jednolitych, jasnych lub refleksyjnych powierzchni, co prowadziło do powstawania rozległych ubytków w chmurze punktów. W scenach skoncentrowanych wokół pojedynczego obiektu model często rekonstruował przede wszystkim element centralny, częściowo pomijając otaczające go tło. Skutkowało to bardziej zwartą reprezentacją obiektu, lecz ograniczało kompletność w przypadkach, w których istotne było odtworzenie całego otoczenia. Odnotowano również pojedyncze przypadki poważnych błędów w estymacji rozmieszczenia kamer.

MapAnything uzyskiwał najwyższe oceny kompletności C spośród analizowanych modeli. Utworzone rekonstrukcje zazwyczaj obejmowały większą część sceny widocznej na obrazach źródłowych, a braki w obrębie obserwowanego fragmentu scenerii występowały rzadziej niż w przypadku VGGT. Model uzyskiwał relatywnie wysokie oceny odwzorowania struktury i szczegółów, co miało swoje odzwierciedlenie w najwyższym wyniku osiągniętym przez model, bowiem MapAnything okazał się jedynym spośród analizowanych modeli, dla którego odnotowano maksymalny możliwy wynik $Q = 12$. Taki wynik odnotowano dwukrotnie w scenariuszu jednoobrazowym, a przykład jednego z tych przypadków zobrazowano na rys. 13. Więcej przykładów rekonstrukcji na podstawie jednego ujęcia przedstawiono w załączniku 7. Przy interpretacji wspomnianych przewag należy jednak uwzględnić omówione wcześniej różnice w domyślnym filtrowaniu punktów na podstawie pewności predykcji. Jednocześnie wraz ze wzrostem liczby obrazów wejściowych obserwowano pogorszenie oceny artefaktów i szumu, a w niektórych wariantach wieloobrazowych występowało ponadto rozwarstwienie lub wzajemne przesunięcie fragmentów rekonstrukcji.



Rysunek 13. Przykład sceny wewnętrznej ze zbioru autorskiego. Ilustracja przedstawia przypadek, w którym MapAnything uzyskał maksymalną ocenę $Q = 12$. Jednocześnie widoczne jest charakterystyczne dla części rekonstrukcji VGGT pomijanie fragmentów sceny, co w tym przypadku przełożyło się na ocenę kompletności C równą 1 pkt. Źródło: opracowanie własne.

W przypadku MAST3R jednym z częściej obserwowanych problemów była integracja geometrii pochodzącej z wielu widoków. Model często rekonstruował znaczną część zawartości obrazów i uzyskiwał relatywnie dobre wyniki w zakresie odwzorowania struktury i szczegółów, przewyższając pod tym względem VGGT w analizowanych scenariuszach wieloobrazowych. Jednak poszczególne fragmenty rekonstrukcji nie zawsze były poprawnie łączone we wspólnym układzie współrzędnych, co objawiało się przesuniętymi powierzchniami oraz licznymi artefaktami. Zwiększanie liczby obrazów wejściowych nie przekładało się przy tym na systematyczną poprawę spójności geometrycznej rekonstrukcji. Średnia wartość kryterium G wynosiła odpowiednio 1,39, 1,42 i 1,39 dla dwóch, czterech i ośmiu obrazów, natomiast mediana we wszystkich wariantach pozostawała na poziomie 1 punktu. MAST3R był ponadto jedynym spośród analizowanych modeli, dla którego odnotowano przypadki całkowitego niepowodzenia rekonstrukcji, odpowiadające wartości $Q = 0$. Wszystkie dotyczyły sceny `exhibition_hall` ze zbioru ETH3D i wystąpiły w 2 badanych scenariuszach.

Wskazuje to, że w przypadku tej sceny samo zwiększenie liczby obrazów wejściowych nie było wystarczające do uzyskania poprawnej rekonstrukcji.

Kategoria sceny

W rozdziale 4.2 przedstawiono potencjalne problemy rekonstrukcyjne wynikające z kategorii, do jakiej daną scenę można przypisać. Na potrzeby niniejszej analizy wszystkie sceny należące do badanych zbiorów przyporządkowano do odpowiednich grup, a następnie wykorzystano ten podział do uzupełnienia analizy jakościowej o ocenę wyników w zależności od typu sceny. Ze względu na charakter przedstawianej zawartości wyróżniono cztery kategorie: sceny zewnętrzne, wewnętrzne, obiektowe oraz naturalne³. Dane uzupełniające dla niniejszej sekcji w postaci dodatkowych ilustracji scen z podziałem na analizowane kategorie zamieszczono w załączniku 7. Zestawienie wszystkich scen wraz z przypisanymi kategoriami przedstawiono w załączniku 5, a wyniki analizy w tabeli 13.

Tabela 13. Mediana i średnia oceny jakościowej Q uzyskane przez analizowane modele dla poszczególnych kategorii scen. Źródło: opracowanie własne.


Model	Naturalne	Zewnętrzne	Wewnętrzne	Obiektowe
VGGT – mediana Q	6	7,5	6	6
VGGT – średnia Q	6,36	7,31	5,77	6,19
MASt3R – mediana Q	5	7	6	6
MASt3R – średnia Q	5,43	7,04	5,51	6,37
MapAnything – mediana Q	7	9	8	8
MapAnything – średnia Q	6,93	8,75	8,25	8,06

Na podstawie uzyskanych ocen nie zaobserwowano wyraźnej specjalizacji któregośkolwiek z badanych modeli względem jednej określonej kategorii scen. Jednocześnie wyniki wskazują na pewne różnice pomiędzy kategoriami. Sceny zewnętrzne uzyskiwały relatywnie najwyższe oceny dla wszystkich analizowanych metod, natomiast w ujęciu zbiorczym najniższe wyniki odnotowano dla scen naturalnych. Zależności te nie miały jednak charakteru bezwzględnego, a w obrębie poszczególnych kategorii występowało zróżnicowanie jakości uzyskiwanych rekonstrukcji. Obserwacje wizualne wskazywały, że istotne znaczenie miały lokalne właściwości sceny, takie jak wyrazistość konturów, obecność tekstury, kontrast kolorystyczny, sposób oświetlenia, stopień przesłonięcia oraz odległość poszczególnych elementów od kamery.

Sceny zewnętrzne średnio uzyskały najwyższe oceny spośród wyróżnionych kategorii. Wyniki analizy wskazują, że zróżnicowane sceny obejmujące elementy architektury i otwartego otoczenia nie stanowiły dla badanych metod szczególnie niekorzystnego przypadku. Obserwacje poszczególnych rekonstrukcji wskazywały jednak, że modele nie odwzorowywały całej widocznej przestrzeni z jednakową dokładnością. Najczęściej zachowywane były elementy znajdujące się bliżej aparatu,

³Charakterystyka niektórych scen pozwalała na przypisanie ich do więcej niż jednej kategorii. W ramach niniejszej pracy zdecydowano się jednak na podział rozłączny, w którym każda scena mogła należeć wyłącznie do jednej grupy. Przykładowo *statue* i *tennis_table* ze zbioru autorskiego zostały zarejestrowane na zewnątrz, lecz ze względu na sposób kadrowania oraz skupienie ujęć na pojedynczym obiekcie przypisano je do grupy obiektowej.

posiadające wyraźne granice, kontrastujące z otoczeniem lub charakteryzujące się rozpoznawalną teksturą. Bardziej oddalone albo wizualnie słabo odseparowane fragmenty częściej pozostawały niekompletne, co zobrazowano na rys. 14.



Rysunek 14. Przykład rekonstrukcji sceny zewnętrznej. Wartości Q dla VGGT, MapAnything oraz MAST3R wynosiły kolejno 10, 8 i 9. Źródło: opracowanie własne.


Nie zaobserwowano przy tym stałego wzorca określającego, które obszary zostaną pominięte przez konkretną metodę. Ostateczna jakość była więc w znacznym stopniu zależna od lokalnych właściwości poszczególnych części sceny, mimo relatywnie wysokich wyników całej kategorii.

W przypadku scen wewnętrznych wystąpiło większe zróżnicowanie uzyskanych rezultatów. Mediana Q wynosiła 6 dla VGGT i MAST3R oraz 8 dla MapAnything, przy średnich równych odpowiednio 5,77, 5,51 oraz 8,25. Szczególnie wyraźna była więc przewaga MapAnything, podczas gdy rezultaty pozostałych dwóch metod były jednymi z niższych w badaniu. W części przypadków korzystne warunki stanowiła regularna geometria pomieszczeń oraz obecność mebli, krawędzi i innych wyraźnie wydzielonych elementów, które ułatwiały zachowanie ogólnego układu przestrzennego. Jednocześnie rozległe jednolite powierzchnie, takie jak ściany, podłogi czy sufity, nie zawsze były rekonstruowane poprawnie i mogły pozostawać niekompletne lub uzyskiwać niewłaściwą głębokość. Kategoria ta sugeruje zatem, że sama regularność geometryczna sceny nie gwarantuje wysokiej jakości wyniku, jeżeli nie towarzyszy jej dostateczna liczba wyraźnych cech wizualnych.

Sceny obiektowe osiągały wyniki pośrednie pomiędzy scenami zewnętrznymi i naturalnymi. W przeciwieństwie do pozostałych kategorii rekonstrukcja koncentrowała się tutaj przede wszystkim na pojedynczym obiekcie centralnym lub niewielkiej grupie obiektów. Obserwacje wizualne wskazywały, że elementy tła były często rekonstruowane jedynie częściowo lub całkowicie pomijane, nie prowadząc jednak zazwyczaj do istotnego zaburzenia geometrii głównego obiektu. Jedna ze scen została celowo zarejestrowana na jednolitym, białym tle w celu sprawdzenia wpływu takiego

sposobu akwizycji, jednak nie zaobserwowano na tej podstawie jednoznacznej poprawy jakości. Wraz ze zwiększaniem liczby widoków możliwe było natomiast uwzględnienie większego zakresu powierzchni obiektu, choć w części przypadków prowadziło to również do pojawiania się przesuniętych lub powielonych fragmentów rekonstrukcji.


Sceny naturalne charakteryzowały się nieregularną geometrią, dużą liczbą drobnych struktur oraz częstymi wzajemnymi przesłonięciami. W odróżnieniu od powierzchni typowych dla architektury występowało w nich mniej regularnych płaszczyzn i jednoznacznych krawędzi, a podobne wizualnie fragmenty mogły znajdować się na różnych głębokościach. Cechy te mogły stanowić jedną z przyczyn relatywnie niższych wyników uzyskiwanych dla tej kategorii. Grupa ta w ujęciu zbiorczym uzyskała najniższe oceny spośród analizowanych. Mediana Q wynosiła 6 dla VGGT, 5 dla MAST3R oraz 7 dla MapAnything. Na rys. 15 zobrazowano jeden z niżej ocenionych wariantów sceny naturalnej. W części przypadków wykorzystanie dodatkowych widoków umożliwiło zwiększenie zakresu odtworzonej struktury, jednak nie przekładało się to na jednoznaczną i systematyczną poprawę całkowitej jakości rekonstrukcji.



Rysunek 15. Przykład rekonstrukcji sceny należącej do kategorii naturalnej w scenariuszu dwuobrazowym. Wartość Q dla wszystkich trzech modeli wyniosła 5. Źródło: opracowanie własne.

Trudne przypadki i ograniczenia

Jak wskazano powyżej, sceny naturalne bogate w roślinność należały do bardziej wymagających przypadków, lecz trudności sprawiały również inne cienkie elementy, takie jak nogi mebli, elementy ogrodzeń czy wąskie krawędzie obiektów. Ich niewielka szerokość w obrazie oraz częste przesłonięcia sprzyjały pomijaniu części punktów lub błędnemu łączeniu ich z sąsiednimi powierzchniami. Trudność rekonstrukcji drobnych i cienkich struktur jest również wskazywana w literaturze [27], a zjawisko to znalazło odzwierciedlenie w wynikach przeprowadzonych testów. Wszystkie analizowane modele miały również trudności w pobliżu granic głębokości, gdzie punkty należące do pierwszego planu bywały błędnie rozciągane w kierunku tła. Jasne lub słabo teksturowane powierzchnie to kolejny problem uniwersalnie występujący w przeprowadzonych eksperymentach. Modelom zdarzało się pomijać takie obszary albo odtwarzać je jedynie częściowo, co prowadziło do powstawania wyraźnych braków w chmurze punktów. Podobne zjawisko zachodziło dla powierzchni refleksyjnych. Istotnym źródłem błędów były również sceny rozległe oraz obrazy wykonane z wyraźnie różnych perspektyw. W takich przypadkach modele musiały jednocześnie oszacować geometrię oraz wzajemne położenie kamer. W skrajnych przypadkach dochodziło do błędnego oszacowania i utraty spójności całej rekonstrukcji, których przykłady umieszczono w załączniku 7. Przedstawione przypadki wskazują, że mimo różnic w ogólnej jakości uzyskiwanych rezultatów żadna z badanych metod nie była całkowicie odporna na szczególnie wymagające właściwości scen, a charakter obserwowanych błędów różnił się pomiędzy modelami, co zobrazowano na rys. 16.



Rysunek 16. Każdy z testowanych modeli charakteryzował się własnym profilem występujących błędów. MapAnything i MASt3R wygenerowały spójne geometrie, jednak zawierające odłączone od reszty sceny artefakty. Okna zostały zupełnie pominięte w rekonstrukcjach MASt3R i VGGT, który dodatkowo dokonał błędnego oszacowania pozycji kamer. Źródło: opracowanie własne.

Ważnym założeniem eksperymentu było również ograniczenie danych wejściowych wyłącznie do fotografii. Niektóre spośród analizowanych metod umożliwiają wykorzystanie dodatkowych informacji geometrycznych, takich jak parametry wewnętrzne i zewnętrzne kamer, pozy lub mapy głębokości. Zastosowanie takich danych mogłoby wpłynąć zarówno na jakość uzyskanych rekonstrukcji, jak i na wnioski wynikające z ich porównania. Należy również podkreślić, że przedstawione wnioski jakościowe wynikają z ustrukturyzowanej oceny wizualnej przeprowadzonej bez wykorzystania geometrycznych danych referencyjnych. Z tego względu nie należy ich interpretować jako pomiaru dokładności geometrycznej analizowanych metod.

Ocena dokładności metrycznej rekonstrukcji MapAnything

W ramach przeprowadzonych prac zdecydowano się rozszerzyć część eksperymentalną o dodatkowe badanie poświęcone dokładności metrycznej rekonstrukcji. Celem badania było sprawdzenie, w jakim stopniu odtworzona geometria pozwala na wyznaczanie rzeczywistych wymiarów elementów sceny. Do eksperymentu wybrano model MapAnything, ponieważ jedną z deklarowanych właściwości tej metody jest generowanie rekonstrukcji w skali metrycznej. Na potrzeby eksperymentu wybrano pięć scen: `spqr`, `room_1`, `room_2`, `kettle` oraz `miscellaneous`, zawierających elementy o wymiarach możliwych do bezpośredniego zmierzenia. Dla każdej sceny wykonano od dwóch do czterech niezależnych pomiarów rzeczywistych długości, które następnie porównano z odpowiadającymi im odległościami w rekonstruowanej scenie. Dla każdego analizowanego odcinka wskazywano dwa odpowiadające mu punkty na obrazie, po czym na podstawie przewidzianych przez model współrzędnych 3D obliczano odległość między nimi. Przykład mierzonych odcinków zobrazowano na rys. 17.



Rysunek 17. Punkty pomiarowe wykorzystane do oceny dokładności metrycznej rekonstrukcji dla scen `spqr` oraz `room_2`. Źródło: opracowanie własne.

Dla każdej pary punktów wyznaczano błąd bezwzględny długości oraz błąd względny, określający stosunek wartości bezwzględnej różnicy między długością zrekonstruowaną i referencyjną do długości referencyjnej. Jako zbiorczą miarę dokładności dla danego przypadku testowego wykorzystano średni bezwzględny błąd procentowy (MAPE), obliczony na podstawie błędów względnych wszystkich analizowanych odcinków. Procedurę przeprowadzono dla rekonstrukcji uzyskanych z jednego, dwóch, czterech oraz ośmiu obrazów wejściowych.

Badanie miało charakter uzupełniający względem zasadniczej części eksperymentów i nie stanowiło próby odtworzenia testów wykonywanych przez autorów MapAnything. Warto jednak odnieść uzyskane rezultaty do wartości raportowanych w oryginalnej pracy [13]. Autorzy podają między innymi błąd względny estymowanego współczynnika skali metrycznej (E_{scale}) oraz błąd względny rekonstruowanych punktów (E_{points}). Metryki te opisują odpowiednio dokładność estymacji globalnej skali sceny oraz geometrii rekonstrukcji. Dokładne wartości liczbowe zamieszczono jedynie dla scenariusza dwuobrazowego i wynoszą one kolejno 0,13 oraz 0,08. Na podstawie dodatkowych wykresów można jednak zaobserwować, że w zakresie liczby obrazów analizowanym w niniejszej pracy E_{scale} pozostaje na zbliżonym poziomie, natomiast E_{points} stopniowo wzrasta, osiągając dla ośmiu obrazów wartość około 0,13. Odpowiada to odchyleniom rzędu odpowiednio 13% i 8%, co wskazuje na możliwość uzyskania stosunkowo dobrego przybliżenia metrycznej geometrii sceny już na podstawie dwóch widoków.

Ze względu na różnice w sposobie przeprowadzenia eksperymentów i zastosowanych miarach wartości te nie są bezpośrednio porównywalne z błędem obliczanym w niniejszym badaniu, mogą jednak stanowić orientacyjny punkt odniesienia przy interpretacji uzyskanych wyników. Pełne zestawienie danych oraz opracowany za pomocą sztucznej inteligencji skrypt zamieszczono w repozytorium plików, do którego odnośnik znajduje się w załączniku 3, natomiast w dalszej części pracy przedstawiono wybrane wyniki badań, między innymi w tabeli 14.

Tabela 14. Wartości średniego bezwzględnego błędu procentowego MAPE uzyskane dla poszczególnych scen i liczby obrazów wejściowych. Pogrubieniem oznaczono najniższą wartość błędu dla każdej sceny. Źródło: opracowanie własne.

Scena	1 zdjęcie	2 zdjęcia	4 zdjęcia	8 zdjęć	Najlepszy wariant
spqr	240,84%	201,65%	201,88%	194,00%	8
kettle	89,14%	76,71%	71,15%	76,59%	4
miscellaneous	45,25%	74,69%	77,01%	73,86%	1
room_1	14,14%	10,06%	9,37%	5,90%	8
room_2	4,65%	11,68%	12,15%	10,76%	1

W wynikach przedstawionych przez autorów MapAnything zależność poszczególnych miar dokładności od liczby widoków nie była jednakowa i podobnie w przeprowadzonym eksperymencie nie zaobserwowano jednolitego kierunku zmian dokładności metrycznej. Uzyskane rezultaty były silnie zależne od analizowanej sceny. Szczególnie wyraźny kontrast zaobserwowano pomiędzy scenami spqr oraz room_2. W przypadku spqr wartości MAPE pozostawały bardzo wysokie we wszystkich

scenariuszach, a dla ośmiu obrazów wartość błędu wyniosła 194,00%. Z kolei dla room_2 najniższy błąd uzyskano już przy pojedynczym obrazie i wyniósł on jedynie 4,65%. Skalę tych różnic lepiej obrazuje bezpośrednie zestawienie długości referencyjnych i wartości wyznaczonych na podstawie rekonstrukcji, przedstawione w tabeli 15. Dla sceny spqr w wariancie wykorzystującym osiem obrazów dwa odcinki o długości referencyjnej 13,0 cm zostały oszacowane odpowiednio na 44,68 cm i 43,48 cm, natomiast odcinek o długości 123,0 cm na 250,72 cm. W przypadku room_2 przy pojedynczym obrazie odcinki o długościach referencyjnych 60,0 cm, 119,0 cm i 11,0 cm zostały oszacowane odpowiednio na 60,68 cm, 131,65 cm i 10,76 cm.

Tabela 15. Referencyjne i przewidywane przez MapAnything długości analizowanych odcinków. Pogrubieniem oznaczono wartość najbliższą długości referencyjnej dla danego odcinka. Źródło: opracowanie własne.

Scena	Odcinek	Ref. [cm]	1 zdjęcie [cm]	2 zdjęcia [cm]	4 zdjęcia [cm]	8 zdjęć [cm]
spqr	hannibal_h	13,0	53,23	45,57	46,92	44,68
spqr	roman_h	13,0	51,27	45,06	43,97	43,48
spqr	tv_w	123,0	268,93	255,61	254,04	250,72
kettle	kettle_h	21,5	41,08	38,59	38,63	38,59
kettle	kettle_measure_h	10,0	18,72	17,39	16,26	17,37
miscellaneous	book_h	20,5	33,18	36,41	38,06	38,37
miscellaneous	book_w	13,6	17,50	23,36	22,90	21,84
room_1	mug	12,0	7,58	10,27	9,44	11,35
room_1	table	90,0	80,52	98,22	92,25	93,88
room_1	table_leg	72,0	69,27	74,82	70,38	73,47
room_1	windows	138,0	145,44	155,62	153,71	154,31
room_2	clock	60,0	60,68	67,27	66,78	65,21
room_2	table	119,0	131,65	137,72	138,17	135,90
room_2	sink_edge_length	11,0	10,76	11,79	11,99	12,03

Na tle przedstawionych wyników można zauważyć zależność od charakteru analizowanych scen. Dwie sceny osiągające najlepsze rezultaty, room_1 oraz room_2, należały do kategorii scen wewnętrznych, podczas gdy pozostałe przypadki miały charakter obiektowy i były silniej skoncentrowane na wybranym elemencie. Sceny wewnętrzne, bogatsze w różnorodne elementy o zróżnicowanych rozmiarach i wzajemnych relacjach przestrzennych, mogły ułatwiać modelowi oszacowanie skali w porównaniu ze scenami obiektowymi, silnie skoncentrowanymi na pojedynczych elementach. Sugerowałoby to, że charakterystyka sceny może mieć istotny wpływ na dokładność metryczną rekonstrukcji. Jednocześnie zwiększanie liczby widoków nie niwelowało obserwowanego zróżnicowania pomiędzy scenami, co dodatkowo sugeruje, iż sama liczba obrazów wejściowych nie była czynnikiem decydującym o dokładności metrycznej rekonstrukcji.

Warto również przeanalizować stosunek długości przewidywanej przez model L_{pred} do rzeczywistej długości referencyjnej L_{GT} . Wartość ilorazu L_{pred}/L_{GT} równa 1 oznacza poprawne odwzorowanie wymiaru, wartości większe od 1 wskazują na jego przeszacowanie, natomiast wartości mniejsze od 1 — na niedoszacowanie. Analiza uzyskanych wyników wykazała wyraźną przewagę przypadków, w których MapAnything przeszacowywał rzeczywiste wymiary badanych elementów. Zjawisko to obejmowało od 10 do 13 spośród 14 pomiarów, w zależności od liczby obrazów wejściowych. Największy udział przeszacowań odnotowano dla dwóch oraz ośmiu obrazów, gdzie stanowiły one 92,86% wszystkich

przypadków. Wskazuje to, że błędy uzyskane w eksperymencie nie były rozłożone symetrycznie, lecz wykazywały wyraźną tendencję do zawyżania odtwarzanych długości. Zestawienie przypadków przeszacowania i niedoszacowania dla poszczególnych wariantów liczby obrazów przedstawiono w tabeli 16.

Tabela 16. Liczba przypadków przeszacowania i niedoszacowania rzeczywistych długości przez MapAnything w zależności od liczby obrazów wejściowych. Źródło: opracowanie własne.

Liczba obrazów	Przeszacowanie	Niedoszacowanie	Udział przeszacowań
1	10	4	71,43%
2	13	1	92,86%
4	12	2	85,71%
8	13	1	92,86%

Wartości ilorazu $L_{\text{pred}}/L_{\text{GT}}$ pozwalają również ocenić, czy błędy poszczególnych wymiarów w obrębie tej samej rekonstrukcji mają zbliżony charakter. Jeżeli dla różnych odcinków wartości tego współczynnika są podobne, oznacza to, że ich długości zostały przeskalowane w zbliżonym stopniu. Może to wskazywać, że istotnym źródłem błędu jest niepoprawne odwzorowanie globalnej skali rekonstrukcji, podczas gdy wzajemne relacje wybranych wymiarów pozostają stosunkowo dobrze zachowane. Z kolei znaczne różnice wartości $L_{\text{pred}}/L_{\text{GT}}$ dla poszczególnych odcinków mogą świadczyć o występowaniu dodatkowych, lokalnych zniekształceń geometrii.

Przypadki, w których proporcje mierzonych odcinków pozostawały stosunkowo dobrze zachowane, zaobserwowano między innymi dla scen kettle oraz miscellaneous. Rozmieszczenie punktów wykorzystanych do wyznaczenia analizowanych odcinków przedstawiono na rys. 18.



Rysunek 18. Punkty pomiarowe wykorzystane do oceny dokładności metrycznej rekonstrukcji dla scen kettle, miscellaneous oraz room_1. Źródło: opracowanie własne.

W przypadku sceny kettle, pomimo znacznego przeszacowania obu analizowanych odcinków, ich wzajemna relacja pozostawała stosunkowo stabilna. Rzeczywisty stosunek ich długości wynosił 2,15, natomiast dla rekonstrukcji uzyskanych z jednego, dwóch i ośmiu obrazów odpowiednio około

2,20, 2,22 oraz 2,22. Zbliżone zjawisko wystąpiło również w scenie *miscellaneous*, jednak wyraźnie zaznaczyło się ono przede wszystkim w scenariuszu dwuobrazowym. W tej scenie dwa odcinki pomiarowe odpowiadały szerokości i wysokości tej samej książki. W wariancie dwuobrazowym oba wymiary zostały zawyżone odpowiednio o 77,59% oraz 71,76%, jednak ich wzajemna proporcja pozostała zbliżona do rzeczywistej. Stosunek długości boków książki wynosił około 1,51, natomiast w rekonstrukcji 1,56. Dla jednego, czterech i ośmiu obrazów osiągał on odpowiednio około 1,90, 1,66 oraz 1,76 i w tych scenariuszach zgodność proporcji była wyraźnie słabsza.

Zbliżoną tendencję odnotowano również dla *room_2*, gdzie w obrębie poszczególnych scenariuszy różne odcinki były zazwyczaj przeszacowywane w podobnym stopniu. Obserwacja ta nie była jednak uniwersalna. W scenie *spqr* wartości $L_{\text{pred}}/L_{\text{GT}}$ wyraźnie różniły się pomiędzy mierzonymi elementami. Zaobserwowanego błędu nie można było wyjaśnić wyłącznie jednolitym przeskalowaniem całej rekonstrukcji, a poza niepoprawnym odwzorowaniem skali mogły występować również lokalne zniekształcenia geometrii.

Podsumowując, MapAnything był w stanie uzyskać dla części scen rekonstrukcje o wymiarach zbliżonych do rzeczywistych wymiarów badanych elementów. Dokładność metryczna była jednak silnie zależna od analizowanej sceny, natomiast wpływ liczby obrazów wejściowych nie wykazywał jednolitego kierunku zmian. Model wykazywał również wyraźną tendencję do przeszacowywania rzeczywistych wymiarów. Jednocześnie w części przypadków, mimo błędnej skali bezwzględnej, wzajemne relacje pomiędzy mierzonymi odcinkami pozostawały stosunkowo dobrze zachowane, co sugeruje, że istotnym źródłem błędu mogło być niepoprawne odwzorowanie globalnej skali rekonstrukcji.

Rozdział 6

Podsumowanie

Rekonstrukcja trójwymiarowej sceny na podstawie pojedynczego obrazu lub niewielkiej liczby zdjęć pozostaje zadaniem trudnym ze względu na niepełną informację o geometrii obserwowanej przestrzeni. Rozwój metod opartych na głębokich sieciach neuronowych pozwolił jednak na wykorzystanie wiedzy zdobytej podczas treningu do uzupełniania informacji, których nie można bezpośrednio wyznaczyć na podstawie zależności geometrycznych. W tym kontekście w niniejszej pracy przeanalizowano trzy współczesne modele wykorzystujące architekturę typu Transformer: VGGT, MAST3R i MapAnything. Badanie zrealizowano na 38 scenach, w tym 20 scenach autorskich oraz scenach pochodzących ze zbiorów LLFF i ETH3D. Dla każdej sceny przygotowano cztery scenariusze badawcze obejmujące jeden, dwa, cztery i osiem obrazów wejściowych, przy czym MAST3R nie był testowany w scenariuszu jednoobrazowym. Łącznie uzyskano w ten sposób 418 odrębnych przypadków testowych, dla których przeprowadzono ustandaryzowaną analizę wizualną. Badania uzupełniono ograniczoną analizą dokładności metrycznej MapAnything na podstawie wybranych scen autorskich.

Spośród metod badanych w ramach pracy najbardziej wszechstronny okazał się MapAnything. Pod względem wydajności obliczeniowej osiągał on wyniki zbliżone do VGGT, natomiast MAST3R, mimo najmniejszego wykorzystania pamięci VRAM, wymagał kilkukrotnie dłuższego czasu rekonstrukcji w porównaniu z pozostałymi metodami. Dla ośmiu obrazów średni czas wykonania rekonstrukcji przez MAST3R wynosił 54,24 s, podczas gdy dla MapAnything i VGGT było to odpowiednio 5,92 s i 6,07 s. Mimo zbliżonej wydajności obu modeli pod względem jakości rekonstrukcji przewagę uzyskał MapAnything, między innymi dzięki większej kompletności odtwarzanych scen. W przypadku VGGT znacznie częściej obserwowano ubytki w rekonstrukcji, co prowadziło do niższej oceny kompletności C , która przykładowo dla ośmiu obrazów wyniosła 1,24 pkt wobec 2,47 pkt dla MapAnything. We wszystkich badanych modelach wraz ze zwiększaniem liczby ujęć średnia wartość C pozostawała na podobnym poziomie lub wzrastała, natomiast średnia ocena dotycząca artefaktów i szumu A malała. Dodatkowe widoki mogły więc umożliwiać odtworzenie kolejnych fragmentów geometrii, lecz nie prowadziły do systematycznego wzrostu zagregowanego wyniku Q . Najwyższe średnie wartości Q odnotowano w scenariuszu jednoobrazowym dla modeli VGGT i MapAnything, gdzie wyniosły one odpowiednio 6,55 i 8,47. W przypadku MAST3R najlepszą średnią wartość, równą 6,11, otrzymał

wariant dwuobrazowy, jednak dla większej liczby obrazów wyniki pozostawały na zbliżonym poziomie, wykazując niewielką tendencję spadkową. Różnic tych nie należy jednak bezpośrednio interpretować jako różnic w jakości rekonstrukcji pomiędzy scenariuszami, ponieważ kompletność, stanowiąca jedną ze składowych wyniku Q , odnosiła się do zakresu sceny widocznego na obrazach wejściowych, który zmieniał się w poszczególnych wariantach. Dodatkowa analiza dokładności metrycznej MapAnything wykazała ponadto, że w części badanych scen model odtwarzał rzeczywiste wymiary z niewielkim błędem, podczas gdy w innych przypadkach błędy były bardzo duże. Przykładowo, średni bezwzględny błąd procentowy wyniósł 4,65% dla sceny *room_2* w wariancie jednoobrazowym, natomiast dla sceny *spqr* osiągnął 240,84%, co wskazuje na silną zależność dokładności metrycznej modelu od analizowanej sceny.

Przeprowadzone badania wskazują, że uzyskanie użytecznej rekonstrukcji 3D na podstawie od jednego do ośmiu zdjęć jest możliwe na odpowiednio wydajnym sprzęcie konsumenckim z wykorzystaniem gotowych, wytrenowanych modeli. Wzrost liczby obrazów wejściowych wiązał się ze zwiększeniem kosztu obliczeniowego, jednak nie uniemożliwiał wykonania rekonstrukcji na zastosowanym sprzęcie. Jakość rezultatów pozostawała natomiast silnie zależna od zastosowanej metody, charakteru sceny oraz doboru obrazów wejściowych, przy czym szczególne trudności nadal sprawiały elementy słabo teksturowane, refleksyjne, przezroczyste i geometrycznie złożone.

Skrypty wykorzystane do przeprowadzenia eksperymentów oraz materiały wynikowe udostępniono w repozytorium GitHub, do którego odnośnik zamieszczono w załączniku 3.

6.1 Dalsze prace

Tematykę niniejszej pracy można uznać za relatywnie wąski obszar badawczy, czego jedną z konsekwencji jest ograniczona liczba algorytmów spełniających przyjęte wymagania kwalifikacyjne. Grupa ta została dodatkowo pomniejszona o modele, których nie udało się poprawnie uruchomić w ramach prowadzonych badań. Jak wskazano w rozdziale 3.1, ich implementacje wymagały zastosowania ściśle określonych wersji bibliotek i innych elementów oprogramowania. W części przypadków publicznie dostępny kod wymagał pakietów w niekompatybilnych ze sobą wersjach, uniemożliwiając instalację modelu. Jednym z kierunków dalszych prac mogłoby być zatem rozszerzenie eksperymentów o kolejne metody po przygotowaniu dla nich stabilnych i powtarzalnych środowisk uruchomieniowych. Modele przeanalizowane w niniejszej pracy charakteryzowały się, w uproszczeniu, podobnym paradygmatem działania. Wartościowym rozszerzeniem badań byłoby zatem uwzględnienie rozwiązań opartych na odmiennych reprezentacjach i procedurach rekonstrukcyjnych, takich jak NeRF lub 3D Gaussian Splatting. W chwili przygotowywania niniejszej pracy istniały już metody jednokierunkowe wykorzystujące tego rodzaju reprezentacje; możliwe byłoby zatem opracowanie spójnej metodyki porównawczej, uwzględniającej różnice między generowanymi reprezentacjami i pozwalającej określić, jakie wyniki poszczególne podejścia osiągają pod względem jakości rekonstrukcji oraz zapotrzebowania na zasoby obliczeniowe. Ograniczenia przeprowadzonych badań dotyczyły również autorskiego zbioru danych. Część z nich wynikała ze świadomie przyjętych

założeń, takich jak wykonywanie zdjęć w warunkach możliwie praktycznych. Jednak przeprowadzenie analogicznych eksperymentów z wykorzystaniem obrazów o wyższej jakości lub dodatkowych danych geometrycznych uzupełniłoby uzyskane wyniki. Pozwoliłoby to ocenić, w jakim stopniu jakość rekonstrukcji zależy od właściwości samych metod, a w jakim od rozdzielczości, ostrości czy szumu. Potencjał badawczy wykazuje zarówno zawężenie, jak i rozszerzenie zakresu zbioru danych. Ponieważ analizowane modele zostały zaprojektowane jako rozwiązania generalizujące na różne typy scenerii, autorski zbiór obejmował zróżnicowane kategorie scen. Skoncentrowanie kolejnych badań na jednej kategorii, na przykład scenach wewnętrznych, pozwoliłoby dokładniej przeanalizować typowe dla niej problemy. Jednocześnie rozszerzenie zbioru o większą liczbę przykładów oraz sceny wielkoskalowe umożliwiłoby lepszą ocenę zdolności modeli do generalizacji. Zastosowany zbiór obejmował 20 niezależnych scen, co pozwoliło przeprowadzić założone eksperymenty, jednak większa skala zwiększyłaby reprezentatywność uzyskanych wyników. Najważniejszym kierunkiem dalszych prac byłoby przeprowadzenie ilościowej oceny jakości geometrycznej z wykorzystaniem ustandaryzowanych metryk. Ocenę wyników w niniejszej pracy oparto na ustandaryzowanej analizie wizualnej, która pozwala wskazać charakterystyczne artefakty i tendencje, lecz nie zapewnia obiektywnego pomiaru błędu.

Bibliografia

- [1] Brachmann, E. i Prisacariu, V. A., „Building a Large Geospatial Model to Achieve Spatial Intelligence”, <https://nianticlabs.com/news/largegeospatialmodel>, data dostępu 16.03.2026.
- [2] Canelhas, D. R., Schaffernicht, E., Stoyanov, T., Lilienthal, A. J. i Davison, A. J., „An Eigenshapes Approach to Compressed Signed Distance Fields and Their Utility in Robot Mapping”, *CoRR*, t. abs/1609.02462, 2016. arXiv: 1609.02462. adr.: <http://arxiv.org/abs/1609.02462>.
- [3] Caron, M. i in., *Emerging Properties in Self-Supervised Vision Transformers*, 2021. arXiv: 2104.14294 [cs.CV]. adr.: <https://arxiv.org/abs/2104.14294>.
- [4] Chen, Y. i in., „MVSplat: Efficient 3D Gaussian Splatting from Sparse Multi-view Images”, w *Computer Vision – ECCV 2024*, Leonardis, A., Ricci, E., Roth, S., Russakovsky, O., Sattler, T. i Varol, G., red., Cham: Springer Nature Switzerland, 2025, s. 370–386, isbn: 978-3-031-72664-4.
- [5] Dai, A., Chang, A. X., Savva, M., Halber, M., Funkhouser, T. i Nießner, M., „ScanNet: Richly-annotated 3D Reconstructions of Indoor Scenes”, w *Proc. Computer Vision and Pattern Recognition (CVPR)*, IEEE, 2017.
- [6] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K. i Li, F.-F., „ImageNet: a Large-Scale Hierarchical Image Database”, *czer.* 2009, s. 248–255. doi: 10.1109/CVPR.2009.5206848.
- [7] Dosovitskiy, A. i in., *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*, 2021. arXiv: 2010.11929 [cs.CV]. adr.: <https://arxiv.org/abs/2010.11929>.
- [8] Goodfellow, I., Bengio, Y. i Courville, A., *Deep Learning*. MIT Press, 2016, <http://www.deeplearningbook.org>.
- [9] Hendrycks, D. i Gimpel, K., *Gaussian Error Linear Units (GELUs)*, 2023. arXiv: 1606.08415 [cs.LG]. adr.: <https://arxiv.org/abs/1606.08415>.
- [10] Herman Gomes, *Marr's Theory: From primal sketch to 3-D models*, https://homepages.inf.ed.ac.uk/rbf/CVonline/LOCAL_COPIES/GOMES1/marr.html, data dostępu: 21.03.2026.
- [11] Hong, Y. i in., *LRM: Large Reconstruction Model for Single Image to 3D*, 2024. arXiv: 2311.04400 [cs.CV]. adr.: <https://arxiv.org/abs/2311.04400>.
- [12] Horn, B. K. P., „Shape from Shading: A Method for Obtaining the Shape of a Smooth Opaque Object from One View”, Massachusetts Institute of Technology, Artificial Intelligence Laboratory, Cambridge, Massachusetts, spraw. tech. AI-TR-232 and MAC-TR-79, list. 1970. adr.: <https://people.csail.mit.edu/bkph/AIM/AITR-232-OPT.pdf>.

- [13] Keetha, N. i in., „MapAnything: Universal Feed-Forward Metric 3D Reconstruction”, w *International Conference on 3D Vision (3DV)*, IEEE, 2026.
- [14] Kerbl, B., Kopanas, G., Leimkühler, T. i Drettakis, G., „3D Gaussian Splatting for Real-Time Radiance Field Rendering”, *ACM Transactions on Graphics*, t. 42, nr. 4, lip. 2023. adr.: <https://repo-sam.inria.fr/fungraph/3d-gaussian-splatting/>.
- [15] Leroy, V., Cabon, Y. i Revaud, J., „Grounding Image Matching in 3D with MAST3R”, w *Computer Vision – ECCV 2024*, Leonardis, A., Ricci, E., Roth, S., Russakovsky, O., Sattler, T. i Varol, G., red., Cham: Springer Nature Switzerland, 2025, s. 71–91, isbn: 978-3-031-73220-1.
- [16] Li, Z. i Snavely, N., „MegaDepth: Learning Single-View Depth Prediction from Internet Photos”, w *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, s. 2041–2050.
- [17] Lowe, D., „Object recognition from local scale-invariant features”, w *Proceedings of the Seventh IEEE International Conference on Computer Vision*, t. 2, 1999, 1150–1157 vol.2. doi: 10.1109/ICCV.1999.790410.
- [18] Lynch, K. M. i Park, F. C., „Configuration Space”, w *Modern Robotics: Mechanics, Planning, and Control*. Cambridge: Cambridge University Press, 2017, s. 10–49. doi: 10.1017/9781316661239.005.
- [19] Marr, D., *Vision: A Computational Investigation into the Human Representation and Processing of Visual Information*. The MIT Press, lip. 2010, isbn: 9780262289610. doi: 10.7551/mitpress/9780262514620.001.0001. adr.: <https://doi.org/10.7551/mitpress/9780262514620.001.0001>.
- [20] Mildenhall, B., Srinivasan, P. P., Tancik, M., Barron, J. T., Ramamoorthi, R. i Ng, R., „NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis”, w *ECCV*, 2020.
- [21] Mildenhall, B. i in., „Local Light Field Fusion: Practical View Synthesis with Prescriptive Sampling Guidelines”, *ACM Transactions on Graphics (TOG)*, 2019.
- [22] Oquab, M. i in., *DINOv2: Learning Robust Visual Features without Supervision*, 2024. arXiv: 2304.07193 [cs.CV]. adr.: <https://arxiv.org/abs/2304.07193>.
- [23] Roberts, L., *Machine Perception of Three-Dimensional Solids*. Garland Publishing, sty. 1963, isbn: 0-8240-4427-4.
- [24] Rojas, S. i in., „Re-ReND: Real-time Rendering of NeRFs across Devices”, *arXiv preprint arXiv:2303.08717*, 2023.
- [25] Schönberger, J. L. i Frahm, J.-M., „Structure-from-Motion Revisited”, w *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [26] Schönberger, J. L., Zheng, E., Pollefeys, M. i Frahm, J.-M., „Pixelwise View Selection for Unstructured Multi-View Stereo”, w *European Conference on Computer Vision (ECCV)*, 2016.
- [27] Schöps, T. i in., „A Multi-View Stereo Benchmark with High-Resolution Images and Multi-Camera Videos”, w *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

-
- [28] Smondrk, M., Babusiak, B., Benova, M. i Janoušek, L., „SOFTWARE TOOL FOR ANALYSIS OF VOXEL HUMAN BODY MODELS”, *Lékař a technika - Clinician and Technology*, t. 51, s. 59–65, grud. 2021. doi: 10.14311/CTJ.2021.1.09.
- [29] Snavely, N., Seitz, S. M. i Szeliski, R., „Photo tourism: exploring photo collections in 3D”, w *Seminal Graphics Papers: Pushing the Boundaries, Volume 2*, 1 wyd. New York, NY, USA: Association for Computing Machinery, 2023, isbn: 9798400708978. adr.: <https://doi.org/10.1145/3596711.3596766>.
- [30] Sun, C., Shrivastava, A., Singh, S. i Gupta, A., *Revisiting Unreasonable Effectiveness of Data in Deep Learning Era*, 2017. arXiv: 1707.02968 [cs.CV]. adr.: <https://arxiv.org/abs/1707.02968>.
- [31] Tancik, M. i in., *Block-NeRF: Scalable Large Scene Neural View Synthesis*, 2022. arXiv: 2202.05263 [cs.CV]. adr.: <https://arxiv.org/abs/2202.05263>.
- [32] Tancik, M. i in., „Nerfstudio: A Modular Framework for Neural Radiance Field Development”, w *ACM SIGGRAPH 2023 Conference Proceedings*, ser. SIGGRAPH '23, 2023.
- [33] Tochilkin, D. i in., *TripoSR: Fast 3D Object Reconstruction from a Single Image*, 2024. arXiv: 2403.02151 [cs.CV]. adr.: <https://arxiv.org/abs/2403.02151>.
- [34] Vaswani, A. i in., *Attention Is All You Need*, 2023. arXiv: 1706.03762 [cs.CL]. adr.: <https://arxiv.org/abs/1706.03762>.
- [35] Wang, J., Chen, M., Karaev, N., Vedaldi, A., Rupprecht, C. i Novotny, D., „VGGT: Visual Geometry Grounded Transformer”, w *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.
- [36] Wang, Z. i Zhu, Y., *NeRFlex: Resource-aware Real-time High-quality Rendering of Complex Scenes on Mobile Devices*, 2025. arXiv: 2504.03415 [cs.GR]. adr.: <https://arxiv.org/abs/2504.03415>.
- [37] Yang, S. i in., *Robo3R: Enhancing Robotic Manipulation with Accurate Feed-Forward 3D Reconstruction*, 2026. eprint: 2602.10101.
- [38] Yao, Y., Luo, Z., Li, S., Fang, T. i Quan, L., *MVSNet: Depth Inference for Unstructured Multi-view Stereo*, 2018. arXiv: 1804.02505 [cs.CV]. adr.: <https://arxiv.org/abs/1804.02505>.
- [39] Yao, Y. i in., „Blendedmvs: A large-scale dataset for generalized multi-view stereo networks”, w *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, s. 1790–1799.
- [40] Yeshwanth, C., Liu, Y.-C., Nießner, M. i Dai, A., „ScanNet++: A High-Fidelity Dataset of 3D Indoor Scenes”, w *Proceedings of the International Conference on Computer Vision (ICCV)*, 2023.
- [41] Yu, A., Ye, V., Tancik, M. i Kanazawa, A., „pixelNeRF: Neural Radiance Fields from One or Few Images”, w *CVPR*, 2021.

- [42] Zhu, S., Wang, G., Kong, X., Kong, D. i Wang, H., *3D Gaussian Splatting in Robotics: A Survey*, 2024. arXiv: 2410.12262 [cs.R0]. adr.: <https://arxiv.org/abs/2410.12262>.

Wykaz skrótów i symboli

CNN	splotowa sieć neuronowa (ang. <i>Convolutional Neural Network</i>)
SfM	(ang. <i>Structure from Motion</i>)
MVS	(ang. <i>Multi View Stereo</i>)
NeRF	neuronowe pola radiancji (ang. <i>Neural Radiance Fields</i>)
3DGS	rozsmarowywanie gaussów (ang. <i>3D Gaussian Splatting</i>)
ViT	transformer wizyjny (ang. <i>Vision Transformer</i>)

Spis rysunków

1	Przykład hierarchicznej reprezentacji modelu człowieka z podziałem na kolejne części składowe: kończynę górną, przedramię oraz dłoń. Źródło: [10]	6
2	Trójwymiarowa rekonstrukcja w formie rzadkiej chmury punktów. Źródło: [29]	13
3	Procedura rekonstrukcji 3D w wykonaniu NeRF. Źródło: [20]	15
4	Architektura modelu ViT. Źródło: [7]	17
5	Model centrum Rzymu w formie rzadkiej chmury punktów wykonany za pomocą COLMAP. Źródło: [25].	21
6	Przykład wykonanej przez twórców MegaDepth optymalizacji map głębi, porównanie zdjęcia źródłowego (a) z mapą głębi klasycznego MVS (b) oraz ostateczną, poprawioną mapą głębi (c). Źródło: [16]	34
7	Przykład sceny wewnętrznej ze zbioru danych: wewnątrz kawiarni z licznymi drobnymi obiektami, powierzchniami refleksyjnymi, przeszkloną witryną oraz zróżnicowanym oświetleniem. Źródło: opracowanie własne.	40
8	Wykresy przedstawiające uśrednione czasy rekonstrukcji oraz czasy inferencji przy zastosowaniu różnej liczby zdjęć źródłowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.	49
9	Wpływ źródła danych na czas rekonstrukcji modelu MapAnything dla poszczególnych scenariuszy. Przeciętna rekonstrukcja sceny z autorskiego zestawu dla scenariusza z 8 obrazami zajmowała około dwukrotnie dłużej niż przeciętna scena ze zbioru LLFF przy takiej samej liczbie zdjęć. Źródło: opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.	50
10	Wykres przedstawiający średnią maksymalną ilość przypisanej pamięci VRAM przy zastosowaniu różnej liczby zdjęć źródłowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.	51
11	Każdy z modeli charakteryzował się innym profilem dystrybucji dostępnej pamięci RAM w zależności od źródła danych. Źródło: opracowanie własne na podstawie wyników przeprowadzonych eksperymentów.	54

12	Przykład sceny obiektowej, dla której zaobserwowano wzrost oceny kompletności rekonstrukcji C wraz ze zwiększeniem liczby fotografii. W górnym rzędzie przedstawiono rekonstrukcje odpowiadające drugiemu scenariuszowi (dwa zdjęcia), natomiast w dolnym – trzeciemu scenariuszowi (cztery zdjęcia). W przypadku MAST3R wartość C wzrosła z 1 pkt do 2 pkt, natomiast dla MapAnything z 2 pkt do 3 pkt. Źródło: opracowanie własne.	60
13	Przykład sceny wewnętrznej ze zbioru autorskiego. Ilustracja przedstawia przypadek, w którym MapAnything uzyskał maksymalną ocenę $Q = 12$. Jednocześnie widoczne jest charakterystyczne dla części rekonstrukcji VGGT pomijanie fragmentów sceny, co w tym przypadku przełożyło się na ocenę kompletności C równą 1 pkt. Źródło: opracowanie własne.	63
14	Przykład rekonstrukcji sceny zewnętrznej. Wartości Q dla VGGT, MapAnything oraz MAST3R wynosiły kolejno 10, 8 i 9. Źródło: opracowanie własne.	65
15	Przykład rekonstrukcji sceny należącej do kategorii naturalnej w scenariuszu dwuobrazowym. Wartość Q dla wszystkich trzech modeli wyniosła 5. Źródło: opracowanie własne.	66
16	Każdy z testowanych modeli charakteryzował się własnym profilem występujących błędów. MapAnything i MAST3R wygenerowały spójne geometrie, jednak zawierające odłączone od reszty sceny artefakty. Okna zostały zupełnie pominięte w rekonstrukcjach MAST3R i VGGT, który dodatkowo dokonał błędnego oszacowania pozycji kamer. Źródło: opracowanie własne.	67
17	Punkty pomiarowe wykorzystane do oceny dokładności metrycznej rekonstrukcji dla scen spqr oraz room_2. Źródło: opracowanie własne.	68
18	Punkty pomiarowe wykorzystane do oceny dokładności metrycznej rekonstrukcji dla scen kettle, miscellaneous oraz room_1. Źródło: opracowanie własne.	71
19	Rekonstrukcja sceny church ze zbioru autorskiego w scenariuszu jednoobrazowym, uzyskana za pomocą modeli VGGT oraz MapAnything. Źródło: opracowanie własne.	107
20	Rekonstrukcja sceny mural_king ze zbioru autorskiego w scenariuszu jednoobrazowym, uzyskana za pomocą modeli VGGT oraz MapAnything. Źródło: opracowanie własne.	107
21	Rekonstrukcja sceny flower ze zbioru LLFF w scenariuszu jednoobrazowym, uzyskana za pomocą modeli VGGT oraz MapAnything. Źródło: opracowanie własne.	107
22	Rekonstrukcja sceny old_computer ze zbioru ETH3D w scenariuszu jednoobrazowym, uzyskana za pomocą modeli VGGT oraz MapAnything. Źródło: opracowanie własne.	108
23	Rekonstrukcja sceny observatory ze zbioru ETH3D dla scenariusza dwuobrazowego (środkowe zdjęcie) oraz czteroobrazowego (prawe zdjęcie), uzyskana za pomocą modelu VGGT. Źródło: opracowanie własne.	108

24	Rekonstrukcja sceny room_3 ze zbioru autorskiego dla scenariusza jednoobrazowego (środkowe zdjęcie) oraz dwuobrazowego (prawe zdjęcie), uzyskana za pomocą modelu VGGT. Źródło: opracowanie własne.	109
25	Rekonstrukcja sceny kettle ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	109
26	Rekonstrukcja sceny terrace_2 ze zbioru ETH3D dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	110
27	Rekonstrukcja sceny bridge ze zbioru ETH3D dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	110
28	Rekonstrukcja sceny room_5 ze zbioru autorskiego dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	111
29	Rekonstrukcja sceny lounge ze zbioru ETH3D dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	111
30	Rekonstrukcja sceny room_3 ze zbioru autorskiego dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	112
31	Rekonstrukcja sceny room ze zbioru LLFF dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	112
32	Rekonstrukcja sceny wewnętrznej office ze zbioru autorskiego dla scenariusza ośmioobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	113
33	Rekonstrukcja sceny wewnętrznej room_2 ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	113
34	Rekonstrukcja sceny wewnętrznej cafe ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	114
35	Rekonstrukcja sceny naturalnej fern ze zbioru LLFF dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	114
36	Rekonstrukcja sceny naturalnej orchids ze zbioru LLFF dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	115

37	Rekonstrukcja sceny naturalnej bush_1 ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	115
38	Rekonstrukcja sceny zewnętrznej gate ze zbioru autorskiego dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	116
39	Rekonstrukcja sceny zewnętrznej boulders ze zbioru ETH3D dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	116
40	Rekonstrukcja sceny zewnętrznej synagogue ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	117
41	Rekonstrukcja sceny obiektowej horns ze zbioru LLFF dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	117
42	Rekonstrukcja sceny obiektowej miscellaneous ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	118
43	Rekonstrukcja sceny obiektowej tennis_table ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.	118
44	Częściowo nieudana rekonstrukcja sceny bridge ze zbioru ETH3D dla scenariusza ośmioobrazowego, uzyskana za pomocą modelu VGGT. Źródło: opracowanie własne.	119
45	Nieudana rekonstrukcja sceny exhibition_hall ze zbioru ETH3D dla scenariusza ośmioobrazowego, uzyskana za pomocą modelu MAST3R. Źródło: opracowanie własne.	120
46	Częściowo nieudana rekonstrukcja sceny statue ze zbioru ETH3D dla scenariusza ośmioobrazowego, uzyskana za pomocą modelu VGGT. Źródło: opracowanie własne.	121

Spis tabel

1	Tabela porównawcza testowanych modeli rekonstrukcyjnych. Źródło: opracowanie własne na podstawie [13, 35, 15].	30
2	Tabela potencjalnych problemów rekonstrukcyjnych występujących w danych kategoriach scen. Źródło: opracowanie własne.	39
3	Zestawienie skryptów wykorzystanych do automatyzacji rekonstrukcji. Źródło: opracowanie własne.	44
4	Zestawienie skryptów wykorzystanych do agregacji wyników eksperymentów. Źródło: opracowanie własne.	46
5	Tabela przedstawiająca średni czas rekonstrukcji oraz średni czas inferencji przy zastosowaniu różnej liczby zdjęć źródłowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne.	48
6	Tabela przedstawiająca średnią wartość maksymalnej przypisanej pamięci VRAM w MiB przy zastosowaniu różnej liczby zdjęć źródłowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne.	51
7	Średnie maksymalne wykorzystanie pamięci RAM w MiB w ramach całego procesu dla testowanych modeli i poszczególnych scenariuszy liczby obrazów wejściowych. Źródło: opracowanie własne.	53
8	Średnia wartość maksymalnej przypisanej pamięci RAM w MiB w trakcie wykonywania rekonstrukcji przy zastosowaniu różnej liczby zdjęć wejściowych (scenariuszy) dla testowanych modeli. Źródło: opracowanie własne.	53
9	Skala zastosowana do jakościowej oceny rekonstrukcji. Źródło: opracowanie własne. .	57
10	Mediana i średnia zagregowanego wyniku jakościowego Q w zależności od liczby obrazów wejściowych. Źródło: opracowanie własne.	58
11	Średnie oceny kompletności oraz artefaktów i szumu w zależności od liczby obrazów wejściowych. Źródło: opracowanie własne.	59
12	Średnie wartości sumarycznej oceny jakości Q dla rekonstrukcji wykorzystujących dwa i cztery obrazy wejściowe, z uwzględnieniem trzech wariantów doboru obrazów. Źródło: opracowanie własne.	61

13	Mediana i średnia oceny jakościowej Q uzyskane przez analizowane modele dla poszczególnych kategorii scen. Źródło: opracowanie własne.	64
14	Wartości średniego bezwzględnego błędu procentowego MAPE uzyskane dla poszczególnych scen i liczby obrazów wejściowych. Pogrubieniem oznaczono najniższą wartość błędu dla każdej sceny. Źródło: opracowanie własne.	69
15	Referencyjne i przewidywane przez MapAnything długości analizowanych odcinków. Pogrubieniem oznaczono wartość najbliższą długości referencyjnej dla danego odcinka. Źródło: opracowanie własne.	70
16	Liczba przypadków przeszacowania i niedoszacowania rzeczywistych długości przez MapAnything w zależności od liczby obrazów wejściowych. Źródło: opracowanie własne.	71
17	Zestawienie wersji repozytoriów, wag, parametrów wejściowych oraz środowisk obliczeniowych zastosowanych podczas rekonstrukcji z wykorzystaniem modeli MapAnything, VGGT i MAST3R.	101
18	Podział scen ze zbiorów autorskiego oraz zbiorów ETH3D i LLFF na kategorie według dominującego rodzaju przedstawianej przestrzeni. Źródło: opracowanie własne.	103
19	Mediany i średnie ocen jakościowych w zależności od liczby obrazów wejściowych dla analizowanych modeli. Źródło: opracowanie własne.	105

Spis załączników

1	Specyfikacja komputera użytego w pracy	91
2	Autorski zbiór danych	93
3	Odnosnik do repozytorium	99
4	Tabela środowisk testowych.....	101
5	Zestawienie scen badanych zbiorów z podziałem na kategorie	103
6	Tabela wyników wizualnej analizy jakościowej	105
7	Ilustracje uzupełniające	107

Załącznik 1

Specyfikacja komputera użytego w pracy

Komputer	
OS	Windows 11 Education
OS typ	64-bit
CPU	AMD Ryzen 7 5800X3D CPU @ 3,4 GHz x 8
GPU	GeForce RTX 4070
RAM	32 GiB

Załącznik 2

Autorski zbiór danych

Autorski zbiór danych obejmuje 20 zróżnicowanych scen, z których każda została przedstawiona za pomocą ośmiu ujęć wykonanych z odmiennych punktów obserwacji. Sposób pozyskania ujęć nie był jednakowy dla wszystkich przypadków. Zmienne są zarówno położenie i kierunek obserwacji kamery, jak i trajektoria jej ruchu. Zbiór obejmuje szerokie spektrum przypadków: od prostych, wyraźnie wyodrębnionych obiektów, przez sceny o bogatej teksturze, aż po trudne przypadki zawierające roślinność, refleksy, powierzchnie słabo teksturowane, cienkie struktury, powtarzalne wzory i liczne przesłonięcia.

1. Bush_1



2. Bush_2



3. Cafe



4. Church



5. Gate



6. Kettle



7. Millenium_Falcon



8. Miscellaneous



9. Mural_bird



10. Mural_king



11. Office



12. Room_1



13. Room_2



14. Room_3



15. Room_4



16. Room_5



17. Spqr



18. Statue



19. Synagogue



20. Tennis_table



Załącznik 3

Odnośnik do repozytorium

Repozytorium GitHub zawiera skrypty rekonstrukcyjne, arkusze zbiorcze danych oraz wyniki przeprowadzonych testów.

<https://github.com/kamilsnopkowski/one-or-few-shot-3d-reconstruction>

Załącznik 4

Tabela środowisk testowych

Tabela 17. Zestawienie wersji repozytoriów, wag, parametrów wejściowych oraz środowisk obliczeniowych zastosowanych podczas rekonstrukcji z wykorzystaniem modeli MapAnything, VGGT i MAST3R.

Metoda	MapAnything	VGGT	MASt3R
Wersja repozytorium	wersja projektu: 1.1 tag: v1.1 commit: f065d13383ae84a7f80f0e0104a4d12afc7c7c82	wersja projektu: 0.0.1 tag: brak commit: 674a023bb8f3a685de3d01ff373e55abd7dd88a4	wersja projektu: brak tag: brak commit: f5209afc300cec36239a7ac992263f36847bbba0
Wagi	facebook/map-anything	facebook/VGGT-1B	naver/MASt3R_ViTLarge_BaseDecoder_512_catmlpdpt_metric
Rozdzielczość wejściowa modelu	518×392 px 518×336 px	518×392 px 518×350 px	512×384 px 512×336 px
Confidence	filtrowanie według confidence wyłączone	globalny 50. percentyl zachowywane są punkty z confidence większym lub równym medianie	Odrzucenie punktów o confidence 1,5; brak progowego filtrowania dopasowań.
Dtype	wagi: FP32; inferencja: AMP BF16; eksport: FP32	wagi: FP32; inferencja: AMP BF16; eksport: FP32	wagi: FP32 inferencja i optymalizacja: w FP32 z mnożeniem macierzy CUDA wykorzystującym TF32 eksport: FP32 Bez AMP.
Środowisko	Python 3.12.12 PyTorch 2.10.0+cu128; torchvision 0.25.0; CUDA PyTorch 12.8; cuDNN 9.10.2; CUDA Toolkit 12.0.140	Python 3.10.20 PyTorch 2.3.1+cu121; torchvision 0.18.1; CUDA PyTorch 12.1; cuDNN 8.9.2; CUDA Toolkit 12.0.140	Python 3.11.15 NumPy: 1.26.4 PyTorch 2.5.1, CUDA PyTorch 11.8, torchvision 0.20.1+cu118, cuDNN 9.1.0; CUDA Toolkit 12.0.140

Załącznik 5

Zestawienie scen badanych zbiorów z podziałem na kategorie

Tabela 18. Podział scen ze zbiorów autorskiego oraz zbiorów ETH3D i LLFF na kategorie według dominującego rodzaju przedstawianej przestrzeni. Źródło: opracowanie własne.

Kategoria scen	Autorski	ETH3D	LLFF
Wewnętrzne	office, room_1, room_2, room_3, room_4, room_5, cafe, church	bridge, exhibition_hall, lecture_room, lounge, old_computer	room, trex
Zewnętrzne	gate, mural_bird, mural_king, synagogue	boulders, observatory, terrace_2	-
Naturalne	bush_1, bush_2	botanical_garden	fern, leaves, flower, orchids
Obiektowe	kettle, millenium_falcon, miscellaneous, spqr, statue, tennis_table	statue	fortress, horns

Załącznik 6

Tabela wyników wizualnej analizy jakościowej

Q — łączny wynik rekonstrukcji, C — ocenę kompletności, G — spójności geometrycznej, A — artefaktów i szumu, natomiast D — odwzorowania struktury i szczegółów.


Tabela 19. Mediany i średnie ocen jakościowych w zależności od liczby obrazów wejściowych dla analizowanych modeli. Źródło: opracowanie własne.

Model	Kryterium	1 obraz	2 obrazy	4 obrazy	8 obrazów
VGGT	Q (med.)	7	6	6	6
	Q (śr.)	6,55	6,45	6,24	6,13
	C (med.)	1	1	1	1
	C (śr.)	1,11	1,24	1,24	1,24
	G (med.)	2	2	2	2
	G (śr.)	1,84	1,71	1,68	1,66
	A (med.)	2	2	2	2
	A (śr.)	2,24	2,08	1,95	1,84
	D (med.)	1	1	1	1
	D (śr.)	1,37	1,42	1,37	1,39
MASt3R	Q (med.)	–	6	6	6
	Q (śr.)	–	6,11	6,08	6,00
	C (med.)	–	1	2	2
	C (śr.)	–	1,42	1,53	1,61
	G (med.)	–	1	1	1
	G (śr.)	–	1,39	1,42	1,39
	A (med.)	–	2	2	1
	A (śr.)	–	1,76	1,53	1,37
	D (med.)	–	1,5	2	2
	D (śr.)	–	1,53	1,61	1,63
MapAnything	Q (med.)	8	8	8	8
	Q (śr.)	8,47	8,05	8,00	7,79
	C (med.)	2	2	3	3
	C (śr.)	2,34	2,42	2,47	2,47
	G (med.)	2	2	2	2
	G (śr.)	1,89	1,71	1,68	1,66
	A (med.)	2	2	2	2
	A (śr.)	2,18	1,89	1,74	1,58
	D (med.)	2	2	2	2
	D (śr.)	2,05	2,03	2,11	2,08


Załącznik 7

Ilustracje uzupełniające


Rekonstrukcje z pojedynczego obrazu



Rysunek 19. Rekonstrukcja sceny church ze zbioru autorskiego w scenariuszu jednoobrazowym, uzyskana za pomocą modeli VGGT oraz MapAnything. Źródło: opracowanie własne.



Rysunek 20. Rekonstrukcja sceny mural_king ze zbioru autorskiego w scenariuszu jednoobrazowym, uzyskana za pomocą modeli VGGT oraz MapAnything. Źródło: opracowanie własne.




Rysunek 21. Rekonstrukcja sceny flower ze zbioru LLFF w scenariuszu jednoobrazowym, uzyskana za pomocą modeli VGGT oraz MapAnything. Źródło: opracowanie własne.




Rysunek 22. Rekonstrukcja sceny old_computer ze zbioru ETH3D w scenariuszu jednoobrazowym, uzyskana za pomocą modeli VGGT oraz MapAnything. Źródło: opracowanie własne.

Poprawa kompletności C wraz ze zwiększaniem liczby zdjęć




Rysunek 23. Rekonstrukcja sceny observatory ze zbioru ETH3D dla scenariusza dwuobrazowego (środkowe zdjęcie) oraz czteroobrazowego (prawe zdjęcie), uzyskana za pomocą modelu VGGT. Źródło: opracowanie własne.




Rysunek 24. Rekonstrukcja sceny room_3 ze zbioru autorskiego dla scenariusza jednoobrazowego (środkowe zdjęcie) oraz dwuobrazowego (prawe zdjęcie), uzyskana za pomocą modelu VGGT. Źródło: opracowanie własne.


Charakterystyczne zachowania modeli




Rysunek 25. Rekonstrukcja sceny kettle ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MASt3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 26. Rekonstrukcja sceny terrace_2 ze zbioru ETH3D dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 27. Rekonstrukcja sceny bridge ze zbioru ETH3D dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 28. Rekonstrukcja sceny room_5 ze zbioru autorskiego dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MASt3R oraz MapAnything. Źródło: opracowanie własne.



Rysunek 29. Rekonstrukcja sceny lounge ze zbioru ETH3D dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MASt3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 30. Rekonstrukcja sceny room_3 ze zbioru autorskiego dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 31. Rekonstrukcja sceny room ze zbioru LLFF dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.


Kategoria sceny



Rysunek 32. Rekonstrukcja sceny wewnętrznej office ze zbioru autorskiego dla scenariusza ośmioobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 33. Rekonstrukcja sceny wewnętrznej room_2 ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.



Rysunek 34. Rekonstrukcja sceny wewnętrznej cafe ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.



Rysunek 35. Rekonstrukcja sceny naturalnej fern ze zbioru LLFF dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 36. Rekonstrukcja sceny naturalnej orchids ze zbioru LLFF dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MASt3R oraz MapAnything. Źródło: opracowanie własne.



Rysunek 37. Rekonstrukcja sceny naturalnej bush_1 ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MASt3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 38. Rekonstrukcja sceny zewnętrznej gate ze zbioru autorskiego dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 39. Rekonstrukcja sceny zewnętrznej boulders ze zbioru ETH3D dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 40. Rekonstrukcja sceny zewnętrznej synagogue ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.



Rysunek 41. Rekonstrukcja sceny obiektowej horns ze zbioru LLFF dla scenariusza dwuobrazowego, uzyskana za pomocą modeli VGGT, MAST3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 42. Rekonstrukcja sceny obiektowej miscellaneous ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MASt3R oraz MapAnything. Źródło: opracowanie własne.




Rysunek 43. Rekonstrukcja sceny obiektowej tennis_table ze zbioru autorskiego dla scenariusza czteroobrazowego, uzyskana za pomocą modeli VGGT, MASt3R oraz MapAnything. Źródło: opracowanie własne.


Przypadki rekonstrukcji częściowo lub całkowicie nieudanych



Rysunek 44. Częściowo nieudana rekonstrukcja sceny bridge ze zbioru ETH3D dla scenariusza ośmioobrazowego, uzyskana za pomocą modelu VGGT. Źródło: opracowanie własne.



Rysunek 45. Nieudana rekonstrukcja sceny exhibition_hall ze zbioru ETH3D dla scenariusza ośmioobrazowego, uzyskana za pomocą modelu MASt3R. Źródło: opracowanie własne.



Rysunek 46. Częściowo nieudana rekonstrukcja sceny statue ze zbioru ETH3D dla scenariusza ośmioobrazowego, uzyskana za pomocą modelu VGGT. Źródło: opracowanie własne.